

ANÁLISE DE SENTIMENTO DE NOTÍCIAS DO MERCADO FINANCEIRO

Matheus Cabral dos Santos Falcão

Projeto de Graduação apresentado ao Curso de Engenharia Eletrônica e de Computação da Escola Politécnica, Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Engenheiro.

Orientador: Heraldo Luís Silveira de Almeida

Rio de Janeiro

Março de 2020

ANÁLISE DE SENTIMENTO DE NOTÍCIAS DO MERCADO FINANCEIRO

Matheus Cabral dos Santos Falcão


PROJETO DE GRADUAÇÃO SUBMETIDO AO CORPO DOCENTE DO CURSO
DE ENGENHARIA ELETRÔNICA E DE COMPUTAÇÃO DA ESCOLA
POLITÉCNICA DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO
PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU
DE ENGENHEIRO ELETRÔNICO E DE COMPUTAÇÃO

Autor:



Matheus Cabral dos Santos Falcão

Orientador:




Prof. Heraldo Luís Silveira de Almeida, D.Sc.

Examinador:



Prof. Flávio Luis de Mello, D.Sc.

Examinador:



Prof. Roberto Ivo da Rocha Lima Filho, D.Sc.

Rio de Janeiro

Março de 2020

Declaração de Autoria e de Direitos

Eu, *Matheus Cabral dos Santos Falcão* CPF 149.005.417-02, autor da monografia *Análise de Sentimento de Notícias do Mercado Financeiro*, subscrevo para os devidos fins, as seguintes informações:

1. O autor declara que o trabalho apresentado na disciplina de Projeto de Graduação da Escola Politécnica da UFRJ é de sua autoria, sendo original em forma e conteúdo.
2. Excetuam-se do item 1. eventuais transcrições de texto, figuras, tabelas, conceitos e ideias, que identifiquem claramente a fonte original, explicitando as autorizações obtidas dos respectivos proprietários, quando necessárias.
3. O autor permite que a UFRJ, por um prazo indeterminado, efetue em qualquer mídia de divulgação, a publicação do trabalho acadêmico em sua totalidade, ou em parte. Essa autorização não envolve ônus de qualquer natureza à UFRJ, ou aos seus representantes.
4. O autor pode, excepcionalmente, encaminhar à Comissão de Projeto de Graduação, a não divulgação do material, por um prazo máximo de 01 (um) ano, improrrogável, a contar da data de defesa, desde que o pedido seja justificado, e solicitado antecipadamente, por escrito, à Congregação da Escola Politécnica.
5. O autor declara, ainda, ter a capacidade jurídica para a prática do presente ato, assim como ter conhecimento do teor da presente Declaração, estando ciente das sanções e punições legais, no que tange a cópia parcial, ou total, de obra intelectual, o que se configura como violação do direito autoral previsto no Código Penal Brasileiro no art.184 e art.299, bem como na Lei 9.610.
6. O autor é o único responsável pelo conteúdo apresentado nos trabalhos acadêmicos publicados, não cabendo à UFRJ, aos seus representantes, ou ao(s) orientador(es), qualquer responsabilização/ indenização nesse sentido.
7. Por ser verdade, firmo a presente declaração.



Matheus Cabral dos Santos Falcão

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
Escola Politécnica - Departamento de Eletrônica e de Computação
Centro de Tecnologia, bloco H, sala H-217, Cidade Universitária Rio
de Janeiro - RJ CEP 21949-900

Este exemplar é de propriedade da Universidade Federal do Rio de Janeiro, que poderá incluí-lo em base de dados, armazenar em computador, microfilmear ou adotar qualquer forma de arquivamento.

É permitida a menção, reprodução parcial ou integral e a transmissão entre bibliotecas deste trabalho, sem modificação de seu texto, em qualquer meio que esteja ou venha a ser fixado, para pesquisa acadêmica, comentários e citações, desde que sem finalidade comercial e que seja feita a referência bibliográfica completa.

Os conceitos expressos neste trabalho são de responsabilidade do(s) autor(es).

*“Só em Ti confiarei
Eu nada temerei
Em frente eu irei “*

AGRADECIMENTO

Essa tese é um fruto de uma longa caminhada, marcada por muitas horas de trabalho. É um trabalho construído com o apoio e a colaboração de diversas pessoas.

Primeiramente agradeço a Deus que conduz minha vida e permitiu que essa realização fosse possível.

À minha família, por todo amor e suporte oferecidos. Obrigado aos meus pais, Sérgio e Márcia, por sempre terem me orientado e investido para garantir a melhor educação, vocês são minha inspiração e exemplo de superação. Com certeza finalizar esse trabalho é uma conquista nossa.

Obrigado aos meus irmãos, Moisés e Sarah, pela amizade e por tornarem meus dias mais tranquilos. Obrigado a minha namorada Gabriella, por estar ao meu lado em todos os momentos.

Ao professor Heraldo, que com toda sua sabedoria ajudou a lapidar as ideias iniciais para o desenvolvimento desse trabalho, cujas sugestões sempre foram pertinentes. Por fim, agradeço aos meus amigos, pelo companheirismo e por tornarem minha trajetória mais leve.

RESUMO

O objetivo dessa dissertação foi analisar o efeito do sentimento textual das notícias financeiras sobre o comportamento dos preços no mercado acionário brasileiro. Para analisar o efeito do tom das notícias sobre o comportamento de oscilação dos preços no mercado brasileiro, foi verificada a influência que o sentimento textual das notícias realiza sobre alguns ativos. Para alcançar o objetivo do trabalho, foram utilizados os valores diários do índice Bovespa e um grupo de cinco ações de diferentes setores da economia, Ambev, Itaú, Magazine Luiza, Petrobrás e Vale. Além disso, foram analisados os textos das notícias financeiras do Jornal Valor Econômico e Folha de São Paulo, no período de 01 de janeiro de 2013 a 16 de agosto de 2019, correspondendo a 1.470 observações diárias. Os resultados levantados mostram os sentimentos tendem a ser neutros na maioria dos dias, mas que em dias de incerteza economia pessimista eles tendem a seguir essa tendência.

Dessa maneira, conclui-se que, os conteúdos dos jornais no Brasil, influenciam na visão dos investidores nos momentos em que existe uma maior incerteza no mercado e na economia. O trabalho buscou aprimorar a visão sobre o papel da mídia no mercado acionário de países emergentes, levantando evidências de que os corpus das notícias são importantes fontes de informações para a tomada de decisão.

Palavras-Chave: Notícias Financeiras; Sentimento Textual; Mercado Acionário; Tomada de decisão.

ABSTRACT

The purpose of this dissertation was to analyze the effect of textual feelings in financial news on the behavior of prices in the Brazilian stock market. To analyze the tone effect of the news on the price fluctuation behavior in the Brazilian market, the influence of the textual feeling of the news on some assets was verified. To achieve the work objective, the daily Bovespa index values and a group of five stocks from different sectors of the economy, Ambev, Itaú, Magazine Luiza, Petrobrás and Vale were used. In addition, the financial news texts of the newspaper Valor Econômico and Folha de São Paulo from January 1, 2013 to August 16, 2019, corresponding to 1,470 samples, were analyzed. The surveyed results show that feelings seem to be neutral on most days, but on days of pessimistic economic uncertainty they seem to follow this trend.

Thus, we conclude that the content of newspapers in Brazil influences investors views at times when there is greater uncertainty in the market and in the economy. The work sought to improve the view on the role of the media in the emerging markets' drive market, raising the records that the news corpus are important sources of information for decision making.

Key words: Financial News; Textual Feeling; Stock Market; Decision making.

SIGLAS

API – Application Programming Interface

ARCH – Autoregressive Conditional Heteroskedasticity

CeDEx - Centre for Decision Research and Experimental Economics)

CSS – Cascading Style Sheets

DJIA – Dow Jones Industrial Average

ffn – Financial Functions for Python

GARCH – Generalized Autoregressive Conditional Heteroskedasticity

HME - Hipótese do Mercado Eficiente

NLTK – Natural Language Toolkit

ONU – Organização das Nações Unidas

PUCRS – Pontifícia Universidade Católica do Rio Grande do Sul

ROI – Return on Investment

VaR - Value-at Risk

Sumário

1	Introdução	1
1.1	Tema	1
1.2	Delimitação	1
1.3	Justificativa	2
1.4	Objetivos	3
1.5	Metodologia	3
1.6	Descrição	4
2	Fundamentações teóricas	5
2.1	Eficiência de mercado	5
2.2	Economia Comportamental	8
2.3	Análise de Sentimento	11
2.3.1	Principais Conceitos	12
2.3.1.1	Detecção de polaridade e subjetividade de sentimentos	12
2.3.1.2	Presença de termos x frequência	13
2.3.1.3	Partes da marcação de fala	13
2.3.1.4	Negação	14
2.3.2	Níveis de análise	14
2.3.2.1	Análise de sentimentos em nível de documento	14
2.3.2.2	Análise de sentimentos em nível de sentença	14
2.3.2.3	Análise de sentimentos em nível de entidade e palavra	15
2.3.3	Abordagens baseadas no léxico	15
2.3.3.1	Abordagem manual	16
2.3.3.2	Abordagem baseada em dicionário	16
2.3.3.3	Abordagem baseada em corpus	17
2.4	Incerteza Econômica	18

2.5 – Cisnes Negros	19
2.5.1 – Falácia Narrativa	20
2.5.2 – "Mediocristão" ou "Extremistão"	21
3 Metodologia	24
3.1 – Aquisição dos Dados	25
3.1.1 – Ativos	26
3.1.1.1 – Ibovespa	26
3.1.1.2 – Petrobras	27
3.1.1.3 – Vale	28
3.1.1.4 – Ambev	28
3.1.1.5 – Itaú	29
3.1.1.6 – Magazine Luiza	29
3.1.2 – Dados Financeiros	30
3.1.3 – Coleta das notícias	31
3.2 – Modelagem Estatística	34
3.2.1 – Retorno	34
3.2.2 – Risco	36
3.2.2.1 – Desvio Padrão	37
3.2.2.2 – Coeficiente de Variação	37
3.2.2.3 – Volatilidade	37
3.2.2.4 – Covariância	38
3.2.2.5 – Coeficiente de correlação	39
3.2.3 – Outliers	39
3.3 – Análise de sentimento das Notícias	42
3.3.1 – Pré processamento das notícias	42
3.3.1.1 – Filtro de notícias irrelevantes	42
3.3.1.2 – Conversão para minúsculo	43
3.3.1.3 – Remoção de palavras irrelevantes	43
3.3.1.4 – Remoção de espaços, pontuação e números	43
3.3.2 – Léxicos	43
3.3.2.1 – OpLexicon Reader	45
3.3.2.2 – LiwcReader	45
3.3.2.3 – SentiLexReader	46

3.3.3 – Algoritmo	47
4 Resultados	48
4.1 – Análise das notícias	48
4.2 – Análise estatística	53
4.3 – Análise de sentimento	60
5 Conclusão	73
5.1 – Resumo e conclusões	73
5.2 – Limitações e Trabalho Futuro	74
Bibliografia	76

Lista de Figuras

Figura 1 – Desenho da Pesquisa	25
Figura 2 – Participação dos ativos na Bovespa	26
Figura 3 – Selenium IDE	32
Figura 4 - Quartil	41
Figura 5 – Preços da Vale com Notícias	55
Figura 6 – Correlação entre os Ativos	60
Figura 7 – Wordcloud Substantivos	61
Figura 8 – Wordcloud Verbos	62
Figura 9 – Wordcloud Adjetivos	62

Lista de Tabelas

Tabela 1 – Notícias da Folha de São Paulo	49
Tabela 2 – Notícias do Valor Econômico	49
Tabela 3 – Ranking das palavras dos Títulos	52
Tabela 4 – Ranking das palavras das Descrições	52
Tabela 5 – Retorno Mensal da Magazine Luiza	55
Tabela 6 – Análise estatística	59
Tabela 7 – Análise de Sentimento Geral	69
Tabela 8 – Análise pelo Sentimento do Dia	70
Tabela 9 – Análise de Sentimento dos Outliers	71

Lista de Gráficos

Gráfico 1 – Distribuição de Notícias	50
Gráfico 2 – Quantidade de Palavras no Título e Descrição	51
Gráfico 3 – Quantidade de Palavras na Título e Descrição sem Stopword	51
Gráfico 4 – Preços dos Ativos	53
Gráfico 5 – Volumes dos Ativos	54
Gráfico 6 – Retorno dos Ativos	56
Gráfico 7 – Desempenho Relativo	57
Gráfico 8 – Histograma dos Ativos	57
Gráfico 9 – Análise de Sentimento Anual	65
Gráfico 10 – Análise de Sentimento Mensal	65
Gráfico 11 – Histograma LIWC	66
Gráfico 12 – Histograma Sentilex	67
Gráfico 13 – Histograma OpLexicon	67
Gráfico 14 – Distribuição LIWC por Jornal	68
Gráfico 15 – Distribuição Sentilex por Jornal	68
Gráfico 16 – Distribuição OpLexicon por Jornal	69

Lista de Equações

Equação 1 – Taxa de Retorno	34
Equação 2 – Retorno Linear	35
Equação 3 – Retorno acumulado	36
Equação 4 – Desvio Padrão	37
Equação 5 – Coeficiente de Variação	37
Equação 6 – Covariância	38
Equação 7 – Coeficiente de Correlação	39

Capítulo 1

Introdução

1.1 Tema

O tema do trabalho é o estudo do comportamento do mercado financeiro mediante ao impacto das notícias. Com isso, para solucionar o problema em questão será criado um modelo computacional para analisar o sentimento de notícias em dias que ativos sofreram grandes retornos.

1.2 Delimitação

A era da Internet é marcada pela grande quantidade de dados que se tem à disposição. Ela democratizou a informação, e portanto, a produção de conteúdo tem se intensificado cada vez mais, principalmente por conta da descentralização, visto que qualquer pessoa pode escrever em seu blog ou rede social.

Como o objeto de estudo são notícias e existem inúmeras fontes, o modelo será submetido a notícias de duas fontes confiáveis da imprensa brasileiras, Valor Econômico e Folha de São Paulo. Além disso, como as notícias são correlacionadas com ativos do mercado financeiro, o algoritmo descartará notícias fora do escopo, tais como notícias sobre esporte, culinária, cinema, carros e entre outros.

1.3 Justificativa

Por definição, big data é uma quantidade grande de dados armazenados que serão processados e analisados. A trajetória do big data é longa e tem aplicações em diversas áreas. A partir dessa grande quantidade de dados se consegue gerar insights, criar produtos e/ou serviços e influenciar na tomada de decisão.

O volume de notícias as enquadra no aspecto de big data, na qual podem ser cruzadas para prever tendências em diversas áreas de pesquisa e negócios. Cada notícia impacta seu receptor de uma forma e gera um sentimento específico. Por sua vez, a compreensão dos pensamentos, emoções, sentimentos e comportamentos tem crescido constantemente por conta dos avanços da neurociência. Uma área que vem ganhando muito destaque dentro desse contexto e tem muita relação com esse trabalho, é a Economia comportamental.

A pesquisadora Flávia Ávila, mestre em Economia Comportamental pelo CeDEx group (Centre for Decision Research and Experimental Economics), da Universidade de Nottingham, na Inglaterra, e uma das coordenadoras do primeiro Guia de Economia Comportamental e Experimental do Brasil, explica que um dos pontos fundamentais da Economia Comportamental é utilizar experimentos controlados, big data, neurociência e outros métodos empíricos para testar e medir quais, como e o quanto fatores econômicos, psicológicos, sociais e emocionais afetam uma determinada tomada de decisão.

Em meio a grande quantidade de informações, os estudiosos de economia comportamental têm buscado estudar o papel das notícias nos mercados financeiros. Resultados de alguns estudos relacionados ao sentimento textual ressaltam que o tom dos textos das notícias apresenta relação com as oscilações do mercado, em termos do risco e do retorno dos ativos (VERHOEVEN, 2016) [1]. Apesar disso, os coeficientes das regressões apresentam magnitude pequena, o que indica um impacto baixo, fazendo Tetlock (2010) [2] questionar o impacto das notícias sobre a volatilidade dos ativos. Como esses estudos concentram-se no mercado acionário dos Estados Unidos, o objetivo deste trabalho é ver os impactos em um país emergente como o Brasil.

Além disso, utilizamos nesta tese o conceito de Cisne Negro [3], criado por Nassim Taleb, estatístico, analista de riscos Líbano-americano e matemático de formação. Segundo ele, Cisne Negro é um evento imprevisível fora da curva de extrema raridade e que provoca um impacto violento na sociedade. Eventos como crises globais, a ascensão do Google, atentados terroristas em grande escala como o de 11 de setembro, são exemplos de Cisnes Negros que são praticamente impossíveis de serem previstos. Aplicação desse conceito será utilizada como base para buscarmos dias que os ativos tiveram maiores retornos para entendermos os motivos.

Neste sentido, o presente trabalho é um complemento de estudos anteriores, entretanto, buscando originalidade, visto que o foco da pesquisa é entender momentos de euforia do mercado, investigando explicações sobre o impacto que o tom das notícias exerce. Os modelos disponíveis até o momento estão associados para entender os sentimentos gerais das notícias, enquanto nesse busca-se entender o que causaram Cisnes Negros em diferentes ativos de diferentes setores, com o propósito de se entender se a notícia tem impacto sistemático ou isolado.

1.4 Objetivo

O objetivo geral é apresentar um modelo computacional capaz de correlacionar as notícias de jornais com a volatilidade de ativos específicos de diferentes setores, tanto em dias específicos de quedas e altas brutas, quanto em todo o espaço de tempo do banco de dados.

1.5 Metodologia

Para alcançar esse objetivo, o projeto é dividido em três etapas:

(a) explorar big data de notícias financeiras e dados financeiros, a fim de identificar padrões de comportamentos que possam contribuir com o gerenciamento de risco e também na otimização da tomada de decisão no mercado acionário brasileiro;

(b) construir uma análise estatística para encontrar os dias que sofreram maiores quedas e altas.

(c) analisar o sentimento das notícias e aprofundar as explicações sobre o impacto que o conteúdo informacional das notícias provoca sobre as atividades do mercado acionário.

A primeira etapa do trabalho será o desenvolvimento de um modelo computacional em python utilizando a biblioteca Selenium. Ele irá automaticamente coletar as datas, títulos, descrições e links das notícias do Valor Econômico e Folha de São Paulo. Infelizmente, notícias anteriores ao ano de 2013 não são encontradas de forma contínua no Valor Econômico, portanto serão analisadas apenas após esse ano. Além disso, a coleta dos dados financeiros serão feitas por meio da biblioteca ffN.

Posteriormente, a segunda etapa do trabalho após a coleta dos preços serão calculados no Python os retornos logarítmicos dos ativos para identificar as datas dos dias que sofreram as maiores perdas e ganhos. As análises estatísticas serão realizadas e os outliers identificados.

Por fim, a terceira etapa consistirá na análise de sentimento das notícias no python utilizando a biblioteca NLTK para processamento de linguagem natural. Para se ter uma análise completa em relação ao sentimento das notícias, serão usados dicionários abertos em português, tais como: OP Lexicon Reader, SentiLex Reader e Liwc Reader [4].

1.6 Descrição

O capítulo 2 trará alguns conceitos do domínio do problema, como a fundamentação teórica necessária para embasar a tese. No capítulo 3 são apresentadas as metodologias utilizadas para se encontrar os resultados. No capítulo 4 os resultados são apresentados detalhadamente. Por fim, no capítulo 5 são apresentadas as conclusões.

Capítulo 2

Fundamentação Teórica

2.1 Eficiência de mercado

Os principais motivadores do estudo da hipótese do mercado eficiente surgem a partir da necessidade de explicar o movimento dos preços das ações e identificar comportamentos padronizados dos preços no mercado.

Um dos primeiros estudiosos sobre mercado eficiente foi Bachelier [5] que começou a desenvolver sua tese em 1900 na França. Com foco no mercado de opções, ele analisou o comportamento dos preços com base na especulação dos investidores e na teoria das probabilidades para explicar o movimento dos preços dos ativos. Segundo suas investigações, o conhecimento das informações passadas não dão vantagens ou desvantagens para os investidores, visto que o preço das ações são um reflexo das expectativas futuras. Com base nisso, conclui-se que se tem uma competição justa.

Bachelier também foi responsável por começar as primeiras ideias sobre o comportamento aleatório dos preços ou Random Walk, resultado do estudo das volatilidades dos ativos em relação a processos especulativos de investidores. Sua conclusão do random walk é que a aleatoriedade dos preços demonstram a imprevisibilidade dos ativos o que dificulta a estimativa de seus preços.

Outro estudioso crucial foi Osborne [6] em 1959. "Brownian Motion in the Stock Market" apresenta o conceito de que ativos do índice americano New York Stock Exchange (NYSE) tinham preços com valores independentes de variáveis

aleatórias, que são os principais drivers de mudança de preço. Portanto, os preços teriam um comportamento imprevisível, visto que os investimentos são feitos levando em conta a expectativa futura de crescimento do valor dos ativos, o que resulta em uma independência nas transações futuras.

Diversos estudos a respeito da volatilidade de preços dos ativos e de como especular seu valor futuro foram realizados até a década de 1950, utilizando como argumento principal o fair game. Entretanto, não conseguiram demonstrar uma interdependência na tomada de decisão de investidores, ou seja, a escolha de um investidor impacta os demais.

Surgem novos estudos em meio a esse contexto, em 1965, Samuelson [7] apresentou um deles. Seu estudo foi relacionado a volatilidade das commodities, mais especificamente do trigo. Ao analisar sua série histórica ele observa impactos de aspectos de sazonalidade no ativo. Os preços das commodities e a sazonalidade em meio ao processo produtivo do trigo são fatores que o levam a criticar o conceito de preços serem randômicos.

Com essa conclusão, Samuelson não utiliza o fair game para analisar o comportamento dos ativos. Ao utilizar Martingale [8], ele diz que preços futuros não são previstos por preços passados e que em um investimento o retorno esperado é igual ou maior que o atual.

Outro estudioso foi Eugene Fama [9] que acompanhou entre 1957 e 1962 as flutuações de 30 ações integrantes da Dow Jones Industrial Average (DJIA). Ao analisar seus retornos diários e correlacioná-los, encontrou uma autocorrelação positiva de primeira ordem em 77% dos ativos. Pelo fato das variações serem pequenas, ele interpretou que esse comportamento era um reflexo de um random walk e que essa era uma relação importante no processo de precificação no mercado de capitais.

Em 1970, Fama reafirma a aleatoriedade do comportamento dos ativos e a partir das modelagens de Martingale e fair game, propõem a Hipótese do Mercado Eficiente (HME) [10]. Essa teoria tem como fundamentação que os preços são reflexo das informações de mercado e que todos têm acesso de igual forma.

Consoante Fama, um mercado eficiente detêm determinadas características específicas: todos os players de mercado tem acesso a todas as informações disponíveis; o impacto que as informações relacionadas aos preços causam nos investidores são iguais; e não há custos de transação dos títulos.

Além disso, as correções dos preços são consequências de três níveis diferentes de informação: (a) forma fraca – conjunto de informações passadas nos preços; (b) forma semiforte - informações de domínio público; e (c) forma forte – informações de domínio público e informações privilegiadas [11].

A HME em sua teorização propõe que investidores têm racionalidade nas suas tomadas de decisão [12]. Tal afirmação leva em conta que a entrada de novas notícias no mercado são sinais para ajustar as expectativas dos investidores em relação a futuros fluxos de caixa de ativos.

Portanto, quando temos uma entrada de informação que anima ou frustra os investidores teremos compra ou venda de ativos fazendo com que os preços se ajustem conforme a expectativa futura de retorno. Dessa forma, as informações no curto prazo tem influência nos preços dos ativos, o que mantém o mercado eficiente visto que todos têm acesso a essas informações.

Com isso, um mercado eficiente é um conceito atrelado a um mercado ideal, em que os preços dos ativos refletem sinais que ajudam na tomada de decisão dos investimentos, visto que são responsáveis por quantificar o valor de mercado de empresas de capital aberto [13].

Entretanto, a ideia de um mercado eficiente é generalista, e por ser um conceito, não tem um método científico que a teste e prove. Logo, os estudos direcionados sobre os comportamentos dos preços são baseados na expectativa de retorno futuro com modelagens para encontrar os preços dos ativos.

Em contraponto a teoria dos mercados eficientes e analisando suas limitações conceituais, estudiosos começam a questionar a respeito da racionalidade do investidores. Tvesky e Kahneman foram pioneiros na arguição da racionalidade limitada dos investidores [14]. Aspectos psicológicos, dentre eles os desvios

cognitivos, são grandes influenciadores na tomada de decisão, posto que se tem uma grande aversão a risco, e especialmente a perda.

Apesar dessa diferente visão abordada pela economia comportamental, ela não explica em vias práticas o que seria um mercado com racionalidade limitada. Com isso, vários estudiosos começaram a fazer estudos empíricos para invalidar ou adaptar suas teses para um diferente formato a hipótese de mercado eficiente.

Diversos autores defenderam a tese que as informações não refletem no preço no exato momento, visto que na realidade do mercado existem custos de transação e informações privilegiadas. Portanto, a influência da informação nos preços é parcial e não completa, visto que as informações privilegiadas irão beneficiar apenas uma Gama de investidores e não o todo. Dessa forma, há uma diferença de expectativa entre os agentes de mercado, demonstrando seu desequilíbrio e sua ineficiência.

2.2 Economia Comportamental

O ponto principal da economia comportamental é a racionalidade. A teoria econômica clássica tem como suposição fundamental que os agentes econômicos são seres racionais, onde todas as tomadas de decisão são exclusivamente sem envolvimento de emoções, baseada em análises de dados e estatísticas.

Para eles as variações de curto prazo são apenas movimentos aleatórios pontuais que não impactam o valor do ativo, pois se considerar no longo prazo esses ruídos se cancelarão. Segundo a economia tradicional, o melhor entendimento do mercado financeiro é através da capacidade de modelá-lo matematicamente.

Em confronto a economia tradicional, vem o conceito da economia comportamental que tem como foco a utilização das áreas de psicologia e economia para explicar os comportamentos de agentes econômicos. Seus principais precursores são Daniel Kahneman e Amos Tversky, ambos psicólogos, que desenvolveram uma nova visão para o funcionamento psicológico da tomada de decisão. Estes expuseram os principais pontos que influenciam nas decisões econômicas e as diferentes percepções desta nova teoria. A partir disso inovaram

no modelo de entendimento do funcionamento do mercado financeiro a partir dos aspectos psicológicos que geralmente influenciam nas escolhas dos indivíduos.

A tese de maior relevância escrita por eles foi a apresentação da Teoria da Perspectiva, que veio em confronto a Teoria da Utilidade Esperada que foi desenvolvida por Daniel Bernoulli em 1738 [15]. Segundo Bernoulli, a utilidade é medida em função da riqueza absoluta, e a utilidade marginal diminui à medida que a riqueza aumenta, devido à aversão ao risco.

Já na tese de Kahneman e Tversky, o valor é atribuído a ganhos e perdas, e não a riqueza final. A função de valor é definida nos desvios de um ponto de referência e é normalmente côncava para ganhos (implicando média de risco), geralmente convexa para perdas (busca de risco). Geralmente, a função é mais inclinada para perdas do que para ganhos, devido a fatores psicológicos que fazem as pessoas terem uma grande aversão a perdas. Além da tese, eles realizaram experimentos que a confirmaram. Por fim, a teoria da perspectiva teve um resultado que prediz um padrão quádruplo distinto de atitudes de risco:

- 1) Aversão ao risco por ganhos de probabilidade moderada a alta e perdas de baixa probabilidade;
- 2) Busca de risco por ganhos de baixa probabilidade e perdas de probabilidade moderada a alta.

Com intuito de exemplificar a teoria, supõe-se que um indivíduo tenha a possibilidade de receber R\$ 500, porém pode receber de duas formas. Na primeira você recebe de forma direta os R\$ 500. Na segunda, você recebe R\$1.000 primeiro de forma que terá que devolver R\$ 500 após um tempo. No final a riqueza recebida será a mesma, entretanto a sensação das duas formas de receber o valor final é diferente. O que deixa claro a aversão à perda das pessoas, que provavelmente optaram pela primeira escolha.

Uma forma complementar de vermos essa aversão é através de uma nova situação. Se uma pessoa tiver a opção de receber R\$4.000 com 100% de chance, ou R\$6.000 com 70% de chance, provavelmente ela irá optar pela primeira opção,

visto que é preferido um ganho garantido em comparação a uma chance de não ter nenhum ganho. Exemplificando mais uma vez os efeitos que a incerteza causa.

O comportamento com o ganho potencial é bem diferente em relação a aversão à perda. De forma irracional, as pessoas desprezam sua aversão ao risco quando um ganho potencial é grande, apesar da probabilidade de obtê-lo seja pífia. Um exemplo desse caso é em relação a loteria, onde pessoas sonham em transformar suas vidas ganhando uma fortuna e desprezam o fato de que a probabilidade de ganhar é muito baixa.

Outro estudioso importante para as finanças comportamentais, é Richard Thaler (1980). Ele discute sobre a existência de situações nas quais os agentes econômicos se comportam de maneira inconsistente com a teoria econômica e propõe que a teoria de Kahneman e Tversky em perspectiva seja usada como base para uma teoria descritiva alternativa. Além disso, ele trabalha com outros assuntos complementares: sub-ponderação dos custos de oportunidade, dificuldade em desprezar os custos irrecuperáveis, comportamento de pesquisa, e pré-compromisso e autocontrole [16].

O artigo de Thaler introduziu a noção de "contabilidade mental". O conceito dela pode ser demonstrado por uma série de situações que os consumidores fazem. Se uma pessoa recebe R\$1000 pelo seu salário ou R\$1000 na loteria ou em um reembolso, elas gastaram esse dinheiro de formas diferentes. Essa tendência ocorre devido ao costume que se têm em gastar o dinheiro imprevisível de forma mais impulsiva. Thaler também fala sobre a influência da forma de pagamento, onde os indivíduos tendem gastar mais se utilizarem cartão de crédito ou débito ao invés de dinheiro vivo, embora a fonte dele seja a mesma.

Outro estudo desenvolvido por Thaler é a Teoria do "empurrão". Ele aborda a propensão das pessoas a fazerem doações para caridade se tiverem conhecimento que pessoas do seu círculo social fizeram o mesmo. Essa tese é interessante pois aborda a psicologia social, onde mostra que indivíduos gostam de fazer coisas parecidas e que se importam com a opinião a respeito delas.

Tversky e Kahneman voltam em 1981 com mais um artigo apresentando uma nova teoria, chamada de teoria do enquadramento. Ela se baseia nos conceitos

psicológicos que orientam a percepção nos momentos da tomada de decisão. A avaliação de probabilidades e resultados produzem mudanças previsíveis de preferência quando o mesmo problema é enquadrado de maneiras diferentes, ou seja um problema em outro referencial passa a ser analisado de forma diferente. Os autores argumentam que, devido à Teoria do Enquadramento e da Perspectiva, a Teoria Racional da Escolha não fornece uma base adequada para uma teoria descritiva da tomada de decisão.

Uma pesquisa prática utilizada por Kahneman e Tversky é sobre o dilema da epidemia. Supõe-se que 900 pessoas foram infectadas e deve-se escolher como serão salvas. Caso opte pela solução A, 300 serão salvas, enquanto na solução B, existe a probabilidade de salvar um terço das 900 pessoas. Em sua maioria, as pessoas escolheram a primeira solução.

Já em uma segunda rodada, as soluções mudam. Na solução C, a epidemia causará morte de 600 pessoas. Enquanto na solução D, a epidemia tem chance de matar dois terço e um terço se salvará. Nessa rodada, a situação se inverteu e as pessoas escolheram em sua maioria a D, visto que o objeto principal das soluções mudou. Na primeira rodada buscavam salvar as pessoas sem se expor a riscos. Enquanto na segunda, foi preferível se ater a possibilidade de salvar vidas do que escolher a morte de algumas.

2.3 Análise de Sentimento

A análise de sentimentos refere-se ao processamento de linguagem, linguística computacional e análise de texto para identificar e extrair informações subjetivas em alguma fonte de conteúdo. O sentimento do texto, na comunicação verbal ou escrita, é entendido por seu receptor como um dos atributos do discurso.

Em uma comunicação verbal, além do conteúdo transmitido, elementos como a linguagem corporal influenciam fortemente na percepção do sentimento da mensagem. Entretanto, em uma comunicação escrita se tem apenas como objeto de análise o texto.

No entanto, a interpretação desse sinal transmitido por um interlocutor pode ser interpretado através de uma opinião subjetiva na qual a considerará positiva ou negativa.

No âmbito textual, uma notícia pode ser classificada em positiva ou negativa sem ser de opinião. Por exemplo, se a notícia mencionar que “o lucro de uma empresa aumentou”. Isto é uma notícia claramente boa, mas se a notícia é sobre “a falência de uma empresa”, então é uma notícia ruim.

Neste capítulo, uma visão geral da pesquisa de análise de sentimentos será abordada, mencionando conceitos-chave, características, diferentes níveis de análise e geração de léxicos de sentimentos.

2.3.1 Principais conceitos

2.3.1.1 Detecção de polaridade e subjetividade de sentimentos

O sentimento de um texto pode ser extraído a partir de uma análise das palavras que o compõe, com o intuito de capturar um sentimento de otimismo ou pessimismo. Sua análise busca correlacionar os sentidos linguísticos das palavras, sem considerar seu significado, as estruturas das frases e o contexto

Entretanto, diversos autores têm lidado com problemas na hora de classificar os sentimentos em diferentes maneiras. Em 2012, Liu argumentou sobre os problemas enfrentados nas classificações de duas e três classes [17].

Ao utilizar a classificação de duas classes podemos visualizar dois problemas, o primeiro é por conta da objetividade do texto, em suma entender se aquele fragmento do texto expressa alguma opinião. Após esse problema de classificação subjetiva enfrentamos um problema de polaridade, que consiste na dificuldade para rotular de forma binária as sentenças como uma expressão de opinião positiva ou negativa.

Já no modelo de classificação de três classes, o fragmento do texto pode ser rotulado entre positivo, negativo ou neutro. Quando se é catalogado como neutro

pode ser devido à falta de opinião encontrada no texto ou apenas a identificação de um sentimento que se situa entre o otimista e o pessimista.

Contudo, em algumas situações esse tipo de classificação em três classes não é suficiente, visto que mais informações são demandadas para poder analisar com mais precisão. Com isso, uma metodologia usada é a escala multiponto (por exemplo, um a cinco pontos). Este tipo de classificação pode ser visualizado como um problema de categorização de texto com várias classes.

2.3.1.2 Presença de termos x frequência

Quando utilizamos a abordagem de presença dos termos estamos fazendo uma análise binária e simplesmente determinando suas ocorrências, caso sim (valor 1), caso não (valor 0). Já na abordagem de frequência, analisaremos a recorrência das palavras, analisando o número de vezes que foi utilizada. A abordagem de frequências têm sido amplamente utilizadas, porém em grande parte dos casos, o desempenho mais preciso foi obtido usando a abordagem binária.

Pode-se salientar que apesar de que se tenha maior probabilidade de um assunto se destacar devido a uma maior recorrência de palavras-chave, o sentimento geral não pode ser destacado por meio do uso repetido dos mesmos.

2.3.1.3 Partes da marcação de fala

A escrita é uma reapresentação da fala, com todas as suas características morfológicas básicas. Em português, as classes gramaticais são: substantivo, verbo, adjetivo, advérbio, pronome, preposição, composição, conjunção e interjeição.

Palavras atribuídas a mesma classe gramatical normalmente apresentam comportamento semelhante em termos de sintaxe. Pode-se salientar que classes específicas são de extrema importância para se extrair sentimento do texto. Adjetivos, por exemplo, são indicadores importantes de opinião, enquanto substantivos são indicadores fortes de sentimento.

2.3.1.4 Negação

Em meio a análise de sentimento, pode-se ressaltar a importância das palavras de negação, visto que elas invertem a polaridade da sua análise. Comparando com circuitos lógicos, elas são um NOT de sentimentos. A frase "As pessoas não devem investir na Petrobrás" tem uma grande semelhança com "As pessoas devem investir na Petrobrás" entretanto o indicador de negação muda todo o sentido fazendo com que elas apresentem sentimentos completamente opostos.

2.3.2 Níveis de análise

Em meio a análise de sentimento, pode-se ressaltar que existem três diferentes níveis de análise do sentimento textual. O sentimento pode ser baseado no documento, nas palavras ou na frase. A seguir, será apresentada uma breve descrição desses diferentes níveis de análise.

2.3.2.1 Análise de sentimentos em nível de documento

Na análise no nível do documento é realizada uma classificação para o contexto geral do texto, o classificando como um texto otimista ou pessimista. Dessa forma assume-se que o documento expressa opiniões sobre um único assunto e as opiniões são de um único autor de opinião.

Caso se tenham documentos que avaliam e comparam vários assuntos, logo se demandará um nível de análise mais robusto e aumentará consideravelmente a complexidade na classificação dos sentimentos textuais.

2.3.2.2 Análise de sentimentos em nível de sentença

A análise de sentimentos no nível da frase consegue uma maior eficiência devido a visão mais detalhada que se têm. Em complemento, as mesmas técnicas utilizadas na análise de documento podem ser aplicadas na sentença.

Este nível de análise assume que a sentença expressa uma única opinião de um único detentor de opinião. Entretanto, não se pode assumir sempre esse caso.

Existem limitações para frases de alta complexidade. Por exemplo, frases com sentimentos diferentes e com diferentes agentes, tal como " A Bovespa está se recuperando após a queda da Vale".

Outras limitações que dificultam na análise de sentimento de sentenças são:

- 1) Não poder lidar com opiniões em sentenças comparativas, como por exemplo, "A Bovespa está subindo mais que a Vale."
- 2) Frases formuladas como perguntas, como por exemplo, "O Bradesco está se saindo melhor que o Itaú? "
- 3) Frases sarcásticas, que em geral podem significar exatamente o oposto do que é o conteúdo aparente, tal como, "A Bovespa está indo tão bem!".

Ainda que as análises no nível do documento ou da frase representem uma boa abordagem, em alguns casos, eles podem não atingir o nível de detalhe necessário. Em tais casos, uma análise no nível da palavra fornece uma boa alternativa.

2.3.2.3 Análise de sentimentos em nível de entidade e palavra

As análises apresentadas anteriormente tem grande eficiência quando todo o texto ou cada frase é destinado a um único assunto. Entretanto os textos podem se referir a diferentes assuntos que podem ter muitos aspectos, e a opinião sobre cada tópico pode ser diferente. A Análise de sentimento no nível da entidade tem como objetivo descobrir sentimentos relacionados às palavras. A abordagem para analisar os sentimentos em nível das palavras é identificar todas as entidades de um corpus do texto e extrair o sentimento de todas as frases que expressem polaridades relevantes.

2.3.3 Abordagens baseadas no léxico

Um léxico de sentimentos é uma lista de palavras atribuídas com uma pontuação positiva ou negativa refletindo sua polaridade de sentimentos. Exemplos de palavras positivas são: bom, bonito, feliz e legal. Exemplos de palavras negativas são ruins, feias, infelizes, ruins e Terrível.

Uma forma de se adquirir os léxicos de sentimentos, ou seja, a lista de palavras de opinião, três principais abordagens têm sido utilizadas: abordagem manual, abordagem baseada no dicionário e abordagem baseada no corpus.

2.3.3.1 Abordagem manual

Para a utilização de Léxicos em uma abordagem manual, depende-se de pessoas para criarem as etiquetas escolhendo palavras de um dicionário. Antes das inovações tecnológicas, alguns pesquisadores foram pioneiros nesse tipo de análise de sentimento.

Em 1971, Victor Niederhoffer fez um estudo sobre a influência das notícias no comportamento dos preços no mercado financeiro [18]. Com um processo manual, ele fez a correlação das oscilações das ações com eventos mundiais utilizando notícias do New York Times, no período entre 1950 e 1966. Na sua pesquisa foram analisados apenas os títulos das notícias e diversos leitores ajudaram na categorização se o sentimento da notícia era otimista ou pessimista. Sua pesquisa concluiu que o mercado reagiu de forma intensa em meio as notícias pessimistas, oscilando de forma exagerada.

Entretanto, o estudo de Niederhoffer teve algumas limitações que restringiram uma análise mais completa. Pelo fato do processo de análise ser manual, ele teve uma limitação em relação a quantidade de amostras utilizadas, principalmente por conta da quantidade de informações que se tem entre os anos 1950 e 1966. Além desse fato supracitado, outra limitação é a interpretação subjetiva do sentimento exposto nos textos.

2.3.3.2 Abordagem baseada em dicionário

Essa abordagem exige a coleta de um pequeno conjunto de palavras de opinião manualmente com orientações conhecidas e depois acrescentar este conjunto pesquisando em um dicionário por seus sinônimos e antônimos. As palavras recém encontradas são adicionadas ao Léxico. O processo iterativo continua até quando não são encontradas mais palavras novas. Depois que o processo estiver concluído, é possível executar uma inspeção manual para remover e/ou corrigir erros.

A vantagem de usar a abordagem baseada em dicionário é a facilidade de como uma grande número de palavras de sentimentos podem ser encontradas. No entanto, um aspecto negativo, é que a análise não distinga as palavras de opinião que tenham significados diferentes em contextos diferentes. Por exemplo, caso se esteja falando “lucro”, a palavra aumento é positiva. Contudo, se a palavra for “dívida”, é negativa. A orientação do sentimento de aumento é dependente do contexto. Como a abordagem baseada em dicionário não pode capturar as peculiaridades específicas de um domínio específico, a abordagem baseada em corpus pode lidar melhor com esse problema.

2.3.3.3 Abordagem baseada em corpus

Os métodos na abordagem baseada em corpus dependem de sintática e também uma lista inicial de palavras de opinião para encontrar outras palavras de opinião em uma grande corpus (Liu e Zhang, 2012) [19].

A abordagem baseada em corpus tenta resolver o problema que a mesma palavra pode seja positivo em um contexto e negativo em outro. Um desenvolvimento importante nessa área foi o trabalho de Hatzivassilog Lo e McKeown (1997) que introduziu o conceito de consistência de sentimentos [20]. A estratégia usada é por meio de uma lista de adjetivos de opinião inicial para o conjunto de restrições ou convenções linguísticas sobre conectivos para identificar outras palavras de sentimento adjetivo e suas orientações no corpus.

Uma das restrições envolve a conjunção AND. Ele afirma que adjetivos geralmente têm a mesma orientação. Por exemplo, considere a frase, "Esta empresa é confiável e eficiente". Se confiável é conhecido por ser positivo, pode-se inferir que eficiente também é positivo. Isso ocorre porque as pessoas geralmente expressam a mesma opinião em ambas as partes de uma conjunção.

Pode-se notar que a seguinte sentença não é natural: "Esta empresa confiável e ineficiente ". Se for alterado para " Esta empresa é confiável, mas ineficaz eficiente ", torna-se aceitável.

Regras ou restrições também foram projetadas para outros conectivos, OU, MAS, OU E NEM NEM. Essa ideia é chamada de consistência de sentimento. No entanto, na prática, os termos nem sempre são consistentes. Uma etapa de aprendizado foi aplicada a um corpus grande para determinar se dois adjetivos conjugados têm a orientações iguais ou diferentes.

No entanto, como Liu e Zhang (2012) afirmaram, usar apenas a abordagem baseada em corpus e identificar todas as palavras de opinião geralmente não é tão eficaz quanto a aplicação baseada em dicionário. Principalmente pela dificuldade de abordagem na criação dos corpus enorme para cobrir todas as palavras.

2.4 Incerteza Econômica

Por um viés matemático, a incerteza econômica pode ser definida como uma impossibilidade de prever fenômenos que tem uma função de probabilidade desconhecida. Em um viés econômico, a incerteza é uma dúvida dos investidores e analistas a respeito do futuro da empresa, no qual têm grande vínculo com eventos macroeconômicos e microeconômicos, bem como eventos não econômicos, por exemplo fenômenos da natureza.

Em suma, a incerteza está relacionada a volatilidade da economia e do mercado financeiro. Em fenômenos de impacto econômico, como recessões, guerras e crises políticas são observados grandes momentos de incertezas, observados pelo comportamento do mercado e associado a quedas no desemprego e na produção.

A utilização da volatilidade de mercado como base para a incerteza tem algumas limitações, visto que a volatilidade pode mudar no decorrer do tempo sem que ocorra variação na incerteza. Diversas vezes esse movimento ocorre devido a mudanças comportamentais do mercado, onde ficam mais avessos ou dispostos ao riscos.

Por conta dessas limitações, um caminho melhor para tratar da incerteza é por meio de uma análise de mercado, utilizando por exemplo dados macroeconômicos, financeiros, setoriais e série de dados fundamentalistas sobre ativos específicos.

Outro fator que pode ser empregado para auxiliar na identificação da incerteza é analisando a frequência de palavras que a transmitem. O volume de palavras desse cunho tem relação direta com as flutuações de incerteza, visto que o impacto dela intensifica a volatilidade do mercado, e reduz o nível de atividade econômica, os retornos de mercado e consequentemente a expectativa do PIB.

Outra área que sofre influência da incerteza é a política, que por sua vez é muito relevante no Brasil. O impacto da incerteza política resulta em choques econômicos negativos, que afetam também a macroeconomia e por sua vez os preços dos ativos, as taxas de desemprego e os investimentos. Um exemplo de momento de incerteza são as épocas de eleições onde se tem possibilidade de mudança política, que causa uma maior volatilidade no mercado.

Consoante Nicholas Bloom, os impactos da incerteza nas economias de países emergentes e de países desenvolvidos são divergentes entre si, na qual os emergentes apresentam 34% a mais de incerteza que os desenvolvidos [21]. Essa maior incerteza é devido a características marcantes nos emergentes, tais como: existência de uma economia menos diversificada, o que aumenta a exposição às flutuações de preços e desenvolvimento; produtos principais das economias geralmente são commodities, que por sua vez são cíclicos e voláteis; forte presença de instabilidade política, assim como foi comentado anteriormente; e por fim, política fiscal e monetária menos incisivas.

Devido às fragilidades dos países emergentes, as chances de eventos altamente improváveis, também conhecidos como Cisnes Negros, ocorrem aumentam e seus impactos nos ativos se intensificam.

2.5 Cisnes Negros

Antes de 1697, professores ensinavam às crianças europeias que todos os cisnes eram branco. Eles tinham poucas razões para pensar o contrário, já que todos os cisnes já examinados tinham a mesma plumagem branca. Entretanto o explorador holandês Willem de Vlamingh desembarcou na Austrália.

Entre as muitas criaturas improváveis, Vlamingh encontrou Cisnes negros. Com isso, o conceito de que só existiam Cisnes brancos foi descontinuado, e após um tempo passou a ser comum a existência de Cisnes negros.

O fato de não ter presenciado um evento não, significa que ele não exista ou passe a existir. Nassim Taleb nomeou esses ocorridos de Cisnes Negros. Eventos improváveis que parecem impossíveis quando se encontram no desconhecido ou no futuro. Todavia, depois de ocorrerem, as pessoas os assimilam em sua concepção, e o extraordinário se torna comum. Além disso, têm características de serem extremamente disruptivos. Por exemplo, ocorridos como as 1ª e 2ª Guerras Mundiais, os ataques terroristas de 11 de setembro, o surgimento da bolha da Internet nos anos 90, ou invenções que mudam o mundo, como o motor de combustão interna, o computador pessoal e a Internet.

Esses eventos e invenções surgiram de forma repentina, porém em retrospectiva ao analisarem pareciam inevitáveis. A mente humana busca simplificar grande quantidade crescente de dados que recebem diariamente. Simplificações, esquemas mentais e heurísticas, são recursos úteis que permitem as pessoas se concentrarem em suas rotinas e não fiquem sobrecarregadas por uma quantidade infinita de dados. Todavia essas simplificações não são isentas de "custos".

2.5.1 Falácia Narrativa

Um exemplo para exemplificar esse conceito é a história de um empresário extremamente bem sucedido que teve um humilde começo. Segundo Taleb, escritor do livro Cisne Negro, considera-se a hipótese de que ele teve sorte por estar na empresa certa em um momento de alto crescimento econômico. Todavia, sua trajetória é repassada para as pessoas com grande admiração criando-se fábula sobre o quão brilhante o empresário era.

A sorte é subestimada na vida, embora ironicamente seja superestimada em certos jogos de "azar". Até o próprio empresário é vítima de um pensamento imperfeito através do viés de amostragem, acreditando que se ele pode qualquer um pode.

Todavia, não se pode afirmar que todo sucesso é sorte, visto que a habilidade é importante em diversas profissões. No caso do empresário, tiveram outras pessoas que começaram como ele e tinham os mesmos atributos, mas que não atingiram o mesmo sucesso. O "fracasso" dos mesmos esconde a evidência que minaria o "sucesso" do empresário.

Os fatores psicológicos que a mente ao simplificar essas situações podem levar a erros. Por exemplo, após indivíduos criarem teorias, eles buscam prová-las por meio de evidências. Eles caem vítima de “arrogância epistêmica”, tornando-se excessivamente confiante sobre suas ideias e falhando em conta para aleatoriedade. Para fazer suas teorias funcionarem, suavizam os saltos de uma sequência histórica, procurando e encontrando padrões que não existem. Suas categorias conceituais limitam o que veem, com objetivo de ver de acordo com seus objetivos; isso é chamado de "tunelamento". Por fim, as pessoas deixam de considerar os "cisnes negros", o eventos raros altamente consequentes e aleatórios.

2.5.2 "Mediocristão" ou "Extremistão"

Em sua tese Taleb, apresenta o conceito de "Mediocristão" e "Extremistão". São metáforas para duas classes totalmente diferentes de fenômenos naturais. Mediocristão refere-se a fenômenos que se poderia descrever com conceitos estatísticos padrão, como a distribuição Gaussiana, conhecida como “curva de sino”. O Extremistão refere-se a fenômenos em que um único evento ou pessoa que distorce a curva pode distorcer radicalmente a distribuição. Imagine citar Bill Gates em uma comparação de renda executiva.

Para entender a diferença, é só pensar na altura humana versus venda de ingressos de cinema. Enquanto uma amostra de seres humanos pode conter pessoas muito altas e algumas pessoas muito baixas, não se encontra alguém com 10 metros ou 10 centímetros de altura.

Agora considerando a venda de ingressos de cinema. Um filme de sucesso pode ter vendas que excedem o valor médio por uma extensão tão radical que modelar a amostra com uma curva gaussiana é enganosa, tornando assim sem sentido a noção de "valor mediano".

Muitos modelos financeiros na teoria financeira neoclássica são baseados na premissa de que as mudanças nos retornos das ações são normalmente distribuídas em torno da média na bem conhecida curva de sino.

Uma distribuição normal é uma ferramenta analítica poderosa, porque é possível especificar a distribuição com apenas duas variáveis, a média e a raiz quadrada da variância. Contudo, esses modelos são negligentes na captura de "caudas gordas": alterações de preço pouco frequentes, mas muito grandes.

Caudas gordas estão intimamente relacionados às leis de energia, um vínculo matemático entre duas variáveis que são caracterizada por pequenos eventos frequentes e grandes eventos pouco frequentes. Isto é o resultado da combinação do risco de curtose e o risco associado à assimetria. O total dos retornos podem ser dominados por eventos extremos (curtose), que são inclinados para o lado negativo.

Essas distribuições de cauda gorda apresentam vários problemas fundamentais de gerenciamento de riscos.

Estes problemas incluem:

- (1) a presença de eventos adversos extremos;
- (2) alguns fatores aleatórios não observados;
- (3) expectativas difíceis de calcular;

Pressupostos de distribuições normais de retorno das ações são os pilares dos modelos de finanças, incluindo a moderna teoria do portfólio (critério de variação média), a precificação de ativos de capital, o Value-at Risk (VaR) e os modelos Black-Scholes. O colapso da bolsa de 1987 foi tão improvável (segunda-feira negra foi um evento cisne negro), dados os modelos estatísticos padrão usados finanças, que questionou toda a base dos modelos financeiros neoclássicos. Ele foi o que levou a analisarem e concluírem que existem alguns eventos recorrentes, que superam as premissas estatísticas incorporadas nos modelos financeiros padrão empregados para negociação, gestão de investimentos e precificação de derivativos. Nessas estatísticas, as anomalias pareciam afetar muitos mercados

financeiros de uma só vez, incluindo os que normalmente não eram de se pensar estarem correlacionados. Esses eventos raros conhecidos como "Cisnes Negros" que por definição, não têm a perspectiva histórica necessária para realizar análises de risco e matemáticas para estimá-los.


Capítulo 3

Metodologia

O objetivo deste capítulo é fornecer uma visão geral das etapas adotadas no início do estudo até sua conclusão. Conforme descrito anteriormente no capítulo 1, o escopo do trabalho realizado é dividido em três etapas distintas:

- Escolha dos ativos, e coleta dos dados financeiros e notícias;
- Pré-processamento das notícias e modelagem estatística;
- Análise de sentimento nos dias de outliers e análise da sua correlação com os setores.

Figura 1 – Desenho da Pesquisa



Fonte: Elaborado pelo autor

A Figura fornece uma visão geral da arquitetura do sistema desenvolvido, indicando claramente cada uma das três fases. Cada uma fornece visão abrangente da metodologia empregada nessa fase do estudo e suas interações. O objetivo final é que ocorram a fim de entregar o resultado final: a quantificação de qualquer relação potencial que exista entre sentimentos expressos em mídia formal e retornos de mercado.

3.1 Aquisição dos dados

Após a escolha dos ativos que foram analisados, os dados coletados para este estudo podem ser claramente divididos em duas categorias: série histórica dos dados financeiro e notícias de mercado financeiro. Esta seção oferece uma visão geral das motivações da escolha desses ativos e das técnicas usadas para adquirir seus dados. É dividido em três subseções para refletir as diferentes abordagens adotadas para cada categoria.

3.1.1 Ativos

Nessa pesquisa seis ativos foram utilizados para analisar a influência do sentimento de mercado em suas flutuações. Esses ativos são: Bovespa, Petrobrás, Vale, AmBev, Magazine Luiza e Itaú. A ideia de se ter um índice e cinco empresas é para entender como os sentimentos impactam nos diferentes setores da economia e as reações deles em relação a determinados tópicos. Além disso, são ativos com grande participação na Bovespa, que podem ser vistos na figura 2, o que torna suas movimentações de mercado importantes para a economia brasileira.

Figura 2 – Participação dos ativos na Bovespa

Código	Ação	Tipo	Qtde. Teórica (I)	Part. (%) (Z) *
ITUB4	ITAUUNIBANCO	PN ED N1	4.738.562,684	8,573
VALE3	VALE	ON EJ NM	3.158.277,584	8,189
BBDC4	BRADESCO	PN EJ N1	3.873.597,664	6,986
PETR4	PETROBRAS	PN EJ N2	4.520.185,835	6,618
B3SA3	B3	ON EDJ NM	2.047.569,597	4,313
PETR3	PETROBRAS	ON N2	2.731.490,625	4,201
ABEV3	AMBEV S/A	ON EJ	4.348.260,598	3,958
BBAS3	BRASIL	ON NM	1.418.466,803	3,663
ITSA4	ITAUSA	PN N1	4.494.029,326	3,055
LREN3	LOJAS RENNER	ON EJ NM	781.384,541	2,145
JBSS3	JBS	ON NM	1.620.646,499	2,140
BBDC3	BRADESCO	ON EJ N1	1.091.983,694	1,831
IRBR3	IRBBRASIL RE	ON NM	931.245,594	1,772
CNDI3	INTERMEDICA	ON NM	458.380,483	1,609
MGLU3	MAGAZ LUIZA	ON EJ NM	661.834,080	1,556
SUZB3	SUZANO S.A.	ON NM	725.859,318	1,419
BRFS3	BRF SA	ON NM	811.416,229	1,402
UGPA3	ULTRAPAR	ON NM	1.085.159,631	1,320
RENT3	LOCALIZA	ON EB NM	560.843,706	1,319
RAIL3	RUMO S.A.	ON ATZ NM	1.053.753,059	1,299
WEGE3	WEG	ON EJ NM	740.696,136	1,239

Fonte: Bovespa

3.1.1.1 Ibovespa

O Ibovespa é o principal índice brasileiro que reúne as empresas que têm suas ações negociadas na B3. Ele foi criado em 1968 e é considerado uma referência para índices no mundo.

O índice é composto por uma carteira teórica composta pelas ações e units da B3, que é criada a cada quadrimestre. Sendo formado pelos papéis de maior relevância no Brasil, que correspondem a cerca de 80% dos números de negócios

e do volume financeiro do mercado de capitais brasileiro. Ele é calculado pelo preço de todos os ativos do mercado que compõe o seu portfólio.

Pela sua importância no cenário brasileiro, em sua composição não há ativos de companhias em recuperação judicial. Além disso, são excluídas ações em regime especial de administração temporária ou intervenção.

3.1.1.2 Petrobras

A Petrobras é uma das principais empresas brasileiras que atua em diversos setores, tais como: exploração de petróleo, gás natural e energia. Ela foi fundada em 1953 pelo presidente Getúlio Vargas e é uma empresa estatal de economia mista, ou seja, ela é uma empresa de capital aberto que tem como acionista majoritário o Governo Brasileiro. Atualmente, por conta dos casos de corrupção e lavagem de dinheiro que foi envolvida, ela está em um momento de reestruturação e buscando ser uma empresa cada vez mais transparente e com governança corporativa forte.

O ativo utilizado em sua análise foi o PETR4, que são suas ações ordinárias. O motivo da escolha desse ativo é devido a sua importância no mercado de capitais nacional, visto que tem uma grande participação na Bovespa. Além disso, a PETR4 é o ativo que tem maior volume médio diário nos últimos 10 anos, segundo estudo da Econométrica de 2018.

O setor que abrange a Petrobras é o setor de petróleo. O petróleo por ser uma fonte de energia primária e de baixa substituíbilidade se coloca como fonte fundamental para a economia de todos os países. Apesar da difícil substituição do petróleo, por ser uma commodity, seu preço é extremamente volátil. Principalmente devido a fatores de riscos e incertezas globais, o que o torna difícil de se projetar ao longo prazo.

3.1.1.3 Vale

A Vale é uma empresa multinacional brasileira líder na produção de minério de ferro, pelotas e níquel. Além da mineração, ela também é umas das principais operadoras de logística do Brasil, e atua no setor siderúrgico e de energia elétrica, onde participa de consórcios e tem licitações de 9 hidrelétricas no Brasil, no Canadá e na Indonésia.

Atualmente, a Vale só tem ações ordinárias listadas na bolsa (VALE3). Com o objetivo de melhorar na governança corporativa, essa mudança ocorreu em 2017, já que antes ela também tinha ações preferenciais. Assim como a Petrobras, a Vale é uma das empresas mais negociadas na bolsa de valores, o que lhe confere uma liquidez enorme, permitindo fácil transação dos seus ativos.

Apesar de estar presente em diversos setores, suas atividades principais são relacionadas ao setor de mineração. Da mesma forma que a Petrobras, o principal produto da Vale (minério de ferro) é uma commodity, que sofre com a volatilidade. Fatores que impactam fortemente o setor são: As taxas de juros internacionais, flutuações cambiais, dependência do crescimento mundial e fatores políticos que podem influenciar a oferta.

3.1.1.4 Ambev

A Ambev é uma das empresas da cervejaria multinacional Anheuser-Busch InBev. Seu nascimento em 1999 foi marcado pela fusão das empresas Brahma e Antarctica. Hoje em dia a marca já detêm mais de 100 rótulos. O segredo do seu sucesso é a 3G capital, uma empresa forte e capacitada que está por trás da gestão da Ambev, incorporando uma cultura agressiva.

Apesar de ser a maior cervejaria da América Latina, o setor de bebidas impacta seus resultados em partes. Empresas desse setor para manter um crescimento constante necessitam cada vez mais de entrada de novos clientes para manutenção da melhoria das suas receitas. A empresa vive em constante busca de expansão e aquisição de novas marcas. Exemplo disso, é a recente aquisição do fabricante de sucos Do Bem, onde pode expandir sua atuação para um mercado de alimentação saudável.

O ativo da Ambev que será utilizado na tese será o ABEV3. Apesar de encarar cenário político e econômico adverso, sua ação permanece crescendo. Muito por conta das especialidade em logística, alta geração de caixa e constante lucratividade. Fatores esse que a fazem uma boa pagadora de dividendos.

3.1.1.5 Itaú

Itaú foi fundado em 1945, e é o maior banco brasileiro. Ele atingiu essa marca muito por conta da fusão entre o banco Itaú e o Unibanco em 2008. Além de atuar no setor bancário, ele está presente em outras áreas, por meio de empresas do grupo. A Rede, segunda maior adquirente de cartão, e a Porto Seguro, maior seguradora de veículos do Brasil.

A ação utilizada será a ordinária, ITUB3, por conta da sua governança corporativa mais forte. Ela consegue se destacar em meio as concorrentes principalmente pela sua alta rentabilidade e pelas inovações tecnológicas que estão constantemente buscando. Outro ponto positivo ao investir nas ações do Itaú são os altos dividendos que geralmente são pagos.

O setor bancário por sua vez está cada vez mais competitivo, principalmente pela entrada e crescimento de novos players, startups e instituições independentes. Entretanto, o Credit Suisse, um banco de investimento suíço, tem um panorama positivo para o setor bancário tradicional, principalmente devido a redução dos custos que os grandes players vem realizando por meio do investimento em tecnologia.

3.1.1.6 Magazine Luíza

A Magazine Luíza é uma varejista fundada em 1957 em São Paulo. Com foco inicial em venda de presentes, ela teve um crescimento exponencial, principalmente após os anos 2000, onde expandiu seu modelo de negócios para lojas de departamentos. A empresa é referência em transformação digital no varejo, onde investe cada vez mais em inovação tecnológica e posicionamento de

marketing para se firmar no mercado. Com uma cultura forte, está na terceira geração de herdeiros em seu comando.

A ação utilizada foi a MGLU3. Em 2011 foi realizado seu IPO e conseguiu uma captação de R\$ 925 milhões, a segunda maior do ano. O ativo conseguiu se destacar bastante devido ao seu crescimento rápido. Pode-se destacar que entre 2016 e 2019, sua ação cresceu 18.000%, alcançando um novo patamar na B3 entre as maiores altas.

Apesar do alto crescimento da Magazine Luiza, o setor em que está inserida não é fácil. Marcado pelas baixas margens de lucro, volatilidade do mercado e mudanças constantes por conta de demanda de clientes, o setor varejista brasileiro é um ambiente bem desafiador. Entretanto, fatores como juros baixos e crédito facilitado auxiliam o crescimento. Além disso, as inovações tecnológicas ajudaram a empresa a diminuir a concentração de mercado e a expandir seu mercado consumidor.

3.1.2 Dados Financeiros

Para coletar os dados financeiros desses ativos buscou-se bibliotecas que fazem a extração automática dos preços diários e volume de operações, e foi encontrada a biblioteca `ffn`.

A biblioteca `ffn` tem diversas funções aplicadas para quem trabalha com finanças quantitativas. Ela interage com outras grandes bibliotecas, como `Panda` e `Numpy`, e permite ferramentas interessantes, desde cálculo dos retornos logaritmos até gráficos e transformações de dados.

Para utilizar o `ffn` é necessário instalá-lo pelo Python Package Index utilizando `pip`: `$ pip install ffn`. Pelo fato do `ffn` ter dependência de outras bibliotecas, a utilização do `Anaconda`, distribuição do Python, agiliza por já ter pacotes pré instalados.

Os dados Financeiros coletados pela `ffn` vem da Yahoo! Finance, que é uma fonte confiável de informação. Ele faz parte do grande grupo de mídia Yahoo! e fornece notícia e dados financeiros, incluindo cotações, press releases e relatórios

financeiros. Ele também tem algumas funcionalidades online para gestão de finanças pessoais.

Por fim, a série histórica de preço e volume de cada ativo escolhido foi de 01 de janeiro de 2013 até 16 de agosto de 2019. O período escolhido foi com base no período em que se foram coletadas as notícias.

3.1.3 Coleta das notícias

Com o intuito de facilitar a extração de emoções e opiniões expressas em relação ao mercado financeiro de publicações na mídia, foi necessário construir um corpus de notícias relacionadas ao mercado. O estudo se concentra especificamente nas notícias publicadas por fontes formais de mídia, tornando necessária a identificação de um conjunto de fontes de amostra apropriada.

Uma infinidade de notícias existe de diversas fontes, entretanto, nem todas tem relação com o mercado financeiro, o que ao incluí-las dificultaria a precisão da análise. Portanto, cuidadosas considerações foram feitas para garantir que a amostra selecionada servisse como uma representação da mídia formal disponível nesse mercado. Dada a ampla variedade e diversidade das fontes selecionadas, o estudo optou por usar o Valor Econômico e Folha de São Paulo para obter o grande volume de notícias.

A metodologia utilizada para fazer a coleta das notícias foi utilizando Selenium. Essa ferramenta permite que um script controle um navegador realizando todas as atividades que uma pessoa faz no teclado e no mouse. Tudo o que se pode fazer manualmente, passa a ser possível através da programação. Em atividades repetitivas se tem uma grande necessidade dessa ferramenta, visto que economiza muito tempo e elimina os erros de operação. O Selenium apresenta tamanha flexibilidade que você pode utilizá-lo tanto no formato de extensão do navegador, Selenium IDE, quanto no formato de biblioteca para linguagens de programação, o Selenium WebDriver.


O Selenium IDE é uma extensão que pode ser utilizada nos navegadores Chrome e Firefox e possibilita a criação de automações rápidas. Por meio de uma

interface gráfica, e sem necessidade de programar nenhum código para se criar as rotinas. Além do mais, tem como gravar os seus comandos de teclado e mouse para que possam ser reproduzidos depois automaticamente.

Outra funcionalidade dele é a opção de depuração que ajuda na execução das rotinas e a encontrar possíveis erros. Por fim, é uma ferramenta de fácil utilização com foco em atividades rápidas e de baixa complexidade.

Um exemplo de teste no Selenium IDE pode ser visto na figura 3. Neste teste, ele abre o Google automaticamente, digita “Análise de sentimento” e pressiona o botão “Enter” para pesquisar.

Figura 3 – Selenium IDE



Fonte: Elaborado pelo autor

Ademais, o Selenium WebDriver é uma API (Application Programming Interface) que pode ser utilizada em para várias linguagens de programação, tais como Visual Basic for Applications (VBA), Java, C#, Ruby, Python, JavaScript, e outras mais. Ele permite que sejam criadas interações automatizadas com o front-end das páginas web.

Um ponto de grande importância na ferramenta é a compatibilidade que ela tem com vários navegadores diferentes, garantindo a aplicabilidade do sistema em diversos ambientes. Portanto, é possível melhorar ainda mais a qualidade do programa e a portabilidade do código.

Os programas criados para esse trabalho foram desenvolvidos com a linguagem Visual Basic for Applications e utilizando o navegador Google Chrome. O programa desenvolvido tem a capacidade de controlar o navegador, e simular todas as interações do usuário com a tela.

Para interagir com os elementos de um site, deve-se passar o id, nome, class, css ou xpath da estrutura. Deste modo, quanto mais o código seguir boas práticas de programação, melhor será para fazer a automação. Outro ponto relevante a ser observado é que o WebDriver possibilita que se assista a automação.

A lógica utilizada para se executar as extrações das notícias foi diferente em cada fonte. No site da Folha de São Paulo, tem uma aba que mostra as notícias mais recentes, por meio dele é possível ver notícias mais antigas o que facilita a coleta das mesmas por meio de um loop de interação.

A estrutura do site da Folha apresenta que todas as notícias tem o elemento class “c-headline_title”. Essa class é a marcação de que está começando uma notícia e por isso o loop será baseado nela. Dentro de cada notícia tem uma estrutura com os dados que se têm como objetivo extrair, tais como:

- Data – Tag = “time”
- Título – class = “c-headline__title”
- Descrição – class = “c-headline__standfirst”
- Link – class = “c-headline__content”
- Categoria – class = “c-headline__kicker”

A partir disso, foram feitos dois loops, um com a finalidade de pegar todas as notícias de uma página e outro para trocar de página. Com isso conseguiu-se extrair 187.827 notícias do site Folha de São Paulo.

Já no site do Valor tem uma aba que mostra todas as notícias que foram circuladas no jornal físico, e é possível ver essa funcionalidade para notícias passadas. Portanto, foi executado um loop que extraiu 125.390 notícias.

Outras fontes de notícias confiáveis, tais como Estadão, Globo e Infomoney, não apresentam essa possibilidade de visualizar notícias antigas em seus respectivos sites. Esse fator limitante reforçou a escolha das fontes utilizadas.

3.2 Modelagem Estatística

Nesse capítulo algumas metodologias de análises estatísticas serão apresentadas como base para a presente pesquisa.

Primeiramente, é necessário apresentar um dos principais trade-offs que existe no mercado financeiro: risco e retorno. Sua premissa é que a busca por maiores retornos tem como contrapartida, estar disposto a correr mais risco em sua tomada de decisão na área de investimentos. Vale ressaltar que o entendimento do risco e retorno é essencial para o processo de aprimoramento na gestão financeira e de investimentos.

Por fim, foi realizada uma análise descritiva das notícias, para se entender suas relações com os setores e como as notícias se comportam.

3.2.1 Retorno

Por definição, a taxa de retorno é o ganho financeiro que se tem entre o excedente do valor final obtido em um investimento em relação ao valor inicialmente aplicado, levando em conta qualquer valor aportado ou resgatada ao longo da aplicação. A expressão da taxa de retorno financeiro pode ser apresentada por meio da seguinte equação:

$$Taxa\ de\ Retorno\ (\%) = \frac{Receita}{Valor\ aplicado} \times 100 \quad (1)$$

Existem outras formas de apresentar esse indicador, porém elas serão apenas variações da equação apresentada, sempre seguindo a mesma lógica de raciocínio. Essa métrica é bastante utilizada pelo mercado financeiro para cálculo da taxa de retorno financeiro e é conhecida como ROI (Return on Investment).

No mercado financeiro tem outras formas de se calcular o retorno, as mais utilizadas no cotidiano são o retorno linear ou o retorno logaritmo. O retorno linear é mais utilizado pelo mercado principalmente pela sua facilidade, por exemplo quando se fala que uma ação caiu 10% é por meio desse cálculo. Sua equação consiste basicamente na diferença do preço final e inicial do ativo dividido pelo preço inicial.

$$Retorno\ Linear = \frac{Preço_{Final} - Preço_{Inicial}}{Preço_{Inicial}} \quad (2)$$

O cálculo do retorno pode ser utilizado para diferentes tempos, como diário, mensal, trimestral ou anual. A única diferença em relação à equação é substituir o tempo inicial e final mudando assim sua periodicidade para o tempo desejado.

Por outro lado, temos o retorno logaritmo que é uma forma de "normalizar" a distribuição dos retornos. Particularmente os retornos diários dos investimentos financeiros de renda variável. No cálculo do retorno linear utilizando seus limites máximos e mínimos observa-se que seu retorno mínimo é -100% e o máximo é infinito. Esse fator faz com que alguns retornos positivos “pesem” mais em alguns modelos econométricos e regressões. Com isso, o retorno logaritmo busca equilibrar esses pesos.

Além disso, o retorno linear tem umas inconsistências. Por exemplo, se uma ação cai 50% e depois sobe 50%, ao fazer um somatório dos retornos teríamos uma variação 0. Entretanto, isso não é verdade, visto que o retorno linear acumulado é calculado a partir do seu produtório.

$$Retorno\ Acumulado = (1 + Retorno_{Dia\ 1}) * (1 + Retorno_{Dia\ 2}) - 1 =$$

$$Retorno\ Acumulado = (1 + 50\%) * (1 - 50\%) - 1 = -25\%$$

$$Retorno\ Acumulado = \left(\prod_{Dia=1}^N (1 + Retorno_{Dia}) \right) - 1 \quad (3)$$

Enquanto, o retorno logaritmo acumulado é calculado a partir do somatório do logaritmo, o que auxilia no desenvolvimento dessa tese. Essa flexibilidade de escolher entre os dois é devido a seus retornos acumulados serem aproximadamente iguais.

Por fim, após extração de todos os dados históricos de preços, foi criada uma série temporal de retorno logaritmo para cada ativo. O Retorno será usado como principal variável para modelagem estatística ao invés do preço devido a maior facilidade para entender as flutuações dos ativos.

3.2.2 Risco

O risco pode ser definido como a possibilidade de se obter ganhos ou perdas financeiras. Ativos mais arriscados tem comportamentos mais oscilatórios, onde é possível se ter maior potencial, tanto de lucros, quanto prejuízos. Assim, como se falou no primeiro capítulo do presente trabalho a incerteza econômica é a responsável por provocar maiores variações nos retornos de um ativo.

As formas de quantificar esses riscos são diversas e podem ser utilizadas de várias formas. As modelagens estatísticas que auxiliam na métrica desses riscos, dentre os mais conhecidos pode-se ressaltar Desvio-padrão, Coeficiente de variação, Covariância, Correlação e Volatilidade. Dentro dessas métricas de risco algumas estimam o risco de apenas um ativo enquanto outras estimam de dois ou mais.

3.2.2.1 Desvio-padrão

Por definição, o desvio-padrão pode ser calculado pela raiz quadrada da variância. É um indicador muito importante dentro do mercado financeiro. Em

suma, o desvio padrão quantifica a variação dos preços de um ativo em relação a sua média.

Como por exemplo, um ativo com retorno de 4% ao mês e desvio padrão de 1% significa que ele normalmente oscilará entre 3% e 5%. O desvio padrão é apresentado na mesma unidade de medida da média, o que ajuda na análise do impacto em seu retorno.

$$\sigma_R = \sqrt{\frac{\sum_{Dia=1}^N (R_{Dia} - \bar{R})^2}{N - 1}} \quad (4)$$

R_{Dia} : retornos do ativo sendo analisado;

$\bar{R}$: média dos retornos;

Dia : tempo da amostra, que pode ser um dia, uma semana, um mês ou um ano, por exemplo.

3.2.2.2 Coeficiente de Variação

O coeficiente de variação é um modelo de mensuração de risco em relação ao retorno. O que permite comparar o risco de diferentes ativos. Sua equação pode ser demonstrada da seguinte forma:

$$CV = \frac{\sigma_R}{\bar{R}} \quad (5)$$

σ_R : desvio-padrão dos retornos do ativo

$\bar{R}$: média dos retornos

3.2.2.3 Volatilidade

Pode-se definir volatilidade ao quanto um ativo tende a oscilar ao longo do tempo. Uma certa confusão com o desvio padrão pode ser gerada principalmente por conta das semelhanças das suas definições. Em algumas situações o desvio

padrão dos retornos lineares ou logaritmos é utilizado como medida de volatilidade.

Entretanto, existe cálculos mais complexos para volatilidade, principalmente em modelos econométricos. Modelos como ARCH e GARCH que levam em conta a variância condicional e buscam resolver problemas heteroscedasticidade para encontrar, por fim, a volatilidade.

No presente trabalho, o desvio padrão foi considerado como uma medida satisfatória de volatilidade. Principalmente pelo fato de não se trabalhar com modelos econométricos complexos.

3.2.2.4 Covariância

A covariância analisa estatisticamente a variação de dois ativos em conjunto. Ela é equivalente à variância, entretanto, ela realiza o produto dos desvios dos retornos de ambos ativos, ao invés de considerar o quadrado dos desvios dos próprios retornos. A equação da covariância dos retornos dos ativos A e B pode ser representada na seguinte forma:

$$cov(A, B) = \frac{1}{N} \sum_{Dia=1}^N (A_{Dia} - \bar{A})(B_{Dia} - \bar{B}) \quad (6)$$

A_{Dia} e B_{Dia} : Retorno dos ativos

$\bar{A}$ e $\bar{B}$: Médias dos retornos dos dois ativos

Para a variância de um único ativo ao se calcular sua raiz quadrada encontra-se o desvio-padrão, que será um resultado na mesma unidade da média dos retornos do ativo. Todavia, na covariância de dois ativos financeiros não se tem sentido calcular sua raiz quadrada, o que aparentemente seria uma saída para encontrar o "desvio-padrão" de dois ativos.

Por exemplo, ao extrair a covariância entre os retornos do IBOVESPA e de uma ação, não tem sentido querer chegar a uma unidade única que represente a variação dos retornos de duas variáveis. Logo, pode-se dizer que ela não é uma

métrica de risco relativo. Por conta disso, a medida mais utilizada para entender as oscilações de dois ativos ao longo do tempo é a correlação.

3.2.2.5 Coeficiente de correlação

O coeficiente de correlação é uma métrica muito utilizada no mercado financeiro para se relacionar dois ativos. Quando se obtém a correlação de dois ativos, refere-se a extração de um coeficiente de risco mútuo de forma padronizada. Uma das maneiras de se calcular a correlação é por meio do coeficiente de correlação de Pearson:

$$\rho_{A,B} = \frac{cov(A, B)}{\sqrt{var(A) \times var(B)}} \quad (7)$$

O resultado obtido pelo cálculo é limitado entre -1 e +1, onde pode-se analisar que:

- $\rho_{A,B} = -1$: Correlação perfeita negativa;
- $\rho_{A,B} = 0$: não há correlação;
- $\rho_{A,B} = +1$: correlação perfeita positiva;

3.2.3 Outliers

Em um grande grupo de amostras, é corriqueiro que se encontrem variáveis discrepantes com valores extraordinariamente grandes ou pequenas em comparação com os outros conjuntos de dados. Eles são chamados de outliers ou cisnes negros e serão os objetos de estudo no presente trabalho.

Não se tem uma forma precisa para identificar os outliers, até porque alguns podem ser casos de corrupção dos dados e erros de medição ou entrada. Portanto, o ideal é por meio de análises estatísticas, estudar os dados brutos, avaliar a origem dos valores extremos e por fim classificá-los entre outliers ou não.

Eles podem ser classificados entre dois grupos, outliers univariados ou multivariado. O que marca essa distinção entre os grupos é que o primeiro grupo tem como característica um banco de dados com distribuição de uma variável simples, como por exemplo, a distribuição de alturas. Já no multivariado se tem um espaço “n-dimensional”, onde para analisá-lo é necessário recorrer à distribuições multidimensionais.

O efeito encontrado em uma amostra de dados pode ser visualizado por meio de análises estáticas. As métricas mais sensíveis são a média, desvio padrão e regressão linear.

Portanto, formas de se detectá-los são muito importantes para identificar com precisão quem são os outliers e entender suas origens. As mais utilizadas são o método de desvio padrão e método do intervalo interquartil.

No método do desvio padrão, ao termos uma distribuição de dados que formam uma gaussiana ou semelhante a ela, pode-se usar o desvio padrão como ponto de corte para encontrar os outliers. A distribuição gaussiana possui a propriedade de que o desvio padrão da média pode ser usado para cobrir de forma confiável a porcentagem de valores na amostra.

Dentro de um desvio padrão da média, por exemplo, se consegue cobrir 68% dos dados. Essa amostra pode ser aumentada caso sejam acrescentados mais desvio padrões, expandindo dessa forma o intervalo da sua base. Considerando 2 desvios padrões da média alcançamos 95% da base e com 3 desvios padrões da média alcançamos 99,7%.

Três desvios-padrão da média é um ponto de corte comum na prática para identificar valores extremos em uma distribuição gaussiana ou do tipo gaussiana. Todavia, não é uma regra, visto que para amostras menores de dados, pode ser utilizado um valor de 2 desvios padrão (95%) e, para amostras maiores, talvez um valor de 4 desvios padrão (99,9%).

Essa técnica pode ser utilizada tanto em dados univariados com uma distribuição gaussiana. Quanto em dados multivariados, por exemplo, cada variável com sua distribuição gaussiana diferente.


Com duas variáveis se teriam limites em duas dimensões que definiriam uma elipse, e as amostras que caíssem fora da elipse seriam consideradas outliers. Já com três variáveis, se teria um elipsoide e assim por diante em dimensões superiores.

Entretanto, nem todos os dados são normais o suficiente para tratá-los como extraídos de uma distribuição gaussiana. Com isso, para se extrair outliers de um conjunto não gaussiano de distribuição é utilizado o Método do Intervalo Interquartil.

O Intervalo Interquartil é calculado como a diferença entre os percentis 75 e 25 dos dados. Os percentis são calculados ordenando os dados e selecionando valores em índices específicos. O percentil 50 é o valor intermediário ou a média dos dois valores intermediários para um número par de exemplos. Por exemplo, em um caso de 1.000 amostras, o percentil 50 seria a média dos valores 500 e 501.

Os percentis são chamados de quartis, devido aos dados serem divididos em quatro grupos pelos valores 25, 50 e 75. O método pode ser usado para identificar discrepantes, definindo limites nos valores da amostra que são um fator k do IQR abaixo do percentil 25 ou acima do percentil 75. O valor comum para o fator k é o valor 1,5. Um fator k de 3 ou mais pode ser usado para identificar valores extremos, quando descritos no contexto de gráficos de caixa e bigode.

Figura 4 - Quartil



Fonte: Elaborado pelo autor

Em um gráfico de caixa e bigode, esses limites são traçados como cercas nos bigodes (ou nas linhas) desenhadas na caixa. Os valores que ficam fora são desenhados como pontos.

3.3 Análise de Sentimento das Notícias

Após todas as etapas iniciais de coleta e modelagem financeira e estatísticas foi realizada a análise de sentimentos. Esse sub capítulo fornece uma visão geral das etapas realizadas pra fazer a extração da polaridade, e é dividido em três subseções que apresentam as diferentes abordagens utilizadas: Pré processamento das notícias, Léxicos e Algoritmo.

3.3.1 Pré processamento das notícias

Essa etapa é primordial para a análise textual, principalmente devido ao fato de que corpus textuais não estruturados tem muito ruído de informação. Por conta desse fato, é necessário um pré processamento para que se possa limpar a base de dados, prepará-los para a próxima etapa e com isso alcançar bons resultados. As técnicas utilizadas no pré processamento foram:

3.3.1.1 Filtro de notícias irrelevantes

Como o propósito principal da tese é relacionar notícias do mercado financeiro com o comportamento dos ativos, é necessário filtrar notícias que não tem relação com o objetivo principal.

O Valor Econômico é um jornal específico de economia, o que facilitou a análise dessa fonte, entretanto tinham algumas manchetes relacionadas a veículos, programas culturais e movimentos falimentares que foram retiradas para não poluir as análises.

Já no Folha de São Paulo por ser um jornal bem abrangente e teve-se um maior ruído de notícias fora do escopo da pesquisa, tópicos tais como: culinária, veículos, futebol, programas culturais e propagandas.

3.3.1.2 Conversão para minúsculo

A análise de sentimentos do banco de dados é case sensitive, portanto precisa fazer-se necessário o “nivelamento” dos termos utilizados. Para acabar com as inconsistências entre maiúsculo e minúsculo, todas as palavras foram convertidas para minúsculo, o que as torna compatíveis com os léxicos usados na classificação.

Como essa tarefa não afeta o significado das palavras, se não fosse realizada, algumas palavras não seriam consideradas mesma palavra (por exemplo, Boa e boa) e que pode afetar negativamente o resultado.

3.3.1.3 Remoção de palavras irrelevantes

Palavras de interrupção são palavras funcionais específicas do idioma. Estas são palavras utilizadas para definir a estrutura da frase, e frequentemente não adicionam ou removem nenhum sentido relevante (artigos, preposições e conjunções).

Os exemplos incluem a, se, ou. Esse processo também permite a redução do corpus, deixando apenas as palavras essenciais para as próximas etapas.

3.3.1.4 Remoção de espaços, pontuação e números

Eles são outros tipos de caracteres que não trazem sentido ao texto. Portanto, também é importante remover espaços em branco desnecessários, símbolos de pontuação e números.

3.3.2 Léxicos

Léxicos são um conjunto de palavras e expressões de uma língua que são utilizados tanto na linguagem verbal quanto na escrita. No âmbito da análise de sentimentos, ele é a construção de um dicionário específico que se concentra na busca da compreensão da polaridade das palavras do texto. Ele é uma das abordagens mais simples e populares, que tem sido bastante aplicada em pesquisas de finanças e economia.

Resumidamente, um dicionário é uma coleção de palavras, cada uma com atributos de sentimento associado. Com auxílio dessas listas, pode-se quantificar palavras associadas ao sentimento positivo e negativo e fazer uma medida comparativa de polaridade.

Às vezes, esse método pode ser interpretado como uma abordagem não supervisionada do Machine Learning, porém será seguida a premissa que ele é um método independente. Já que a classificação da polaridade da palavra depende exclusivamente do léxico.

Com o intuito de diversificar o trabalho, foram utilizados léxicos em português e inglês. Ao analisar o banco de notícias por diferentes perspectivas se tem resultados mais apurados. Além disso, é possível comparar a precisão dos léxicos.

Além disso, existem classe gramaticais que são mais importantes dentro das análises lexicais, dentre elas pode-se destacar:

- **Substantivo:** se refere a uma entidade, podendo ser um objeto ou uma pessoa. Expressa designações a objetos ou seres. Na análise de sentimentos, os substantivos são importantes para se saber de quem se fala, podendo ser um produto, marca ou objeto.

- **Adjetivo:** oferece uma qualidade ou característica de um substantivo. É fundamental na análise de sentimentos para destacar uma característica boa ou ruim de um determinado objeto.

- **Verbo:** indica o estado ou ação em uma frase. Por meio dos tempos verbais é possível saber se a ação ou estado ocorreu no passado, presente ou futuro.

- **Advérbio:** palavra que propõe modificar o sentido de um verbo ou adjetivo, como por exemplo, na frase: “Isso não é nada bonito”, no qual o advérbio “nada” altera o sentido do adjetivo “bonito”.

Portanto, um adjetivo, um advérbio de negação e de intensidade podem modificar totalmente uma frase, conforme as frases abaixo:

- “A Renner não está boa” (o advérbio “não” nega o adjetivo de valor positivo “boa”).

- “A Vale está com um crescimento muito lento” (advérbio “muito” intensifica o adjetivo “lento”).

3.3.2.1 OpLexicon Reader

O OpLexicon Reader é um Léxico criado pelo Laboratório de Processamento de Linguagem Natural da PUCRS. Eles realizam pesquisas relacionadas à computação semântica e ao tratamento semântico de língua natural, envolvendo processamento linguístico para extração de informações e engenharia de conhecimento baseada em corpus.

A biblioteca é composta por um grupo categorizado com a sua classe morfológica e anotadas com a polaridade positiva, negativa ou neutra. Linguistas fizeram revisão na polaridade de alguns adjetivos, com objetivo de melhorar sua precisão.

O OpLexicon é formado por um grupo de 32.191 itens, dos quais 24.475 são adjetivos e 6.889 são verbos. A construção do Léxico foi baseada, em sua maioria, em textos jornalísticos e resenhas de filmes escritas em Português do Brasil, além da tradução do léxico de opinião em inglês.

3.3.2.2 LiwcReader - Linguistic Inquiry and Word Count

A criação do dicionário brasileiro LIWC em 2007 foi feita via tradução por 3 times: uma equipe do Núcleo Interinstitucional de Linguística Computacional (NILC) da USP, uma da empresa Checon Pesquisa e outra da Unisinos. Foram utilizados alguns dicionários bilíngues Português-Inglês. As conjugações foram inseridas automaticamente usando o dicionário Unitex-PB do NILC e as categorias do dicionário foram levantadas automaticamente.

O objetivo desse dicionário é juntar palavras em categorias que podem ser utilizadas para identificar traços psicolinguísticos nos textos. O LIWC tem 127.149 palavras e cada uma delas é classificada em um ou mais atributos. As duas polaridades principais são positivas e negativas. Outras categorias, como afeto, raiva, tristeza e entre outras, seriam importantes, porém para que se tivesse compatibilidade com as demais bibliotecas em português foi escolhido manter em duas polaridades.

3.3.2.3 SentiLexReader

O SentiLexReader é um Léxico criado pelos pesquisadores portugueses Mário J. Silva e Paula Carvalho. Ambos são do Instituto de Engenharia de Sistemas e Computadores - Investigação e Desenvolvimento (INESC-ID) que é uma instituição privada dedicada à pesquisa e desenvolvimento avançados nos domínios da eletrônica, energia, telecomunicações e tecnologias da informação.

Apesar de existirem alguns Léxicos de sentimento em português atualmente, quando o Sentilex foi desenvolvido os mesmos não existiam ou não eram públicos. Em inglês, os dicionários tinham grande presença, mas em português o Sentilex foi pioneiro.

Com o objetivo de analisar o sentimento e a opinião em textos, ele trata-se de uma ferramenta formada por 7.014 lemas e 82.347 formas flexionadas. Ele é orientado principalmente pelas restrições sintáticas e pelo domínio semântico das palavras, sendo assim um léxico inteligente e flexível. Os adjetivos, verbos, nomes e qualquer expressão de natureza verbal é considerado como uma entrada. Essas entradas exercem impactos sobre uma palavra principal. Em suma, cada entrada irá conter uma informação sobre a sintática de um predicator.

3.3.3 Algoritmo

O objetivo da fase de análise de texto é identificar, quantificar e extrair qualquer sentimento presente em cada uma das fontes de notícias.

O intuito dessa análise é identificar os sentimentos e os motivos dos principais eventos de queda ou ganho extremos. A base de dados contém apenas os títulos das notícias, dessa maneira a abordagem utilizada nesse trabalho foi a baseada no Léxico e no nível da frase.

Cada notícia foi classificada entre os sentimentos positivo, negativo ou neutro. O neutro significa que o artigo não passou nenhum posicionamento de sentimento e se manteve isento de opinião.

Após classificar cada palavra através da análise dos Léxicos, o algoritmo irá fazer um somatório, para dessa forma classificar os títulos das notícias. O algoritmo criado utiliza a categorização de palavras para definir os sentimentos do texto com o seguinte algoritmo:

- Caso o somatório do número de palavras positivas de um título seja maior que a soma do número de palavras negativas, a notícia terá sua polarização como positiva.
- Caso o somatório do número de palavras negativas de um título seja maior que a soma do número de palavras positivas, a notícia terá sua polarização como negativa.
- Caso o somatório se encontre em nenhuma das duas categorizações, a notícia será classificada como neutra.

Capítulo 4

Resultados

Através das metodologias apresentadas anteriormente se obtiveram resultados das pesquisas realizadas. Esse capítulo apresenta a estatística descritiva das variáveis e das notícias, descreve todo o processo de análise gráfica e financeira dos ativos, e os resultados dos impactos do sentimento das notícias financeiras sobre o comportamento dos preços no mercado acionário brasileiro e dos ativos escolhidos, assim como, apresenta a relação desses ativos em momentos de incerteza.

4.1 Análise das notícias

Os índices e ativos são extremamente sensíveis as especulações de mercado. As notícias são importantes fontes de entrada de informação e as reações a elas são importantes drivers de oscilação de mercado. Assim como já foi dito antes, as notícias foram obtidas no jornal Valor Econômico e Folha de São Paulo. A seleção delas foi realizada por meio das notícias direcionadas ao mercado financeiro no período entre 01 de janeiro de 2013 e 16 de agosto de 2019 totalizando uma amostra de 215.972 matérias, conforme disposto nas tabelas 1 e 2.

Tabela 1 – Notícias da Folha de São Paulo

Folha de São Paulo													
Ano \ Mês	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	Total Anual
2013	2.083	1.895	2.170	2.197	2.205	2.192	2.301	2.449	2.184	2.271	2.144	1.983	26.074
2014	1.793	1.863	2.023	2.084	2.186	2.009	2.032	2.159	2.184	1.821	2.007	1.963	24.124
2015	1.850	1.655	1.953	1.614	1.620	1.536	1.626	1.695	1.681	857	79	51	16.217
2016	18	171	444	317	354	426	444	418	417	392	411	395	4.207
2017	443	412	529	506	498	419	369	310	391	495	380	452	5.204
2018	351	345	1.262	1.083	1.031	985	1.094	1.140	1.208	1.309	1.125	1.117	12.050
2019	1.197	1.068	1.015	1.017	1.182	1.103	1.203	669	-	-	-	-	8.454
Total Mensal	7.735	7.409	9.396	8.818	9.076	8.670	9.069	8.840	8.065	7.145	6.146	5.961	96.330

Fonte: Elaborado pelo autor

Tabela 2 – Notícias do Valor Econômico

Valor Econômico													
Ano \ Mês	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	Total Anual
2013	1.649	1.497	1.706	1.857	1.802	1.658	1.827	1.770	1.701	1.963	1.766	1.537	20.733
2014	1.564	1.517	1.454	1.578	1.696	1.546	1.672	1.724	1.729	1.844	1.659	1.559	19.542
2015	1.518	1.406	1.712	1.527	1.601	1.511	1.674	1.659	1.579	1.721	1.628	1.550	19.086
2016	1.382	1.406	1.536	1.421	1.464	1.570	1.490	1.746	1.441	1.510	1.488	1.435	17.889
2017	1.352	1.181	1.547	1.145	1.415	1.395	1.377	1.508	1.332	1.424	1.290	1.227	16.193
2018	1.277	1.180	1.426	1.421	1.388	1.399	1.345	1.529	1.244	1.500	1.262	1.211	16.182
2019	1.333	1.303	1.297	1.329	1.369	1.206	1.398	782	-	-	-	-	10.017
Total Mensal	10.075	9.490	10.678	10.278	10.735	10.285	10.783	10.718	9.026	9.962	9.093	8.519	119.642


Fonte: Elaborado pelo autor

A divisão por meses e anos foi realizada para se entender se tiveram limitações durante a coleta dos dados. Pode-se visualizar que durante outubro de 2015 e fevereiro de 2018 as notícias da Folha de São Paulo tiveram uma queda brusca em seu data mining, o que leva a acreditar que o site não disponibilizou todas as notícias em seu portal, limitando assim análises de sentimento referentes a essa fonte durante esse espaço de tempo. Já o Valor Econômico apresenta maior regularidade na apresentação das notícias, o que indica que o site consegue fazer suas publicações regularmente, ajudando na análise do sentimento das mesmas.

Um ponto a se ressaltar a respeito das notícias é a periodicidade delas. Como pode ser visto no gráfico 1 Enquanto a Folha de São Paulo publica todos os dias da semana, o Valor apenas durante os dias úteis. Essa periodicidade influencia diretamente na análise de sentimento, visto que o mercado financeiro brasileiro só funciona durante dias úteis. Logo notícias que podem impacta-lo que são publicadas no final de semana, terá seu efeito sentido na segunda feira. O mesmo

ocorre para dia com feriado, onde a Bovespa não funciona regularmente, e terá seu efeito sentido no próximo dia útil.

Gráfico 1 – Distribuição de Notícias




Fonte: Elaborado pelo autor

Outro fator identificado é o chamado “efeito segunda-feira”, observa-se que no primeiro dia útil da semana se tem a menor quantidade de publicações em comparação com os demais dias, ou seja, se tem uma queda de produção nesse dia. Também observou-se que a quantidade de palavras publicadas também é a menor. Os estudiosos Antweiler e Murray em 2014 atribuíram a esse efeito uma interpretação psicológica de que as pessoas geralmente na segunda por estarem retornando a rotina de trabalho estão mais deprimidas e costuma escrever menos.


Nos gráficos 2 e 3, se tem o resultado do cálculo de palavras médias nos títulos e descrições das notícias. A etapa de pré processamento do texto foi muito importante para reduzir esse volume de palavras das frases, visto que nem todas são importantes na visão do sentimento textual. Como já foi dito no capítulo de metodologia, foi realizada a retirada das stopwords o que auxiliou uma análise com maior precisão e eficiência. No gráfico 4 e 5 foi mostrada a média pós tratamento das stopwords, e a retirada delas reduziu 33% da média dos títulos e 39% da média das descrições da Folha de São Paulo, enquanto no Valor Econômico a redução da média dos títulos foi de 25% e das descrições de 35%.

Gráfico 2 – Quantidade de Palavras no Título




Fonte: Elaborado pelo autor

Gráfico 3 – Quantidade de Palavras na Descrição




Fonte: Elaborado pelo autor

Gráfico 4 – Quantidade de Palavras no Título sem stopwords



Fonte: Elaborado pelo autor

Gráfico 5 – Quantidade de Palavras a Descrição sem stopwords



Fonte: Elaborado pelo autor

As tabelas 3 e 4, apresentam um ranking por frequências das palavras que mais apareceram nas notícias financeiras após o tratamento das stopwords. A tabela 3 mostra as palavras que apareceram mais nos títulos das matérias, enquanto na tabela 4 mostra as que tiveram maior presença nas descrições das notícias.

Na tabela 3, dentre as palavras com maior frequência evidencia-se “Governo” (2º lugar), “Brasil” (3º lugar) e “EUA” (5º lugar), palavras essas que demonstram a influência que o governo brasileiro e americano tem dentro da economia brasileira. No quadro B, as palavras “Governo” (4º lugar) e “Presidente” (6º lugar) são vistas

com relevância nas descrições, ressaltando a importâncias que os jornais financeiros brasileiros dão a influência da política brasileira. Outra palavra que ganhou destaque em ambos rankings é “Diz” (1º lugar ranking Título e 15º no ranking Descrição). Ela se destacou pois diversas notícias colocam referências as falas de pessoas, como por exemplo, “Mais de 60 mil morreram na Síria, diz ONU”.

As palavras com menor frequência também foram analisadas e em sua grande maioria são substantivos próprios. Dessa forma, entende-se que as menos citadas são termos que apresentam conteúdo semântico de pouca relevância para a análise do sentimento textual.

Tabela 3 – Ranking das palavras dos Títulos

Ranking - Títulos					
Ranking	Palavra	Frequência	Ranking	Palavra	Frequência
1	diz	11849	11	sp	4129
2	governo	6391	12	deve	4054
3	brasil	6376	13	novo	3785
4	sobre	6052	14	bi	3561
5	eua	5469	15	país	3487
6	pode	4910	16	quer	3182
7	vai	4815	17	nova	3140
8	após	4402	18	dilma	3107
9	mercado	4345	19	ser	3055
10	contra	4139	20	ano	2813

Fonte: Elaborado pelo autor

Tabela 4 – Ranking das palavras das Descrições


Ranking - Descrições					
Ranking	Palavra	Frequência	Ranking	Palavra	Frequência
1	sobre	10278	11	mercado	6012
2	ser	9955	12	pode	6010
3	segundo	9166	13	empresas	5959
4	governo	9151	14	brasil	5903
5	ano	8488	15	diz	5894
6	presidente	8369	16	ainda	5779
7	empresa	6949	17	após	5678
8	país	6812	18	vai	5478
9	maior	6531	19	anos	5434
10	milhões	6012	20	deve	5423

Fonte: Elaborado pelo autor

4.2 Análise estatística


Nessa seção é apresentada a descrição dos dados financeiros utilizados, bem como suas análises estatísticas e financeiras. Os gráfico 4 e 5, apresentam respectivamente as series dos preços e volumes coletados que serão usados como base para fazer as análises posteriores e abrangem o período de 01/01/2013 e 16/08/2019.

Gráfico 4 – Preços dos Ativos



Fonte: Elaborado pelo autor

Gráfico 5 – Volumes dos Ativos



Fonte: Elaborado pelo autor

Dentre os retornos dos ativos escolhidos, pode-se ressaltar o da Magazine Luiza pela sua discrepância em relação aos demais. Apesar de ter aberto capital em 2011, o valor do seu papel era bem baixo e a partir de 2016 ela teve crescimentos absurdos, como pode ser visto na tabela 5. Em 2016, ela cresceu 501%, em 2017, cresceu 820%, e em março de 2019 ela cresce 697%.

Tabela 5 – Retorno Mensal da Magazine Luiza

Magazine Luiza - Retorno Mensal													
Ano	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	YTD
2013	-6,61	-15,50	-9,66	-21,83	13,83	-33,99	-5,02	12,33	31,53	25,83	-11,58	-10,12	-41,25
2014	5,30	-4,46	-7,95	33,58	7,11	12,90	-2,61	0,56	-15,78	8,84	-3,64	-3,02	25,48
2015	-3,54	-11,03	-15,87	18,52	-14,91	-17,52	1,70	-28,97	-29,41	-18,06	-25,17	99,89	-62,47
2016	-19,83	39,22	48,48	9,50	8,52	10,76	19,48	31,52	26,45	20,86	12,48	2,09	501,53
2017	20,55	62,60	-14,90	82,52	12,66	1,99	43,31	54,82	4,52	-14,10	-10,87	48,20	820,59
2018	5,41	7,68	7,53	8,99	1,60	18,05	3,34	-1,52	-5,96	37,81	-2,47	9,99	125,72
2019	1,55	-3,13	-0,35	12,69	2,48	7,71	24,91	13,94	0,00	0,00	0,00	0,00	73,55


Fonte: Elaborado pelo autor

Com isso, o valor da sua ação chega a mais de 200 reais tornando mais difícil a circulação dos seus papéis, e para resolver esse problema foi realizado um Split, ou desdobramento de ações. É um processo no qual a empresa divide seus papéis em várias partes fazendo com que o número de ações disponíveis aumente, enquanto o valor do papel diminua, porém preservando valor de mercado da empresa.

Por conta desse dos Splits, a Magazine Luiza teve alguns retornos distorcidos que foram tratados para que sua análise não seja distorcida. Os quadros do gráfico 6, apresentam os cálculos dos retornos dos ativos, que foram obtidos por meio do logaritmo natural sobre o fechamento diário (somente dias uteis) e depois subtraindo o valor em t de t-1.


Na figura 5, é possível analisar o gráfico de preços da Vale durante o período de tempo pesquisado e ver em suas movimentações os impactos de eventos aleatórios. As notícias funcionam como transmissores de fatos que acontecem na realidade, causando impactos reais em seus movimentos.

Figura 5 – Preços da Vale com Notícias



Fonte: Elaborado pelo autor

Gráfico 6 – Retorno dos Ativos




Fonte: Elaborado pelo autor

Os gráficos de retornos são interessantes para se identificar picos de altas e baixas. Anteriormente, alguns desses picos eram missings de preços que o Yahoo Finance têm e isso é um problema na hora de calcular os outliers de retornos verdadeiros, visto que os preços que estão faltando confundirão a análise. Por conta desses problema, foi realizado um tratamento para esse problema.

Além disso, com intuito de melhorar o entendimento dos retornos foi calculado de desempenho relativo. Evidenciado no gráfico 7, pode-se comparar os retorno de diferentes ativos saindo de um mesmo ponto de partida comum, excluindo o ativo da Magazine Luiza devido ao crescimento exponencial que ela teve.


Gráfico 7 – Desempenho Relativo



Fonte: Elaborado pelo autor

A distribuição dos retorno diário também foi plotada para visualizar melhor o seu comportamento e entender se os ativos seguem uma distribuição normal. No gráfico 8, foram apresentadas as análises dos histogramas dos papeis, e cada um deles foi comparado com uma distribuição normal da respectiva média e desvio-padrão.

Gráfico 8 – Histograma dos Ativos



Fonte: Elaborado pelo autor

A análise financeiro estatística apresentada na tabela 6 vem com o propósito de buscar um melhor entendimento da performance dos ativos durante o período escolhido. Os fatores analisados nela são métricas específicas do mercado financeiro.

Importante reparar que a Bovespa como índice de ações brasileiro deve ser considerado como benchmark de retorno. Pode-se visualizar pelas análises de Retorno total e CAGR (retorno anual) que apenas a Magazine Luiza e o Itaú conseguiram performar mais que ela.

Esse retorno pode ser consequência de uma maior exposição ao risco dos papéis citados anteriormente. Na parte do risco foram calculadas algumas métricas: Volatilidade, Sharpe Ratio, Sortino Ratio e Calmar Ratio. Observa-se que esses indicadores para a Magazine Luiza e para o Itaú continuaram maiores em relação aos demais, confirmando sua maior exposição ao risco.

Outro ponto relevante na análise são os índices de Skew e curtose. A assimetria da Bovespa foi aproximadamente 0, que é uma característica de uma curva normal. Já Ambev, Itaú e, Magazine Luiza e Petrobras por terem uma assimetria positiva, o que é uma característica de quem tem cauda direita. Enquanto a Vale tem uma assimetria negativa, e por consequência uma cauda esquerda. Em relação a curtose, os que mais se destacam são a Magazine Luiza e a Petrobrás, evidenciando uma maior presença de Outliers em suas series históricas.

Tabela 6 – Análise estatística


Análise Estatística Financeira						
	Ambev	Itaú	Magazine Luiza	Petrobrás	Vale	Bovespa
Start	02/01/2013	02/01/2013	02/01/2013	02/01/2013	02/01/2013	02/01/2013
End	16/08/2019	16/08/2019	16/08/2019	16/08/2019	16/08/2019	16/08/2019
Risk-free rate	4,25%	4,25%	4,25%	4,25%	4,25%	4,25%
Total Return	43,94%	188,42%	5903,01%	39,34%	27,92%	59,56%
Daily Sharpe	0,36	0,68	1,27	0,35	0,31	0,43
Daily Sortino	0,62	1,2	2,63	0,6	0,53	0,74
CAGR	5,66%	17,36%	85,67%	5,14%	3,79%	7,32%
Max Drawdown	-37,66%	-32,62%	-88,21%	-82,90%	-76,96%	-40,77%
Calmar Ratio	0,15	0,53	0,97	0,06	0,05	0,18
MTD	-6,11%	-0,63%	13,94%	-7,60%	-12,29%	-1,97%
3m	13,58%	10,15%	79,93%	-4,28%	-5,84%	10,87%
6m	2,22%	-5,67%	86,63%	-9,81%	-4,77%	2,34%
YTD	22,89%	-0,27%	73,55%	6,73%	-14,33%	13,56%
1Y	1,47%	21,23%	130,56%	32,66%	-12,13%	29,92%
3Y (ann.)	0,85%	21,14%	295,34%	26,47%	36,04%	19,26%
5Y (ann.)	6,36%	16,98%	133,97%	4,37%	10,84%	11,65%
Since Incep. (ann.)	5,66%	17,36%	85,67%	5,14%	3,79%	7,32%
Daily Sharpe	0,36	0,68	1,27	0,35	0,31	0,43
Daily Sortino	0,62	1,2	2,63	0,6	0,53	0,74
Daily Mean (ann.)	0,02%	0,06%	0,25%	0,02%	0,02%	0,03%
Daily Vol (ann.)	1,42%	1,93%	3,99%	3,15%	2,89%	1,43%
Daily Skew	0,15	0,09	1,45	-0,13	-0,47	-0,08
Daily Kurt	2,20	3,28	12,10	3,12	7,28	1,72
Best Day	8,18%	11,13%	38,00%	15,09%	13,77%	6,39%
Worst Day	-6,35%	-12,84%	-17,75%	-17,15%	-28,18%	-9,21%
Avg. Drawdown	-5,00%	-5,05%	-7,85%	-16,38%	-10,80%	-4,30%
Avg. Drawdown Days	54,93	44,47	37,12	131,72	130,78	65,71
Avg. Up Month	4,13%	7,94%	20,75%	12,19%	10,63%	4,91%
Avg. Down Month	-3,63%	-5,07%	-12,35%	-10,48%	-7,69%	-4,31%
Win Year %	50,00%	66,67%	83,33%	66,67%	50,00%	66,67%
Win 12m %	65,22%	81,16%	72,46%	59,42%	55,07%	71,01%

Fonte: Elaborado pelo autor

Por fim, foi calculada a correlação entre os ativos escolhidos, apresentada na figura 5, para mensurar melhor a relação entre eles. Essa medida vai de -1 a 1, onde quando o valor for -1 se tem uma correlação contrária perfeita, já quando for 1 é uma correlação perfeita. A correlação entre a Bovespa e os outros ativos de destaca devido as ações comporem em peso o Índice. Por conta disso, eles têm uma boa

correlação, exceto Magazine Luiza por conta de seu grande crescimento. Observando a correlação entre os outros ativos, a maior foi entre Petrobrás e Itaú, onde apesar de serem empresas de diferentes setores, elas se assemelham ao fato de serem empresas de grande porte e maduras.

Figura 6 – Correlação entre os Ativos



Fonte: Elaborado pelo autor

4.3 Análise de sentimento

Na análise de sentimento, as palavras que realmente possuem valor informacional e sentimental são de extrema importância para a estruturação da polarização textual. Os termos que geram maior impacto em uma frase normalmente são os que têm as classes gramaticais mais importantes, tais como substantivos, adjetivos e verbos. A partir deles que geralmente se categoriza as informações das orações e com isso se extrai seu sentimento. Partindo dessa premissa foram realizados wordclouds dos substantivos, adjetivos e verbos mais frequentes para ajudar na visualização das palavras que desempenham maior impacto textual.

Figura 8 – Worldclouds Verbos



Fonte: Elaborado pelo autor

Na figura 8 se tem a nuvens de palavras de adjetivos, que por sua vez, poucos apresentam um posicionamento de sentimento, sendo em sua maioria termos com neutralidade.

Figura 9 – Worldclouds Adjetivos



Fonte: Elaborado pelo autor

Após todas as etapas iniciais foi realizada a etapa de análise lexical com dicionários em português. Os dicionários utilizados foram o OP Lexicon, Sentilex PT e Liwc reader. Eles apresentam características semelhantes entre si, como a marcação das classes gramaticais das palavras e as polaridades expressas como:

-1 = sentimento negativo


0 = sentimento neutro

1 = sentimento positivo.

Nem todas as palavras presentes nas notícias estão inclusas nos dicionários, o que interfere na eficácia da pesquisa, já que o sentimento de todas as palavras não serão analisados. Entretanto, essas palavras não entram na soma do resultado de sentimento final. Os resultados estarão dentro do intervalo de -1 e 1, visto que foi realizado um somatório de todas as polaridades e depois calculada a média.


Com o propósito de entender melhor as mudanças de sentimento ao longo do tempo, foram realizados os gráficos 9 e 10 para a visualização dos somatórios de polaridade através dos anos e meses dos diferentes dicionários lexicais.

Gráfico 9 – Análise de Sentimento Anual



Fonte: Elaborado pelo autor

Gráfico 10 – Análise de Sentimento Mensal



Fonte: Elaborado pelo autor


A partir dos resultados apresentados para cada dicionário, analisa-se que as variações entre os resultados de polaridade são baixas, mas marcados de um maior pessimismo. No espaço de tempo anual os resultados se limitam entre o intervalo de -0,095 e 0,05, enquanto no espaço de tempo mensal eles ficam limitada entre -0,12 e 0,7.

Com isso a análise de sentimento em uma visão mais abrangente estão dentro do intervalo assumido para neutro que é entre -0,35 e 0,35. Entretanto, abrindo os resultados por dia e notícias consegue-se entender melhor quais notícias causam um real impacto negativo ou positivo.

Outro ponto interessante no gráfico é a tendência clara do Sentilex em ser pessimista, enquanto o Liwc assume uma tendência mais otimista. O OpLexicon é o único que varia nessa visão anual e mensal.


Com o objetivo de entender melhor essas tendências dos dicionários, verificar a hipótese de que os dicionários tem resultados divergentes entre si e tendem ao sentimento neutro, foi calculada a distribuição dos sentimentos de cada, apresentadas nos gráficos 11, 12 e 13.

Gráfico 11 – Histograma LIWC




Fonte: Elaborado pelo autor

Gráfico 12 – Histograma Sentilex



Fonte: Elaborado pelo autor

Gráfico 13 – Histograma OpLexicon




Fonte: Elaborado pelo autor

A partir dos histogramas, é possível visualizar a grande quantidade de manchetes neutras. O que leva a duas possíveis possibilidades, a primeira é que as notícias tem poucas palavras dentro dos dicionários lexicais, e com isso esses termos após a análise tem um resultado neutro. A segunda é que os artigos em sua maioria são realmente neutros.

Outra observação interessante é a diferença da distribuição entre os dicionários. O OpLexicon e o Sentilex são mais discretizados, apresentando resultados normalmente em -1, 0 e 1. Enquanto, o Liwc tem uma distribuição mais variada, principalmente devido ao fato dele ter uma maior compatibilidade com as notícias e maior número de termos que os outros.


A distribuição do sentimento por jornal também foi calculada, com intuito de entender melhor como se comportam. Nos gráficos 14, 15 e 16, pode-se observar que os resultados por são compatíveis com os resultados mensais e anuais. O OpLexicon é o único que varia entre os resultados por jornal, enquanto o Liwc se polariza nas notícias positivas, e o Sentilex nas negativas.

Gráfico 14 – Distribuição LIWC por Jornal




Fonte: Elaborado pelo autor

Gráfico 15 – Distribuição Sentilex por Jornal



Fonte: Elaborado pelo autor

Gráfico 16 – Distribuição OpLexicon por Jornal



Fonte: Elaborado pelo autor

A tabela 7 exibe dados da estatística descritiva das variáveis da Ibovespa em relação as bibliotecas. Os resultados gerais foram calculados a partir do sentimento de texto, e analisa-se que OpLexicon e Liwc tiveram uma média de sentimento mais otimista, enquanto o Sentilex interpretou uma visão da mídia mais negativa.

Tabela 7 – Análise de Sentimento Geral

Variável	Dados gerais							
	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,00650	1	0,49090	0,79390	-0,00117	215971
SentiLex	-1	0	-0,07699	1	0,53851	0,31023	-0,04480	215971
LIWC	-1	0	0,03207	1	0,31078	2,58496	0,05238	215971
Ambev	-0,06352	0,00047	0,00022	0,08175	0,01420	2,20494	0,14953	1638
Itaú	-0,12837	0,00029	0,00065	0,11128	0,01928	3,27875	0,08669	1638
Magazine Luiza	-0,17752	0,00016	0,00250	0,37996	0,03992	12,09650	1,44820	1638
Petrobrás	-0,17149	0,00056	0,00020	0,15086	0,03146	3,12128	-0,13127	1638
Vale	-0,28182	0,00020	0,00015	0,13768	0,02887	7,27905	-0,46758	1638
Bovespa	-0,09211	0,00028	0,00029	0,06389	0,01427	1,72214	-0,08386	1638

Fonte: Elaborado pelo autor

Na tabela 8, os dias foram segregados pelos sentimentos predominantes das notícias. Os dias em que as três bibliotecas apresentavam um sentimento positivo foi considerado otimista. Enquanto, nos dias em que as três tinham resultados negativos considerou-se um dia pessimista. Os restantes foram considerados como dias neutros.

Um ponto interessante sobre essa análise é o viés mais negativo que o OpLexicon e o SentiLex têm nos dias de mídia neutra. O que, segundo o estudioso Tetlok, pode ser explicada pela natural negatividade que ocorre na linguagem humana nos títulos das notícias financeiras, que através do seu estudo identificou forte viés ao negativismo no Wall Street Journal e no New York Times [22].

Tabela 8 – Análise pelo Sentimento do Dia

Dias com Mídia Positiva								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,04836	1	0,48283	0,83920	0,07228	17943
SentiLex	-1	0	0,00935	1	0,53421	0,44387	0,01060	17943
LIWC	-1	0	0,05427	1	0,30722	2,54718	0,19282	17943
Ambev	-0,06352	0,00160	0,00042	0,08175	0,01487	5,73315	-0,03044	221
Itaú	-0,05931	0,00084	0,00275	0,11128	0,02235	5,07291	1,18313	221
Magazine Luiza	-0,17752	0,00131	0,00400	0,37996	0,04521	21,87512	2,33899	221
Petrobrás	-0,10107	0,00214	0,00180	0,15086	0,03477	2,50322	0,55540	221
Vale	-0,15671	0,00276	0,00163	0,13768	0,03127	4,79748	0,19267	221
Bovespa	-0,03776	0,00090	0,00133	0,06389	0,01581	1,50736	0,36702	221
Dias com Mídia Neutra								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,00490	1	0,49132	0,79126	-0,00357	186840
SentiLex	-1	0	-0,08296	1	0,53809	0,30214	-0,04903	186840
LIWC	-1	0	0,03254	1	0,31059	2,58827	0,06565	186840
Ambev	-0,05665	0,00263	0,00033	0,06729	0,01392	1,36545	0,18258	1311
Itaú	-0,08368	0,00028	0,00057	0,07771	0,01840	0,98758	-0,00576	1311
Magazine Luiza	-0,16837	0,00030	0,00211	0,31691	0,03814	9,53450	1,21738	1311
Petrobrás	-0,16085	0,00056	0,00020	0,12597	0,03024	3,08493	-0,17816	1311
Vale	-0,11842	0,00067	0,00021	0,10668	0,02672	1,70546	-0,01413	1311
Bovespa	-0,04988	0,00036	0,00027	0,04898	0,01381	0,61076	0,01640	1311
Dias com Mídia Pessimista								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,03495	1	0,49155	0,74882	-0,05675	11188
SentiLex	-1	0	-0,11680	1	0,53861	0,21037	-0,06061	11188
LIWC	-1	0	-0,01157	1	0,31441	2,44860	-0,34356	11188
Ambev	-0,04371	0,00051	0,00019	0,04501	0,01401	1,38408	0,37682	106
Itaú	-0,12837	0,00130	0,00070	0,04736	0,02123	11,75162	-2,01013	106
Magazine Luiza	-0,17713	-0,00225	0,00542	0,17646	0,04502	8,12569	1,46274	106
Petrobrás	-0,17149	0,00432	-0,00024	0,07846	0,03203	7,48443	-1,52852	106
Vale	-0,28182	0,00331	0,00129	0,09535	0,04056	21,75246	-2,85263	106
Bovespa	-0,09211	0,00205	0,00169	0,03180	0,01613	9,54296	-1,93636	106

Fonte: Elaborado pelo autor

Por fim, a tabela 9 apresenta quadros dos quais analisam o sentimento das notícias nos dias em que os retornos dos ativos tiveram oscilações fora do normal. Foram considerados outliers os retornos que estavam fora do intervalo de dois

desvios padrões. Interessante que em momento de outliers, os resultados dos sentimentos acompanharam os resultados dos retornos e mantiveram um mesmo padrão, com Liwc positivos, enquanto o Sentilex e o OpLexicon apresentando resultado negativo.

Tabela 9 – Análise de Sentimento dos Outliers

Ambev - Outliers Positivos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,01110	1	0,49828	0,68469	-0,01862	6392
SentiLex	-1	0	-0,06383	1	0,54999	0,20814	-0,01586	6392
LIWC	-1	0	0,04789	1	0,32494	2,27358	0,13041	6392
Ambev	0,02890	0,03505	0,03821	0,08175	0,31476	6,01643	2,23124	65
Ambev - Outliers Negativos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,00263	1	0,49856	0,69059	-0,00114	4918
SentiLex	-1	0	-0,08263	1	0,54813	0,18379	-0,03432	4918
LIWC	-1	0	0,02529	1	0,31471	2,48427	-0,01852	4918
Ambev	-0,06352	-0,03348	-0,03690	-0,02863	0,00847	1,49688	-1,41015	45
Itaú - Outliers Positivos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,01279	1	0,49876	0,70081	0,00806	5463
SentiLex	-1	0	-0,07568	1	0,53835	0,31593	-0,04425	5463
LIWC	-1	0	0,02176	1	0,31327	2,61075	0,01172	5463
Itaú	0,03942	0,04595	0,05146	0,11128	0,01505	5,92444	2,34434	58
Itaú - Outliers Negativos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,00181	1	0,50339	0,63045	-0,02148	4708
SentiLex	-1	0	-0,06664	1	0,54614	0,24831	-0,02768	4708
LIWC	-1	0	0,03117	1	0,31172	2,53945	0,03435	4708
Itaú	-0,12837	-0,04472	-0,04971	-0,03963	0,01460	16,93383	-3,67166	49
Magazine Luíza - Outliers Positivos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,02234	1	0,49748	0,69314	0,01621	4387
SentiLex	-1	0	-0,07053	1	0,53673	0,35592	-0,04652	4387
LIWC	-1	0	0,02876	1	0,30702	2,54960	-0,03250	4387
Magazine Luíza	0,08440	0,11141	0,13955	0,37996	0,06539	3,14222	1,85950	55
Magazine Luíza - Outliers Negativos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,01907	1	0,48907	0,83090	0,00700	3217
SentiLex	-1	0	-0,06062	1	0,52493	0,51800	-0,05124	3217
LIWC	-1	0	0,03736	1	0,31741	2,49673	0,10585	3217
Magazine Luíza	-0,17752	-0,09871	-0,10862	-0,08237	0,03006	0,19477	-1,23833	37
Petrobrás - Outliers Positivos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,01114	1	0,49449	0,75905	0,00317	5715
SentiLex	-1	0	-0,07709	1	0,53426	0,36012	-0,05589	5715
LIWC	-1	0	0,02882	1	0,31949	2,55247	0,07266	5715
Petrobrás	0,06317	0,08004	0,08587	0,15086	0,01910	1,24079	1,16653	59
Petrobrás - Outliers Negativos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,02513	1	0,49719	0,71790	-0,01785	4334
SentiLex	-1	0	-0,05618	1	0,53318	0,41329	-0,04800	4334
LIWC	-1	0	0,04427	1	0,31493	2,47361	0,13489	4334
Petrobrás	-0,17149	-0,08067	-0,09274	-0,06325	0,03052	0,65257	-1,31994	47

Vale - Outliers Positivos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,00818	1	0,49341	0,76861	0,00783	4937
SentiLex	-1	0	-0,07398	1	0,52291	0,50853	-0,07430	4937
LIWC	-1	0	0,03069	1	0,30528	2,63710	0,09267	4937
Vale	0,05895	0,07228	0,07740	0,13768	0,01529	2,48717	1,29871	60

Vale - Outliers Negativos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,01423	1	0,48604	0,88430	-0,00146	3886
SentiLex	-1	0	-0,06021	1	0,54126	0,31347	-0,04430	3886
LIWC	-1	0	0,02596	1	0,30742	2,55185	-0,05788	3886
Vale	-0,28182	-0,07073	-0,08051	-0,05958	0,03392	24,37923	-4,47313	51

Bovespa - Outliers Positivos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	0,01254	1	0,49572	0,72545	-0,00384	4961
SentiLex	-1	0	-0,06074	1	0,53361	0,39736	-0,04651	4961
LIWC	-1	0	0,03215	1	0,31571	2,57725	-0,00938	4961
Bovespa	0,02899	0,03660	0,03793	0,06389	0,00691	2,34619	1,17863	52

Bovespa - Outliers Negativos								
Variável	Mínimo	Mediana	Média	Máximo	Volatilidade	Curtose	Assimetria	Amostra
OpLexicon	-1	0	-0,00270	1	0,50235	0,64911	-0,02168	5176
SentiLex	-1	0	-0,06707	1	0,54996	0,20129	-0,02255	5176
LIWC	-1	0	0,03707	1	0,31423	2,41927	0,12116	5176
Bovespa	-0,09211	-0,03351	-0,03539	-0,02903	0,00896	28,00845	-4,66991	57

Fonte: Elaborado pelo autor

Capítulo 5

Conclusão

Esse capítulo serve como um resumo para todo o trabalho descrito ao longo do estudo e fornece uma visão geral do impacto das notícias no mercado acionário brasileiro. Por fim, as limitações dos métodos de pesquisa utilizados são descritas e sugestões para futuros trabalhos são exibidas.

5.1 Resumo e conclusões

A análise de sentimentos está ganhando cada vez mais importância devido sua capacidade de auxiliar nas interpretações das pessoas quanto a determinado assunto. A internet cada vez como principal fonte de informação facilita ainda mais a extração e automatização desse processo.

Essa dissertação focou em examinar o impacto do sentimento das notícias presentes nos jornais formais baseados na Web sobre os retornos financeiros no Brasil. Com isso, ele foi dividido em três etapas: aquisição e pré-processamento de dados, modelagem estatística e análise de sentimento.

A primeira fase desse trabalho teve como objetivo extrair os conteúdos de mídia e os dados financeiros. A acurácia na coleta dos conteúdos de mídia do Valor Econômico e da Folha de São Paulo foi alta, visto que todas as notícias foram extraídas. Já as séries temporais dos dados financeiros da Ambev, Bovespa, Itaú, Magazine Luiza, Petrobrás e Vale, foram extraídas de forma automatizada.

Na segunda fase, os preços dos ativos, os retornos e os volumes foram as bases utilizadas para a modelagem estatística. A partir deles foram extraídos o desempenho relativo, a distribuição dos retornos, a correlação entre os ativos e o quadro de análise estatística. A partir desse último, pode-se analisar o comportamento dos retornos através de indicadores específicos, como Sharpe ratio, Sortino Ratio, Calmar Ratio e Max Drawdown.

Dado a grande quantidade de notícias extraídas para analisá-los foi de suma importância a utilização das técnicas de processamento de linguagem natural. Na última fase, o pré processamento auxiliou a reduzir a quantidade de dados que seriam processados, reduzindo 32% da quantidade de notícias a serem analisadas.

O sentimento presente no conteúdo da mídia foi identificado e extraído através de uma abordagem baseada em dicionário para análise de sentimentos, resultando no cálculo de séries temporais de sentimentos para cada fonte de conteúdo. Os resultados obtidos no estudo indicam que o sentimento tem um impacto mensurável no retorno que é de natureza episódica e variável no tempo, apresentando significância estatística no mercado brasileiro. Em momentos de retornos fora do normal, principalmente nos de queda, os sentimentos apresentaram sintonia em suas flutuações, o que demonstra que as publicações da mídia em dias pessimistas são mais eficientes na correlação com as quedas dos ativos.

Além disso, observa-se que os sentimentos das notícias tem melhor relação com o modelo estatístico nos dias otimistas nos quais todos os dicionários apresentaram resultado alinhados. Por fim, é visível a grande influência do Governo em seu sentimento de mercado, destacando seus termos durante a duração geral da análise e durante os momentos de incerteza.

5.2 Limitações e Trabalho Futuro

Os resultados dessa pesquisa quantifica o sentimento presente em um texto e analisa seu impacto nos mercados financeiros através de análise das séries temporais dos ativos escolhidos. Existe êxito na relação entre o sentimento extraído

das manchetes com os retornos dos ativos, entretanto existem uma série de limitações que podem ser abordadas em trabalhos futuros.

A principal limitação encontrada foi a abordagem de sentimento baseada em dicionário. Os dicionário Sentilex e Liwc têm análises enviesadas que atrapalharam nos resultados gerais. A falta de termos específicos de mercado financeiro também atrapalham na análise, o que faz da construção de um dicionário próprios para termos do mercado financeiro uma solução viável para esse problema.

O trabalho desenvolvido estuda o retorno e o sentimento diário, levando em conta os preços de fechamento ajustados e os sentimento dos artigos por dia. Devido ao grande volume de negociações e a necessidade do mercado financeiro de uma tomada de decisão rápida, uma análise realizada com maior frequência ajudaria um estudo mais eficiente dos efeitos do sentimento e um estudo mais aprofundado da volatilidade dos dados.

Bibliografia

- [1] STRAUB, Nadine; VLIEGENTHART, Rens; VERHOEVEN, Piet. **Lagging behind? Emotions in newspaper articles and stock market prices in the Netherlands**. Public Relations Review, 2016.
- [2] TETLOCK, Paul C. **Does public financial news resolve asymmetric information?**. Review of Financial Studies, 2010.
- [3] TALEB, Nassim N. **The Black Swan**. Random House, 2007.
- [4] SOUZA, M.; VIEIRA, R.; BUSETTTI, D.; CHISHMAN, R e ALVES I. **Construction of a Portuguese Opinion Lexicon from multiple resources**. 8th Brazilian Symposium in Information and Human Language Technology, 2012
- [5] BACHELIER, Louis. **Théorie de l'espéculacion**. Gauthier-Villars, 1900.
- [6] OSBORNE, M. F. Maury. **Brownian motion in the stock market**. Operations research, 1959.
- [7] SAMUELSON, Paul A. **Proof that properly anticipated prices fluctuate randomly**. Industrial management review, 1965.
- [8] LAKNER, P. **Martingale measure for a class of right-continuous process**. Math Magazine, 1993
- [9] FAMA, Eugene F. **The behavior of stock-market prices**. Journal of Business, 1965.
- [10] FAMA, E. F. **Efficient markets: a review of theory and empirical work**. The Journal of Finance, 1970.
- [11] FRAIBERGER, Samuel. **News Sentiment and Cross-Country Fluctuations**. Available at SSRN, 2016.
- [12] FAMA, Eugene F. **Efficient capital markets: II**. The journal of Finance, 1991

- [13] PEETERS, Guido. **The positive–negative asymmetry: On cognitive consistency and positivity bias.** European Journal of Social Psychology, 1971.
- [14] KAHNEMAN, Daniel; TVERSKY, Amos. **Prospect theory: An analysis of decision under risk.** Econometrica, 1979.
- [15] BERNOULLI, D. **Specimen theoriae novae de mensura sortis.** Commentari Academiae Scientiarum Imperialis Petropolitanae, 1738.
- [16] THALER, Richard H. **Integrating Economics with Psychology.** NBER Working Papers, 1980.
- [17] KEARNEY, Colm; LIU, Sha. **Textual sentiment in finance: A survey of methods and models.** International Review of Financial Analysis, 2014.
- [18] NIEDERHOFFER, Victor. **The analysis of world events and stock prices.** Journal of Business, 1971.
- [19] HUANG, Allen H.; ZANG, Amy Y.; ZHENG, Rong. **Evidence on the information content of text in analyst reports.** The Accounting Review, 2014.
- [20] BLOOM, Nicholas. **The impact of uncertainty shocks.** Econometrica, 2009.
- [21] BONE, R. B.; RIBEIRO, E. P. **Eficiência fraca, Efeito dia-da-semana e efeito feriado no mercado acionário brasileiro: Uma Análise Empírica Sistemática e Robusta,** Revista de Administração Contemporânea, 2002.
- [22] TETLOCK, P. C; SAAR-TSECHANSKY, M.; MACSKASSY, S. **More than words: Quantifying language to measure firms' fundamentals.** Journal of Finance, 2008.