

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Análise Preditiva de Ações Baseada em Notícias

Antonio Lopes Jr

Monografia - MBA em Inteligência Artificial e Big Data

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Antonio Lopes Jr

Análise Preditiva de Ações Baseada em Notícias

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientadora: Prof. Dr. Fernando Pereira dos Santos

Versão original

São Carlos

2026

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTA TRABALHO,
POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E
PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados
fornecidos pelo(a) autor(a)

S856m	Lopes Jr, Antonio Análise Preditiva de Ações Baseada em Notícias / Antonio Lopes Jr ; orientador Fernando Pereira dos Santos. – São Carlos, 2026. 98 p. : il. (algumas color.) ; 30 cm. Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universi- dade de São Paulo, 2026. 1. LaTeX. 2. abnTeX. 3. Classe USPSC. 4. Editoração de texto. 5. Normalização da documentação. 6. Tese. 7. Disserta- ção. 8. Documentos (elaboração). 9. Documentos eletrônicos. I. Santos, Fernando Pereira, orient. II. Título.
-------	---

Antonio Lopes Jr

Predictive Analysis of Stocks Based on News

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Fernando Pereira dos Santos

Original version

São Carlos

2026

RESUMO

LOPES JR, A. **Análise Preditiva de Ações Baseada em Notícias**. 2026. 98 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Apresentar, em resumo, a contextualização, motivação, lacunas, proposta, resultados, direções e conclusões. (1 parágrafo (+/- 500 palavras)).

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (...) Salientamos que algumas Unidades exigem o título dos trabalhos acadêmicos em inglês, tornando necessário a inclusão das referências nos resumos e abstracts, o que foi adotado no **Modelo para TCC em L^AT_EX utilizando a classe USPSC** e no **Modelo para teses e dissertações em L^AT_EX utilizando a classe USPSC**. As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto nbr6028.

Palavras-chave: LaTeX. Classe USPSC. Tese. Dissertação. Trabalho de conclusão de curso (TCC). Relatório.

ABSTRACT

LOPES JR, A. **Predictive Analysis of Stocks Based on News**. 2026. 98 p.
Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências
Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

This is the english abstract.

Keywords: LaTeX. USPSC class. Thesis. Dissertation. Conclusion course paper. Report.

LISTA DE FIGURAS

Figura 1 – Estrutura do particionamento estratificado do corpus rotulado	57
Figura 2 – Distribuição do corpus por veículo (esquerda) e distribuição temporal mensal (direita)	59
Figura 3 – Percentual de valores ausentes nos campos coletados via API	60
Figura 4 – Distribuição do comprimento das publicações por número de caracteres (esquerda) e por número de tokens (direita). As linhas tracejadas ver- melha e laranja indicam, respectivamente, os limiares de textos curtos e longos.	61
Figura 5 – Diagrama do <i>pipeline</i> integrado de PLN para análise de sentimento de publicações financeiras no X/Twitter	76

LISTA DE TABELAS

Tabela 1	– Síntese dos trabalhos relacionados	45
Tabela 2	– Esquema da tabela <code>dataset_split</code>	56
Tabela 3	– Exemplos de entradas do SentiLex-PT02 no domínio financeiro	69
Tabela 4	– Distribuição de classes no conjunto de teste	81
Tabela 5	– Métricas de desempenho — OpLexicon v3.0	83
Tabela 6	– Matriz de confusão — OpLexicon v3.0	84
Tabela 7	– Métricas de desempenho — SentiLex-PT	84
Tabela 8	– Matriz de confusão — SentiLex-PT	84
Tabela 9	– Métricas de desempenho — FinBERT-PT-BR	85
Tabela 10	– Matriz de confusão — FinBERT-PT-BR	85
Tabela 11	– Métricas de desempenho — BERTimbau ajustado	86
Tabela 12	– Matriz de confusão — BERTimbau ajustado	87
Tabela 13	– Comparativo de desempenho entre as abordagens	87
Tabela 14	– Precisão e revocação por classe	88

LISTA DE QUADROS

Quadro 1 – Síntese da caracterização metodológica da pesquisa	48
Quadro 2 – Parâmetros utilizados nas requisições ao <i>endpoint</i> <code>GET /2/users/{id}/tweets</code>	51
Quadro 3 – Estrutura das tabelas do banco de dados PostgreSQL	53
Quadro 4 – Distribuição do corpus por veículo monitorado	58
Quadro 5 – Distribuição mensal das publicações por veículo	59
Quadro 6 – Completude dos campos coletados via API	59
Quadro 7 – Estatísticas descritivas do comprimento das publicações do corpus	60
Quadro 8 – Exemplo de aplicação da função <code>clean()</code> a uma publicação do corpus	64
Quadro 9 – Comparativo entre os fluxos de pré-processamento aplicados às três abordagens de classificação	65
Quadro 10 – Principais bibliotecas Python utilizadas no <i>pipeline</i> e respectivas funções	77
Quadro 11 – Hiperparâmetros do fine-tuning do BERTimbau	82
Quadro 12 – Principais dependências do ambiente de execução	83

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
abnTeX	ABsurdas Normas para TeX
IBGE	Instituto Brasileiro de Geografia e Estatística
LaTeX	Lamport TeX
USP	Universidade de São Paulo
USPSC	Campus USP de São Carlos

SUMÁRIO

1	INTRODUÇÃO	23
1.1	Problema	23
1.2	Justificativa	24
1.3	Objetivos	24
1.3.1	Objetivo Geral	24
1.3.2	Objetivos Específicos	25
1.4	Delimitação do Escopo	25
1.5	Estrutura do Trabalho	25
2	FUNDAMENTAÇÃO TEÓRICA	27
2.1	Mercado Financeiro Brasileiro	27
2.1.1	Hipótese de Mercados Eficientes e Hipótese de Mercados Adaptativos	27
2.2	Big Data e Mídias Sociais em Finanças	28
2.2.1	Características de Big Data (Volume, Velocidade, Variedade)	28
2.2.2	X/Twitter como Fonte de Dados Financeiros	30
2.2.3	Desafios de Processamento de Dados Textuais Massivos	32
2.3	Processamento de Linguagem Natural	34
2.3.1	Conceitos Fundamentais e Paradigmas	34
2.3.2	Pipeline de Processamento Textual	35
2.3.3	Modelos de Linguagem e Transformers	37
2.4	Análise de Sentimento	38
2.4.1	Tarefas e Níveis de Análise	38
2.4.2	Abordagens Metodológicas	39
2.4.3	Análise de Sentimento no Domínio Financeiro em Português	40
2.5	Trabalhos Relacionados	41
2.5.1	Trabalhos Internacionais	41
2.5.2	Trabalhos Nacionais	42
2.5.3	Síntese Comparativa e Posicionamento do Presente Trabalho	44
3	METODOLOGIA	47
3.1	Caracterização da Pesquisa	47
3.2	Fonte de Dados e Processo de Coleta	48
3.2.1	Justificativa da Escolha do X/Twitter como Fonte	48
3.2.2	Veículos Selecionados	49
3.2.3	Período de Análise	49
3.2.4	Processo de Coleta via API	50

3.2.4.1	<i>Endpoint</i> Utilizado e Autenticação	50
3.2.4.2	Parâmetros da Requisição	50
3.2.4.3	<i>Pipeline</i> de Coleta e Armazenamento	51
3.3	Rotulagem Manual do Corpus	52
3.3.1	Protocolo de Anotação em Duas Etapas	54
3.3.2	Ferramenta de Anotação	54
3.3.3	Armazenamento das Anotações	55
3.3.4	Particionamento do Corpus Rotulado para Treinamento e Avaliação	56
3.3.5	Limitações do Processo de Rotulagem	57
3.4	Análise Exploratória dos Dados	57
3.4.1	Dimensões do Corpus e Distribuição por Veículo	58
3.4.2	Compleitude dos Campos	59
3.4.3	Distribuição do Comprimento dos Textos	60
3.4.4	Detecção e Tratamento de Duplicatas	61
3.5	Pré-processamento Textual	62
3.5.1	Fluxo Completo — Abordagem Léxica	62
3.5.1.1	Substituição de URLs	62
3.5.1.2	Conversão de Emojis para <i>Name Codes</i>	63
3.5.1.3	Substituição de Menções	63
3.5.1.4	Remoção do Símbolo de <i>Hashtag</i>	63
3.5.1.5	Normalização de Espaçamento	63
3.5.1.6	Normalização de Caixa com Preservação de Entidades	63
3.5.1.7	Remoção de <i>Stopwords</i>	63
3.5.1.8	Lematização	64
3.5.2	Fluxo Reduzido — FinBERT-PT-BR	64
3.5.3	Fluxo Reduzido — BERTimbau Ajustado	64
3.5.4	Testes Unitários	65
3.6	Abordagens de Classificação de Sentimento	66
3.6.1	Abordagem Baseada em Léxico: OpLexicon	66
3.6.1.1	Escolha do Recurso Léxico	66
3.6.1.2	Estrutura do Léxico	67
3.6.1.3	Implementação e Protocolo de Pontuação	67
3.6.2	Abordagem Baseada em Léxico: SentiLex-PT	68
3.6.2.1	Fundamentação da Escolha	68
3.6.2.2	Estrutura do Léxico	68
3.6.2.3	Implementação e Protocolo de Pontuação	69
3.6.3	Abordagem Baseada em Modelo de Linguagem Pré-treinado: FinBERT-PT-BR	70
3.6.3.1	Fundamentação da Escolha	70
3.6.3.2	Arquitetura do Modelo	71

3.6.3.3	Implementação e Protocolo de Inferência	71
3.6.4	Abordagem Baseada em Modelo de Linguagem Pré-treinado com <i>Fine-tuning</i> : BERTimbau	72
3.6.4.1	Fundamentação da Escolha	72
3.6.4.2	Arquitetura e Protocolo de <i>Fine-tuning</i>	73
3.6.4.3	Implementação e Protocolo de Inferência	74
3.6.5	Métricas de Avaliação das Abordagens	75
3.7	<i>Pipeline</i> Integrado de PLN	75
3.7.1	Visão Geral do <i>Pipeline</i>	76
3.7.2	Ambiente de Execução e Ferramentas	77
3.8	Limitações da Pesquisa	77
3.8.1	Limitações Relativas à Fonte e ao Período de Dados	78
3.8.2	Limitações Relativas à Representatividade do Corpus	78
3.8.3	Limitações Relativas aos Modelos Pré-treinados	78
3.8.4	Limitações de Escopo Analítico	80
4	AVALIAÇÃO EXPERIMENTAL	81
4.1	Configuração Experimental	81
4.1.1	Conjunto de Teste	81
4.1.2	Protocolo de Avaliação	82
4.1.3	Configuração do Fine-Tuning do BERTimbau	82
4.1.4	Ambiente Computacional	83
4.2	Resultados por Abordagem	83
4.2.1	OpLexicon v3.0	83
4.2.2	SentiLex-PT	84
4.2.3	FinBERT-PT-BR	85
4.2.4	BERTimbau Ajustado	86
4.3	Análise Comparativa	87
4.3.1	Hierarquia de Desempenho	87
4.3.2	Desempenho nas Classes Minoritárias	88
4.3.3	Viés de Classe Neutra	89
4.4	Discussão	89
4.4.1	Especialização Prévia versus Ajuste Local ao Gênero	89
4.4.2	Diagnóstico do Viés do FinBERT-PT-BR	89
4.4.3	Limitações das Abordagens Léxicas em Corpus de Tweet	90
4.4.4	Restrições à Generalização dos Resultados	90
5	CONCLUSÕES	93
	REFERÊNCIAS	95

1 INTRODUÇÃO

O mercado financeiro é intrinsecamente volátil, impulsionado não apenas por fundamentos econômicos, mas também por eventos políticos, macroeconômicos, regulatórios e pela percepção coletiva (sentimento) disseminada em dados não estruturados massivos, como notícias de imprensa e mídias sociais.

Embora a relação entre divulgação de resultados corporativos, indicadores macroeconômicos e movimentação de preços seja amplamente documentada, a influência do sentimento público capturado em notícias e mídias sociais sobre o comportamento dos ativos permanece menos compreendida e quantificada. O volume massivo e a alta velocidade (*volume e velocity*) de geração desses dados textuais não estruturados configuram um desafio típico de *Big Data*, excedendo a capacidade de análise humana em tempo real e criando assimetrias informacionais no mercado.

Estudos empíricos demonstram que termos com conotação de incerteza nas edições diárias do jornal Valor Econômico apresentam associação negativa estatisticamente significativa com o retorno diário do Ibovespa, enquanto palavras com tom negativo correlacionam-se positivamente com o aumento da volatilidade do índice (Galdi; Gonçalves, 2018), evidenciando o impacto quantificável do sentimento noticioso sobre a dinâmica de preços no mercado brasileiro.

1.1 Problema

Nesse contexto, emerge a seguinte questão de pesquisa: como estruturar e quantificar, em escala, a polaridade e o conteúdo semântico de publicações financeiras no X/Twitter para caracterizar o sentimento do mercado brasileiro?

Estudos internacionais já demonstraram que o sentimento expresso em mídias sociais mantém relação mensurável com o comportamento do mercado financeiro - Bollen, Mao e Zeng (2011), por exemplo, identificaram associação estatisticamente significativa entre o humor coletivo expresso no Twitter e as variações do mercado de ações norte-americano. No entanto, análises robustas e validadas dessa relação para o mercado brasileiro ainda são escassas. As particularidades linguísticas do português brasileiro, a estrutura diferenciada do mercado de capitais nacional e a limitada disponibilidade de datasets rotulados de qualidade representam desafios específicos que dificultam a transferência direta de soluções desenvolvidas para outros contextos (Santos; Bianchi; Costa, 2023).

A literatura nacional acerca do sentimento do investidor no mercado brasileiro permanece incipiente (Galdi; Gonçalves, 2018), com poucos trabalhos dedicados à construção de modelos de PLN específicos para o domínio financeiro em português. Iniciativas

recentes, como o desenvolvimento do FinBERT-PT-BR (Santos; Bianchi; Costa, 2023), representam avanços importantes ao treinar modelos baseados na arquitetura BERT com 1,4 milhão de textos financeiros em português, porém ainda enfrentam limitações quanto ao tamanho das bases de dados rotuladas (apenas 503 textos anotados manualmente).

1.2 Justificativa

A literatura nacional sobre análise de sentimento aplicada ao mercado financeiro permanece incipiente (Galdi; Gonçalves, 2018), com poucos trabalhos dedicados ao desenvolvimento de ferramentas de PLN específicas para o domínio financeiro em português brasileiro. Essa lacuna é agravada pela limitada disponibilidade de datasets rotulados de qualidade, pelas particularidades linguísticas do português e pela estrutura diferenciada do mercado de capitais nacional, fatores que dificultam a simples transposição de soluções consolidadas em outros idiomas e mercados (Santos; Bianchi; Costa, 2023).

Iniciativas recentes, como o FinBERT-PT-BR (Santos; Bianchi; Costa, 2023), representam avanços relevantes, porém ainda enfrentam restrições quanto ao tamanho das bases de dados anotadas manualmente e à ausência de pipelines reproduzíveis que integrem coleta, pré-processamento e classificação de sentimento em um fluxo estruturado. O presente trabalho busca contribuir nessa direção, ao propor e documentar um pipeline de PLN de ponta a ponta voltado ao contexto financeiro brasileiro, oferecendo à comunidade acadêmica um protocolo metodológico replicável e passível de extensão em pesquisas futuras.

Do ponto de vista prático, a capacidade de monitorar e quantificar o sentimento disseminado em publicações de veículos especializados em tempo quase real representa um recurso relevante para analistas e gestores que buscam incorporar informações não estruturadas à sua leitura de mercado. A automação desse processo por meio de técnicas de aprendizado de máquina supera a limitação humana de processar grandes volumes de dados textuais com alta velocidade, reduzindo assimetrias informacionais e ampliando a qualidade da análise qualitativa do ambiente econômico.

1.3 Objetivos

1.3.1 Objetivo Geral

Desenvolver e validar pipeline de Processamento de Linguagem Natural (PLN) para análise de sentimento de publicações financeiras no X/Twitter, caracterizando padrões temporais e semânticos do discurso financeiro brasileiro.

1.3.2 Objetivos Específicos

1. Coletar e estruturar um dataset de publicações do X/Twitter dos veículos InfoMoney e Exame, abrangendo o período de outubro de 2025 a fevereiro de 2026;
2. Realizar Análise Exploratória dos Dados (AED) e aplicar técnicas de pré-processamento para detecção e remoção de dados redundantes e valores atípicos (*outliers*);
3. Desenvolver um pipeline de pré-processamento e análise de sentimento baseado em PLN para classificação da polaridade dos textos coletados;
4. Avaliar e comparar o desempenho de diferentes abordagens de classificação de sentimento - baseadas em léxico e em modelos de linguagem pré-treinados - no domínio financeiro em português brasileiro;
5. Caracterizar descritivamente o dataset resultante, identificando a distribuição de polaridade e os padrões semânticos predominantes no discurso financeiro dos veículos analisados.

1.4 Delimitação do Escopo

Como *proxy* para captura de sentimento de mercado, serão utilizadas publicações da rede social X (anteriormente Twitter) de veículos especializados em economia e finanças: InfoMoney e Exame. O período de análise compreenderá publicações entre 10 de outubro de 2025 e 6 de fevereiro de 2026, totalizando aproximadamente quatro meses de dados.

A delimitação desse recorte temporal decorre de um conjunto de restrições metodológicas e operacionais: (i) o acesso à API do X/Twitter está condicionado a planos comerciais com janelas históricas limitadas, inviabilizando a coleta retroativa de grandes volumes de dados sem custos elevados; e (ii) o custo de acesso a planos de API com maior capacidade de recuperação histórica representa uma barreira concreta para pesquisas acadêmicas sem financiamento dedicado. Reconhece-se que esse recorte constitui uma limitação do estudo, cujos impactos serão discutidos no Capítulo 5.

A escolha por posts em detrimento de artigos completos fundamenta-se em aspectos metodológicos: (i) maior facilidade de extração estruturada de dados via API, dispensando técnicas complexas de *web scraping*; e (ii) formato textual conciso e objetivo, mais adequado para análise de polaridade semântica.

1.5 Estrutura do Trabalho

Este trabalho está organizado em cinco capítulos. O Capítulo 1 apresenta a contextualização do problema, a questão de pesquisa, a identificação do gap na literatura nacional, a justificativa e os objetivos geral e específicos da pesquisa.

O Capítulo 2 apresenta a revisão de literatura, abordando os fundamentos de Processamento de Linguagem Natural (PLN), as principais abordagens de análise de sentimento aplicadas ao mercado financeiro e os trabalhos relevantes desenvolvidos para o contexto brasileiro e para a língua portuguesa.

O Capítulo 3 descreve em detalhes a metodologia proposta, incluindo: o processo de coleta de dados via API do X/Twitter; a análise exploratória e o tratamento do dataset; e o pipeline de PLN para extração de features semânticas e classificação de polaridade dos textos coletados.

O Capítulo 4 apresenta os resultados da análise de sentimento realizada, incluindo a caracterização descritiva do dataset, os padrões temporais e semânticos identificados no discurso financeiro dos veículos analisados e a discussão dos achados à luz da literatura.

Por fim, o Capítulo 5 sintetiza as principais conclusões do trabalho, discute as contribuições científicas e práticas da pesquisa, apresenta as limitações encontradas e sugere direcionamentos para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta o referencial teórico que sustenta o presente trabalho. A construção do arcabouço conceitual parte da teoria de mercados financeiros — em especial da Hipótese de Mercados Adaptativos (Lo, 2004), que reconhece o papel das emoções e dos comportamentos coletivos na formação dos preços — e avança pelas bases técnicas que viabilizam a análise proposta: o fenômeno do *Big Data* e a emergência das mídias sociais como fonte de dados financeiros (Laney, 2001; Bollen; Mao; Zeng, 2011), os fundamentos do Processamento de Linguagem Natural (Caseli; Nunes; Pagano, 2024; Jurafsky; Martin, 2026) e as abordagens metodológicas da Análise de Sentimento aplicadas ao domínio financeiro em língua portuguesa (Kearney; Liu, 2014; Santos; Bianchi; Costa, 2023). O capítulo encerra com uma revisão dos principais trabalhos relacionados, situando esta pesquisa na literatura nacional e internacional da área.

2.1 Mercado Financeiro Brasileiro

O mercado financeiro brasileiro é organizado em torno da B3 (Brasil, Bolsa, Balcão), que concentra a negociação de ações, derivativos, títulos de renda fixa e câmbio em uma única infraestrutura integrada. Em termos de capitalização e liquidez, a B3 figura entre as principais bolsas de valores da América Latina, sendo amplamente utilizada como referência para estudos empíricos sobre o comportamento de ativos em mercados emergentes (Jr., 1994; Yoshinaga; Castro, 2012). A dinâmica desse mercado é influenciada por um conjunto heterogêneo de fatores — fundamentos macroeconômicos, decisões de política monetária, eventos políticos e, crescentemente, o fluxo contínuo de informações e opiniões veiculadas por meios digitais — o que torna a análise de sentimento uma ferramenta potencialmente relevante para compreender os movimentos coletivos dos investidores.

2.1.1 Hipótese de Mercados Eficientes e Hipótese de Mercados Adaptativos

A Hipótese de Mercados Eficientes (HME), formulada por Fama (1970) e consolidada em sua versão revisada por Fama (1991), postula que os preços dos ativos financeiros refletem, a qualquer momento, toda a informação disponível relevante. Em sua forma semiforte, a HME implica que nenhuma análise de informações públicas — incluindo notícias, relatórios ou declarações de agentes econômicos — seria capaz de gerar retornos sistematicamente superiores ao mercado, uma vez que essas informações já estariam incorporadas aos preços de forma quase instantânea (Fama, 1970; Grossman; Stiglitz, 1980).

A HME, contudo, foi progressivamente desafiada por evidências empíricas de anomalias de mercado — como sobrereação e subreação a eventos, efeito momentum e

reversão à média — que não se encaixam no paradigma de plena eficiência informacional (Jr., 1994). No contexto brasileiro, Jr. (1994) documentaram evidências de sobrereação no mercado acionário nacional, sugerindo que investidores locais respondem de forma excessiva a notícias recentes, padrão consistente com a influência de fatores comportamentais e emocionais nas decisões de investimento.

Em resposta a essas limitações, Lo (2004, 2005) propôs a Hipótese de Mercados Adaptativos (HMA), que reinterpreta a eficiência de mercado sob uma perspectiva evolucionária. Segundo a HMA, os agentes financeiros não são racionais no sentido neoclássico estrito, mas adaptam seu comportamento continuamente em resposta ao ambiente de mercado, incorporando heurísticas, emoções e aprendizado social em suas decisões (Lo, 2004). Essa perspectiva é particularmente relevante para o presente trabalho: se os preços dos ativos refletem não apenas informações objetivas, mas também o estado emocional e as expectativas coletivas dos agentes — conforme previsto pela HMA — então o sentimento expresso em publicações do X/Twitter constitui um sinal informacional potencialmente relevante para compreender o humor do mercado financeiro brasileiro (Lo, 2004; Bollen; Mao; Zeng, 2011; Santos; Bianchi; Costa, 2023). Não por acaso, Santos; Bianchi; Costa (2023) invocam explicitamente a HMA como fundamento teórico do FinBERT-PT-BR, situando a análise de sentimento como ferramenta de captura das “emoções refletidas nos textos” que influenciam as decisões dos agentes no mercado adaptativo.

2.2 Big Data e Mídias Sociais em Finanças

A expansão das plataformas digitais nas últimas duas décadas transformou profundamente a natureza dos dados disponíveis para a pesquisa em finanças. Se, historicamente, os estudos empíricos dependiam de séries temporais de preços, volumes e indicadores contábeis gerados em ciclos regulares, a consolidação das mídias sociais e dos ambientes de comunicação em tempo real produziu um novo tipo de dado — massivo, contínuo, heterogêneo e predominantemente textual — cujo potencial informacional para a compreensão do comportamento dos mercados ainda está sendo explorado (Kearney; Liu, 2014; Mayer-Schönberger; Cukier, 2013). Esta seção caracteriza esse fenômeno sob o conceito de *Big Data*, examina o papel específico do X/Twitter como fonte de dados financeiros e discute os principais desafios metodológicos que emergem do processamento de grandes volumes de texto financeiro em língua portuguesa.

2.2.1 Características de Big Data (Volume, Velocidade, Variedade)

O termo *Big Data* ganhou relevância científica e empresarial a partir do trabalho de Laney (2001), analista do META Group, que identificou três dimensões fundamentais impulsionadas pela explosão do comércio eletrônico no início dos anos 2000: **volume**, **velocidade** e **variedade** - o chamado modelo dos “3 Vs”. Embora o conceito tenha

evoluído desde então, incorporando dimensões adicionais como veracidade e valor (Mayer-Schönberger; Cukier, 2013; Chen; Mao; Liu, 2014), os três eixos originais continuam sendo a base conceitual mais adotada na literatura para caracterizar fenômenos de dados em larga escala.

De maneira geral, *Big Data* pode ser definido como a capacidade de coletar, armazenar e analisar conjuntos de dados cujo tamanho, ritmo de geração ou complexidade superam as capacidades dos sistemas gerenciadores de banco de dados relacionais (RDBMS) e das arquiteturas convencionais de *data warehouse*, projetados para dados estruturados em volumes previsíveis e processamento em lote (Mayer-Schönberger; Cukier, 2013; Chen; Mao; Liu, 2014). Para Chen; Mao; Liu (2014), essa definição é operacionalizada precisamente por meio dos “3 Vs”, que descrevem, respectivamente, a magnitude dos dados produzidos, a rapidez com que precisam ser processados e a heterogeneidade dos formatos em que se apresentam.

Volume refere-se à quantidade absoluta de dados gerados, armazenados e processados. O crescimento exponencial da produção digital — impulsionado por dispositivos conectados, plataformas de mídias sociais, sensores e transações eletrônicas — fez com que a escala de dados relevantes passasse de gigabytes para terabytes e, atualmente, para petabytes e exabytes (Mayer-Schönberger; Cukier, 2013). No contexto financeiro, essa dimensão se manifesta, por exemplo, no volume de ordens de compra e venda negociadas eletronicamente em bolsas de valores, nos registros de operações de alta frequência (*high-frequency trading*) e nas centenas de milhões de publicações diárias em plataformas digitais que tangenciam temas econômicos e financeiros (Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015).

Velocidade diz respeito ao ritmo de geração e à necessidade de processamento dos dados em tempo real ou quase real (Laney, 2001). Em mercados financeiros, a velocidade é uma dimensão especialmente crítica: informações sobre eventos macroeconômicos, decisões de bancos centrais ou crises corporativas se propagam em milissegundos por redes digitais globais, alterando o comportamento dos investidores e os preços dos ativos antes mesmo que analistas humanos possam interpretar os eventos e antes que sistemas convencionais de processamento em lote (*batch processing*) concluam seus ciclos de atualização (Chen; Mao; Liu, 2014). Plataformas como o X (antigo Twitter) exemplificam essa dimensão ao produzirem fluxos contínuos de publicações que, conforme demonstrado por Bollen; Mao; Zeng (2011), carregam informações sobre o humor coletivo capazes de antecipar movimentos no índice Dow Jones Industrial Average (DJIA). A análise em tempo real desses fluxos exige infraestrutura computacional capaz de ingerir e processar *streams* de dados de maneira contínua, o que distingue esses sistemas das abordagens convencionais de processamento em lote (*batch processing*).

Variedade refere-se à diversidade de formatos, estruturas e fontes dos dados

disponíveis. Enquanto sistemas de informação tradicionais lidam predominantemente com dados estruturados — organizados em tabelas com campos e tipos definidos — o ecossistema digital contemporâneo produz volumes massivos de dados semiestruturados (como arquivos JSON e XML) e não estruturados (como textos livres, imagens, vídeos e publicações em redes sociais) (Laney, 2001; Mayer-Schönberger; Cukier, 2013). No domínio financeiro, essa variedade é particularmente desafiadora: análises quantitativas baseadas em séries temporais de preços e volumes coexistem com informações qualitativas extraídas de notícias, relatórios corporativos, comunicados de política monetária e conversações em plataformas de mídias sociais (Kearney; Liu, 2014). Integrar essas fontes heterogêneas em modelos preditivos unificados constitui um dos principais desafios metodológicos do campo, como discutido nas seções subsequentes deste trabalho.

Além dos três eixos originais, a literatura recente tem proposto extensões ao modelo. A dimensão de **veracidade** aborda a incerteza inerente à qualidade e à confiabilidade dos dados, tema especialmente relevante em ambientes de mídias sociais, onde informações falsas, rumores e ruído informacional se misturam a sinais genuínos (Chen; Mao; Liu, 2014). A dimensão de **valor** ressalta que o simples acúmulo de dados não produz *insights* por si só: é necessário transformá-los em conhecimento acionável por meio de técnicas analíticas adequadas (Mayer-Schönberger; Cukier, 2013). No contexto desta dissertação, ambas as dimensões são diretamente relevantes, pois a extração de sinais de sentimento de textos financeiros em língua portuguesa demanda tanto mecanismos de filtragem de ruído quanto abordagens analíticas especializadas capazes de produzir um índice de sentimento coerente e interpretável.

A emergência do *Big Data* redefiniu a fronteira do que é computacionalmente viável na pesquisa em finanças comportamentais. Se, por décadas, a análise empírica em finanças esteve restrita a dados estruturados de alta precisão — preços, volumes, indicadores contábeis — a disponibilidade de conjuntos massivos de dados textuais abriu uma nova agenda de pesquisa centrada na extração automatizada de sentimento a partir de fontes digitais (Kearney; Liu, 2014; Antweiler; Frank, 2004). É nesse contexto que se insere o presente trabalho: a interseção entre o volume, a velocidade e a variedade característicos das publicações financeiras no X/Twitter e as técnicas de Processamento de Linguagem Natural (PLN) discutidas no Capítulo 2, especialmente os modelos baseados em *transformers* adaptados ao domínio financeiro em língua portuguesa.

2.2.2 X/Twitter como Fonte de Dados Financeiros

A utilização de plataformas digitais de comunicação como fonte de dados para análise de mercados financeiros precede o surgimento do X/Twitter. O trabalho pioneiro de Antweiler; Frank (2004) demonstrou que mensagens publicadas em fóruns de discussão financeira — especificamente no Yahoo Finance e no Raging Bull — continham informação

relevante sobre o comportamento futuro dos preços de ações. Analisando aproximadamente 1,5 milhão de mensagens relativas a 45 empresas listadas no Dow Jones Industrial Average e no Dow Jones Internet Index entre 1999 e 2001, os autores encontraram evidências de que o volume de mensagens ajudava a prever a volatilidade do mercado, ao passo que o conteúdo dessas mensagens apresentava relação estatisticamente significativa com retornos subsequentes. Embora o efeito sobre retornos fosse economicamente modesto, o estudo estabeleceu o precedente metodológico central para a área: textos gerados por usuários em plataformas digitais carregam conteúdo informacional com implicações para a dinâmica dos preços de ativos.

A ascensão do X/Twitter — plataforma lançada em 2006 e que rapidamente se tornou um dos principais canais de comunicação em tempo real no mundo — deslocou o foco da pesquisa dos fóruns especializados para as redes sociais de uso geral. A arquitetura da plataforma, baseada em publicações curtas (*tweets*) de até 280 caracteres, cronológicas e públicas, criou um ambiente propício à disseminação veloz de informações financeiras, opiniões de mercado e reações a eventos econômicos (Sprenger *et al.*, 2014). Diferentemente dos fóruns de investidores, o X/Twitter agrega uma audiência heterogênea — analistas institucionais, investidores individuais, jornalistas e o público geral — o que amplia tanto o volume de dados disponíveis quanto a diversidade de perspectivas capturadas (Mao; Counts; Bollen, 2011).

O marco central para a consolidação do X/Twitter como objeto de pesquisa em finanças foi o estudo de Bollen; Mao; Zeng (2011). Os autores analisaram o conteúdo emocional de cerca de 9,7 milhões de *tweets* publicados entre abril e dezembro de 2008, aplicando duas ferramentas de análise de humor: o OpinionFinder, que mede valência positiva e negativa, e o GPOMS (*Google-Profile of Mood States*), que decompõe o estado de humor coletivo em seis dimensões — Calma, Alerta, Certeza, Vitalidade, Gentileza e Felicidade. Por meio de análise de causalidade de Granger e de uma rede neural *fuzzy* auto-organizável, os autores demonstraram que a dimensão “Calma” do GPOMS apresentava causalidade preditiva sobre os valores de fechamento do DJIA com defasagem de dois a seis dias, alcançando acurácia de 87,6% na previsão de movimentos diários de alta e baixa do índice. Esse resultado forneceu evidência empírica robusta de que o humor coletivo expresso em mídias sociais contém informação antecipatória sobre o comportamento do mercado, conectando a hipótese de influência do sentimento do investidor (Baker; Wurgler, 2007) ao ambiente digital das redes sociais.

Estudos posteriores ampliaram e refinaram essa linha de investigação. Sprenger *et al.* (2014) examinaram especificamente *tweets* com conteúdo financeiro — identificados pelo uso de *cashtags* (símbolo \$ seguido do *ticker* da ação) — e encontraram que tanto o sentimento quanto o volume de publicações relacionadas a uma empresa eram preditivos de retornos e volume de negociação nos dias subsequentes, com efeito mais pronunciado

para ações de menor capitalização. Mao; Counts; Bollen (2011), por sua vez, compararam o poder preditivo de *tweets* financeiros com o de buscas no Google Trends, concluindo que a combinação das duas fontes superava qualquer uma isoladamente na previsão de retornos do S&P 500. Já Ranco *et al.* (2015) investigaram a relação entre o volume e o sentimento de *tweets* e os retornos das 30 empresas componentes do DJIA, identificando que o impacto do sentimento no Twitter é especialmente significativo nos dias que antecedem e sucedem eventos corporativos relevantes, como divulgação de resultados e anúncios de fusões.

No contexto brasileiro, a adoção do X/Twitter como fonte de dados financeiros apresenta particularidades relevantes para o presente trabalho. O Brasil figura historicamente entre os países com maior base de usuários da plataforma na América Latina, o que garante um volume substancial de publicações em língua portuguesa com conteúdo relacionado ao mercado financeiro e aos índices da B3. Contudo, a predominância de modelos de análise de sentimento treinados em inglês cria uma lacuna metodológica significativa: léxicos e modelos desenvolvidos para o inglês financeiro — como o dicionário de Loughran; McDonald (2011) — não capturam adequadamente as nuances semânticas e o vocabulário específico do mercado financeiro brasileiro, demandando o desenvolvimento ou adaptação de ferramentas especializadas para o português (Santos; Bianchi; Costa, 2023). É precisamente essa lacuna que motiva a adoção do modelo FinBERT-PT-BR como ferramenta central de análise de sentimento neste trabalho, conforme detalhado na Seção 2.4.

2.2.3 Desafios de Processamento de Dados Textuais Massivos

A disponibilidade de grandes volumes de dados textuais provenientes de plataformas digitais não implica, por si só, a capacidade de extrair deles informação financeiramente relevante. Entre a coleta bruta de publicações e a geração de sinais de sentimento interpretáveis residem desafios técnicos e linguísticos substanciais, cuja superação constitui um dos problemas centrais da área (Kearney; Liu, 2014). Esses desafios podem ser agrupados em quatro dimensões interdependentes: ruído e qualidade dos dados, especificidade do vocabulário financeiro, escassez de recursos para línguas não inglesas e limitações das abordagens de análise disponíveis.

O primeiro e mais imediato desafio é a razão sinal-ruído característica das mídias sociais. Em plataformas como o X/Twitter, apenas uma fração das publicações que mencionam termos financeiros carrega informação genuinamente relevante para o comportamento dos ativos (Bollen; Mao; Zeng, 2011). O restante é composto por ruído informacional de diversas naturezas: *spam* automatizado, publicações de robôs (*bots*), comentários irônicos ou sarcásticos cuja polaridade real é oposta à aparente, e menções ambíguas em que o mesmo termo assume sentidos distintos conforme o contexto. A ironia e o sarcasmo são particularmente problemáticos para sistemas de análise de sentimento baseados em léxicos,

pois invertem a valência das palavras sem alterá-las formalmente (Liu; Zheng; Song, 2020). Além disso, a linguagem informal predominante nas redes sociais — repleta de abreviações, neologismos, emojis e erros ortográficos — exige etapas de pré-processamento robustas que normalizem o texto antes de qualquer análise semântica (Sousa *et al.*, 2025).

O segundo desafio diz respeito à especificidade do vocabulário financeiro. Um dos achados mais influentes nessa área foi demonstrado por Loughran; McDonald (2011), ao analisar a aplicação do dicionário Harvard General Inquirer — léxico de propósito geral amplamente utilizado em ciências sociais — a relatórios anuais de empresas (formulários 10-K). Os autores identificaram que aproximadamente três quartos das palavras classificadas como negativas por esse dicionário não carregavam conotação negativa no contexto financeiro: termos como “*liability*”, “*tax*” e “*depreciation*” são tecnicamente neutros ou simplesmente descritivos no vocabulário contábil-financeiro, mas aparecem como negativos em léxicos de uso geral. Essa discrepância motivou o desenvolvimento do dicionário Loughran-McDonald, específico para o domínio financeiro em inglês, e evidenciou que a transferência direta de ferramentas de PLN de propósito geral para o domínio financeiro produz resultados sistematicamente distorcidos (Loughran; McDonald, 2011; Kearney; Liu, 2014).

No contexto brasileiro, essa limitação se desdobra em uma terceira dimensão: a escassez de recursos linguísticos especializados para o português financeiro. Enquanto o inglês dispõe de léxicos validados (Loughran; McDonald, 2011), corpora anotados e modelos de linguagem pré-treinados em grandes volumes de texto financeiro, o português — e em particular o vocabulário do mercado financeiro brasileiro — permanece subrepresentado nos recursos disponíveis (Sousa *et al.*, 2025). Os estudos aplicados ao mercado brasileiro têm documentado sistematicamente essa lacuna: Falcão (2020), ao analisar notícias do Valor Econômico e da Folha de São Paulo entre 2013 e 2019 e relacioná-las ao comportamento do Ibovespa, e Lucas; Peixoto (2025), ao aplicar os léxicos VADER e HIV a notícias do mercado brasileiro coletadas via Google News API, constataram que dicionários desenvolvidos para o inglês capturam apenas parcialmente a variância dos índices brasileiros, com o percentual explicado pelos léxicos genéricos permanecendo relativamente baixo. A necessidade de recursos especializados para o português financeiro motivou iniciativas como a expansão automática de léxicos por técnicas de Word2Vec e Informação Mútua Pontual (PMI) (Sousa *et al.*, 2025) e, mais recentemente, o desenvolvimento do modelo FinBERT-PT-BR, treinado sobre 1,4 milhão de textos financeiros em português (Santos; Bianchi; Costa, 2023).

O quarto desafio refere-se às limitações inerentes às abordagens disponíveis para processamento em escala. As duas grandes famílias de métodos — abordagens baseadas em léxicos e abordagens baseadas em aprendizado de máquina — apresentam compromissos distintos entre interpretabilidade, custo computacional e desempenho (Kearney; Liu,

2014). Abordagens léxicas são transparentes e dispensam dados rotulados, mas falham diante de ironia, negação e vocabulário não coberto pelo léxico. Abordagens baseadas em aprendizado de máquina — especialmente modelos profundos baseados em *transformers* — alcançam desempenho superior, mas exigem grandes volumes de dados anotados, que são escassos no domínio financeiro em português (Liu; Zheng; Song, 2020; Santos; Bianchi; Costa, 2023). Além disso, o processamento de fluxos contínuos de *tweets* em tempo real impõe restrições de latência que podem inviabilizar modelos computacionalmente custosos sem infraestrutura adequada (Silva *et al.*, 2025). A superação desse conjunto de desafios demanda, portanto, não apenas avanços algorítmicos, mas também a construção cumulativa de recursos linguísticos e computacionais específicos para o domínio financeiro em português, agenda à qual o presente trabalho busca contribuir por meio da adoção e avaliação do FinBERT-PT-BR aplicado às publicações do X/Twitter.

2.3 Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) é o campo de pesquisa que investiga e propõe métodos e sistemas para o tratamento computacional da linguagem humana (Caseli; Nunes; Pagano, 2024). Situado na interseção entre a Ciência da Computação, a Inteligência Artificial e a Linguística, o PLN abrange desde tarefas de baixo nível — como segmentação de texto em palavras e identificação de classes gramaticais — até tarefas de alta complexidade semântica, como tradução automática, resposta a perguntas e análise de sentimento (Jurafsky; Martin, 2026). Para os fins deste trabalho, o PLN constitui o conjunto de técnicas que viabiliza a extração automatizada de sentimento a partir de publicações textuais do X/Twitter relacionadas ao mercado financeiro brasileiro, transformando dados não estruturados em classificações de polaridade que expressam o humor coletivo dos investidores.

2.3.1 Conceitos Fundamentais e Paradigmas

A linguagem natural apresenta desafios computacionais que a distinguem fundamentalmente de outros tipos de dados: é ambígua, dependente de contexto, culturalmente situada e semanticamente densa (Caseli; Nunes; Pagano, 2024). Uma mesma sequência de palavras pode admitir interpretações radicalmente distintas conforme o contexto discursivo em que é produzida, e o significado de uma expressão frequentemente depende de conhecimento de mundo que não está explicitamente codificado no texto. Essas propriedades fazem com que o processamento completo e adequado da língua continue sendo um dos problemas abertos mais desafiadores da Inteligência Artificial (Caseli; Nunes; Pagano, 2024; Jurafsky; Martin, 2026).

Ao longo de sua história, o PLN organizou-se em torno de três grandes paradigmas (Caseli; Nunes; Pagano, 2024). O **paradigma simbólico**, dominante até a década de 1980,

representa o conhecimento linguístico de forma explícita por meio de léxicos, gramáticas e regras lógicas construídas manualmente por especialistas. Embora ofereça alta interpretabilidade e precisão em domínios bem definidos, essa abordagem não escala para a diversidade e a variabilidade da linguagem em uso real. O **paradigma estatístico**, que ganhou proeminência nos anos 1990 com o aumento da capacidade computacional e a disponibilidade de grandes corpora digitais, substituiu as regras explícitas por modelos probabilísticos aprendidos a partir de dados. Fenômenos linguísticos passaram a ser representados em termos de frequências de coocorrência e distribuições condicionais, com destaque para os modelos de *n-gramas* e os classificadores baseados em aprendizado de máquina raso (*shallow learning*) (Jurafsky; Martin, 2026). O **paradigma neural**, que se consolidou a partir de meados dos anos 2010, introduziu arquiteturas de redes neurais profundas capazes de aprender representações distribuídas da língua diretamente a partir de texto bruto, sem a necessidade de engenharia de *features* manual. Esse paradigma atingiu seu apogeu com o desenvolvimento dos modelos de linguagem baseados em *transformers* (Jurafsky; Martin, 2026), que estabeleceram novos estados da arte em praticamente todas as tarefas de PLN e são hoje a base dos sistemas de maior desempenho em análise de sentimento financeiro (Santos; Bianchi; Costa, 2023).

Na prática, aplicações contemporâneas de PLN frequentemente adotam abordagens **híbridas**, combinando o conhecimento explícito do paradigma simbólico — como léxicos especializados de domínio — com a capacidade generalizante dos modelos neurais (Caseli; Nunes; Pagano, 2024; Kearney; Liu, 2014). No domínio financeiro em português, essa hibridização é especialmente relevante dado o vocabulário técnico específico do mercado brasileiro, que pode não estar adequadamente representado em modelos de linguagem treinados em corpora genéricos (Sousa *et al.*, 2025; Santos; Bianchi; Costa, 2023).

2.3.2 Pipeline de Processamento Textual

A extração de informação semântica a partir de textos brutos segue, em geral, um conjunto de etapas encadeadas conhecido como *pipeline* de PLN. Cada etapa transforma a representação do texto, progressivamente reduzindo o ruído e aumentando a estrutura disponível para as etapas subsequentes (Jurafsky; Martin, 2026; Caseli; Nunes; Pagano, 2024). No contexto de análise de sentimento de publicações do X/Twitter, as principais etapas são as seguintes.

A **coleta e armazenamento** constitui o ponto de entrada do *pipeline*. No caso de dados do X/Twitter, isso envolve o acesso à API da plataforma e a estruturação dos dados brutos — que chegam em formato JSON semiestruturado — em um formato adequado para processamento (Freitas, 2024). Metadados como data de publicação, identificador do usuário e métricas de engajamento (*likes*, *retweets*) são preservados para análises subsequentes.

A **tokenização** é o processo de segmentar o texto em unidades mínimas de processamento, denominadas *tokens* (Jurafsky; Martin, 2026). Em textos de redes sociais, a tokenização apresenta desafios particulares: *hashtags*, *cashtags* (e.g., \$PETR4), menções (@usuário), emojis e abreviações informais são elementos que tokenizadores projetados para texto formal tendem a tratar de maneira inadequada. Tokenizadores especializados para o domínio de redes sociais, ou os próprios tokenizadores internos dos modelos *transformer* (baseados em *subword tokenization* como *WordPiece* ou *Byte-Pair Encoding*), são mais adequados para esse tipo de dado (Jurafsky; Martin, 2026; Santos; Bianchi; Costa, 2023).

A **normalização e limpeza** compreende um conjunto de transformações que reduzem a variabilidade superficial do texto sem alterar seu conteúdo semântico relevante. Para textos financeiros do Twitter, isso tipicamente inclui: remoção de URLs, conversão para minúsculas, tratamento de caracteres especiais e normalização de entidades financeiras (*tickers*, siglas de índices). Em abordagens baseadas em léxicos, etapas adicionais como **remoção de palavras funcionais** (*stopwords*), **lematização** — redução de formas flexionadas à forma canônica da palavra — e **stemização** — truncamento do sufixo para obtenção do radical — são aplicadas para reduzir a dimensionalidade do vocabulário (Caseli; Nunes; Pagano, 2024; Sousa *et al.*, 2025). Em modelos *transformer* como o BERT, essas etapas são parcialmente dispensáveis, pois o modelo aprende representações contextualizadas que capturam variações morfológicas automaticamente (Jurafsky; Martin, 2026).

A **representação vetorial** (*embedding*) é a etapa em que o texto processado é convertido em representações numéricas que capturam relações semânticas entre palavras e sentenças (Jurafsky; Martin, 2026). A evolução nessa etapa reflete a progressão dos paradigmas do PLN: das representações esparsas baseadas em frequências (*bag-of-words*, TF-IDF) às representações densas aprendidas por modelos neurais (*word2vec*, GloVe) e, mais recentemente, às representações contextualizadas produzidas por modelos de linguagem de grande escala baseados em *transformers*, em que o vetor de uma palavra é função de todo o contexto em que ela ocorre (Jurafsky; Martin, 2026; Santos; Bianchi; Costa, 2023).

A **classificação ou extração** constitui a etapa final do *pipeline*, em que as representações vetoriais são utilizadas como entrada para modelos que realizam a tarefa de interesse — no caso deste trabalho, a classificação do sentimento de cada publicação em polaridades (positiva, negativa ou neutra) (Claro *et al.*, 2024). A qualidade dessa etapa depende criticamente da adequação das etapas anteriores e da representatividade dos dados de treinamento do modelo em relação ao domínio e à língua-alvo (Kearney; Liu, 2014; Loughran; McDonald, 2011).

2.3.3 Modelos de Linguagem e Transformers

A arquitetura *Transformer*, introduzida por Vaswani *et al.* (2017) no artigo “Attention Is All You Need”, representou uma ruptura fundamental no campo do PLN. Diferentemente das arquiteturas recorrentes (RNN, LSTM) que processavam sequências de forma serial, o *Transformer* opera em paralelo sobre toda a sequência de entrada por meio de um mecanismo de **atenção** (*self-attention*), que pondera a relevância de cada *token* em relação a todos os outros (Jurafsky; Martin, 2026). Isso permitiu tanto um treinamento significativamente mais eficiente em grandes corpora quanto uma captura mais rica de dependências de longo alcance na língua.

O modelo BERT (*Bidirectional Encoder Representations from Transformers*), proposto por Devlin *et al.* (2019), consolidou o paradigma de **pré-treinamento e ajuste fino** (*pre-training and fine-tuning*) como o estado da arte em PLN. Na fase de pré-treinamento, o BERT é treinado em tarefas auto-supervisionadas sobre grandes volumes de texto não rotulado — *Masked Language Modeling* (MLM), em que o modelo aprende a prever tokens mascarados com base no contexto bidirecional, e *Next Sentence Prediction* (NSP) — adquirindo representações linguísticas ricas e generalizáveis (Jurafsky; Martin, 2026). Na fase de ajuste fino (*fine-tuning*), o modelo pré-treinado é especializado para uma tarefa específica — como classificação de sentimento — com um número relativamente pequeno de exemplos rotulados, transferindo o conhecimento linguístico adquirido na fase anterior (Santos; Bianchi; Costa, 2023).

Para o domínio financeiro em inglês, Araci (2019) desenvolveram o FinBERT, um modelo BERT especializado por meio de ajuste fino em textos financeiros, que demonstrou desempenho superior ao BERT genérico em tarefas de análise de sentimento financeiro. Essa abordagem evidenciou que a especialização de domínio — o pré-treinamento ou ajuste fino com textos específicos da área — é um fator determinante para o desempenho em linguagem técnica (Araci, 2019; Santos; Bianchi; Costa, 2023).

No contexto brasileiro, o modelo **BERTimbau** (Souza; Nogueira; Lotufo, 2020) forneceu a base para a especialização em português: trata-se de um BERT pré-treinado sobre um corpus de 2,68 bilhões de palavras em português, cobrindo fontes jornalísticas, enciclopédicas e da *web*. A partir do BERTimbau, Santos; Bianchi; Costa (2023) desenvolveram o **FinBERT-PT-BR**, realizando ajuste fino sobre 1,4 milhão de sentenças de notícias financeiras em português coletadas do Valor Econômico, Exame e InfoMoney entre 2006 e 2022. O modelo resultante — e sua variante para classificação de sentimento, o **SentFinBERT-PT-BR** — apresentou desempenho superior aos modelos anteriores do estado da arte em português para a tarefa de análise de sentimento de textos financeiros, sendo adotado neste trabalho como a principal ferramenta de extração de polaridade das publicações do X/Twitter relacionadas aos índices da B3.

2.4 Análise de Sentimento

A Análise de Sentimento (AS), também denominada mineração de opinião (*opinion mining*), é a área do PLN dedicada à identificação e extração computacional de opiniões, sentimentos, emoções e atitudes expressas em textos não estruturados (Liu; Zheng; Song, 2020). O objetivo central da AS é determinar a **polaridade** de um dado conteúdo — se ele expressa uma orientação positiva, negativa ou neutra — podendo operar em diferentes níveis de granularidade: no nível do documento, da sentença ou de aspectos específicos do texto (Jurafsky; Martin, 2026; Liu; Zheng; Song, 2020). No domínio financeiro, a AS adquire relevância particular ao permitir mensurar a percepção coletiva dos agentes econômicos — expressa em notícias, relatórios e publicações em redes sociais — fornecendo um indicador qualitativo do humor do mercado que complementa as métricas quantitativas tradicionais (Kearney; Liu, 2014; Tetlock, 2007).

2.4.1 Tarefas e Níveis de Análise

A AS pode ser organizada em torno de três tarefas principais, que diferem em complexidade e granularidade (Liu; Zheng; Song, 2020; Jurafsky; Martin, 2026). A **classificação de polaridade** é a tarefa mais diretamente relevante para este trabalho: dado um texto, o sistema atribui-lhe uma categoria de sentimento — positivo, negativo ou neutro. Em contextos financeiros, essa classificação frequentemente se traduz em sinais de otimismo ou pessimismo do investidor em relação a um ativo ou ao mercado como um todo (Bollen; Mao; Zeng, 2011; Galdi; Gonçalves, 2018). A **análise de sentimento baseada em aspectos** (*aspect-based sentiment analysis*) vai além da polaridade global e identifica o sentimento associado a entidades ou atributos específicos mencionados no texto — por exemplo, distinguindo a avaliação sobre a gestão de uma empresa de sua avaliação sobre seus resultados financeiros (Liu; Zheng; Song, 2020). A **detecção de emoções** vai além da polaridade binária e classifica o conteúdo emocional em categorias como alegria, medo, raiva e tristeza, conforme modelos psicológicos de afeto (Bollen; Mao; Zeng, 2011); essa dimensão foi explorada de forma pioneira por Bollen; Mao; Zeng (2011) ao decompor o humor coletivo do Twitter em seis dimensões do GPOMS (*Google-Profile of Mood States*) e correlacioná-las ao DJIA.

No que diz respeito aos níveis de análise, a literatura distingue entre a análise em nível de **documento** — em que uma publicação ou notícia inteira é classificada com uma única polaridade — e a análise em nível de **sentença** — em que cada sentença é classificada individualmente, permitindo capturar a coexistência de sentimentos contraditórios num mesmo texto (Kearney; Liu, 2014). Para publicações curtas como *tweets*, os dois níveis tendem a coincidir, dada a natureza unitária e concisa de cada publicação (Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015). Este trabalho opera predominantemente no nível de documento/publicação, classificando cada *tweet* individualmente como positivo, negativo

ou neutro.

2.4.2 Abordagens Metodológicas

As abordagens para realização de AS podem ser organizadas em três grandes famílias, cada uma com características, vantagens e limitações distintas (Kearney; Liu, 2014; Liu; Zheng; Song, 2020; Lucas; Peixoto, 2025).

A **abordagem baseada em léxicos** classifica o sentimento de um texto computando a soma (ou média ponderada) das pontuações de sentimento das palavras individuais que o compõem, conforme um dicionário pré-compilado que associa cada palavra a um valor de polaridade (Loughran; McDonald, 2011; Sousa *et al.*, 2025). As principais vantagens dessa abordagem são a interpretabilidade, a ausência de necessidade de dados rotulados para treinamento e a facilidade de incorporação de conhecimento especializado de domínio (Lucas; Peixoto, 2025). Suas limitações são igualmente conhecidas: léxicos de propósito geral falham em capturar o significado específico do vocabulário financeiro, conforme demonstrado por Loughran; McDonald (2011); a abordagem é sensível a fenômenos de negação (e.g., “*não subiu*”), ironia e sarcasmo; e não captura dependências contextuais entre palavras distantes no texto (Liu; Zheng; Song, 2020). No contexto brasileiro, Lucas; Peixoto (2025) demonstraram que os léxicos VADER e HIV conseguem explicar, respectivamente, 28,8% e 18,4% da variância do Ibovespa quando aplicados a notícias financeiras em português — resultado significativo, mas limitado pela inadequação dos léxicos ao vocabulário do mercado brasileiro.

A **abordagem baseada em aprendizado de máquina** treina modelos estatísticos ou neurais sobre conjuntos de textos rotulados para aprender, a partir dos dados, os padrões linguísticos associados a cada classe de sentimento (Liu; Zheng; Song, 2020). Métodos tradicionais como Naïve Bayes, Máquinas de Vetores de Suporte (SVM) e árvores de decisão operam sobre representações esparsas do texto (*bag-of-words*, TF-IDF) e alcançam bom desempenho em domínios com vocabulário estável e dados rotulados suficientes (Sousa *et al.*, 2025). A principal limitação dessa família é a dependência de grandes corpora anotados, que são escassos no domínio financeiro em português (Santos; Bianchi; Costa, 2023; Sousa *et al.*, 2025). Além disso, modelos treinados em textos de um domínio ou gênero específico generalizam com dificuldade para outros contextos.

A **abordagem baseada em modelos de linguagem profundos**, em particular os modelos *transformer* discutidos na Seção 2.3.3, representa o estado da arte atual em AS (Liu; Zheng; Song, 2020; Santos; Bianchi; Costa, 2023). Esses modelos aprendem representações contextualizadas das palavras e sentenças durante o pré-treinamento em grandes corpora não rotulados e são depois ajustados (*fine-tuned*) para a tarefa de classificação de sentimento com um número relativamente pequeno de exemplos rotulados. A contextualização é a chave para superar as limitações das abordagens anteriores: o

significado de cada palavra é função de todo o contexto em que ocorre, permitindo que o modelo capture negações, ambiguidades e nuances semânticas que os léxicos e os modelos *bag-of-words* não conseguem representar (Jurafsky; Martin, 2026; Devlin *et al.*, 2019). A **abordagem híbrida**, por fim, combina elementos léxicos com modelos de aprendizado, aproveitando a especificidade dos dicionários especializados para enriquecer as representações aprendidas pelo modelo neural (Kearney; Liu, 2014; Sousa *et al.*, 2025).

2.4.3 Análise de Sentimento no Domínio Financeiro em Português

A aplicação da AS ao domínio financeiro em língua portuguesa apresenta desafios e oportunidades específicos que justificam o esforço de especialização de recursos e modelos. Como discutido na Seção 2.2.3, a transferência direta de ferramentas desenvolvidas para o inglês financeiro produz resultados sistematicamente inferiores ao potencial da área (Loughran; McDonald, 2011; Santos; Bianchi; Costa, 2023). O vocabulário do mercado financeiro brasileiro é rico em termos técnicos, siglas de índices e ativos (Ibovespa, IPCA, Selic, PETR4), referências institucionais (B3, CVM, Banco Central) e expressões idiomáticas que não possuem correspondentes diretos em léxicos ou corpora em inglês (Sousa *et al.*, 2025; Falcão, 2020).

Os primeiros trabalhos aplicados ao mercado brasileiro utilizaram principalmente abordagens léxicas e modelos de aprendizado de máquina raso. Falcão (2020) analisou notícias do Valor Econômico e da Folha de São Paulo entre 2013 e 2019, correlacionando o sentimento extraído com o comportamento do Ibovespa e de cinco ações de diferentes setores, e constatou que os sentimentos tendem a ser neutros na maioria dos dias, seguindo tendências pessimistas em períodos de maior incerteza econômica. Galdi; Gonçalves (2018) investigaram a relação entre pessimismo e incerteza das notícias e o comportamento dos investidores brasileiros, evidenciando que o conteúdo informacional da mídia influencia a visão dos investidores especialmente em momentos de maior turbulência do mercado.

A consolidação do paradigma *transformer* no PLN abriu novas perspectivas para o domínio financeiro em português. O modelo FinBERT-PT-BR (Santos; Bianchi; Costa, 2023), desenvolvido por Santos; Bianchi; Costa (2023) a partir do ajuste fino do BERTimbau (Souza; Nogueira; Lotufo, 2020) sobre 1,4 milhão de sentenças de notícias financeiras em português, estabeleceu um novo estado da arte para a tarefa de classificação de sentimento no domínio. O modelo é publicamente disponível e foi avaliado em um conjunto de 500 sentenças rotuladas de notícias financeiras, superando modelos multilíngues e léxicos especializados nas métricas de acurácia, F1-Score, precisão e recall (Santos; Bianchi; Costa, 2023). Iniciativas paralelas de construção de léxicos especializados para o português financeiro, como a proposta de expansão automática por Word2Vec e PMI de Sousa *et al.* (2025), alcançaram F1-Score de 80% em *tweets* quando combinadas com classificadores SVM, evidenciando o potencial das abordagens híbridas para complementar os modelos

neurais.

No presente trabalho, adota-se o modelo FinBERT-PT-BR como ferramenta central para a extração de polaridade das publicações do X/Twitter relacionadas ao mercado financeiro brasileiro. Essa escolha é motivada por três fatores: (i) a especialização do modelo no vocabulário financeiro em português do Brasil; (ii) seu desempenho superior ao estado da arte anterior nas tarefas de classificação de sentimento financeiro; e (iii) sua disponibilidade pública, que garante a reprodutibilidade da metodologia proposta. Complementarmente, o trabalho avalia uma variante do BERTimbau (Souza; Nogueira; Lotufo, 2020) ajustada por *fine-tuning* diretamente sobre o corpus de *tweets* financeiros coletados, como termo de comparação que situa o desempenho do FinBERT-PT-BR em relação a um modelo genérico especializado *a posteriori* para o gênero e o subdomínio específicos do corpus — abordagem detalhada na subseção 3.6.4. A aplicação de ambos os modelos ao corpus coletado, bem como a análise dos índices de sentimento resultantes, é detalhada no Capítulo 3.

2.5 Trabalhos Relacionados

Esta seção apresenta os principais trabalhos que situam o presente estudo na trajetória da pesquisa em análise de sentimento aplicada a mercados financeiros. A revisão está organizada em dois grupos: trabalhos internacionais que estabeleceram os fundamentos metodológicos da área e trabalhos nacionais que aplicaram técnicas de análise de sentimento ao mercado financeiro brasileiro, evidenciando a lacuna que este trabalho busca contribuir para preencher.

2.5.1 Trabalhos Internacionais

O estudo pioneiro de Antweiler; Frank (2004) foi o primeiro a examinar sistematicamente o conteúdo informacional de textos gerados por usuários em plataformas digitais para análise de mercado. Os autores analisaram aproximadamente 1,5 milhão de mensagens publicadas nos fóruns Yahoo Finance e Raging Bull entre 1999 e 2001, relativas a 45 empresas do Dow Jones Industrial Average e do Dow Jones Internet Index. Utilizando dicionários léxicos para classificar as mensagens em positivas, negativas e neutras, identificaram que o volume de mensagens era preditivo da volatilidade do mercado e que o conteúdo apresentava relação estatisticamente significativa com retornos subsequentes. Embora os efeitos sobre retornos fossem economicamente modestos, o trabalho estabeleceu o precedente metodológico central para a área: textos gerados por usuários carregam conteúdo informacional com implicações para a dinâmica dos preços de ativos.

Tetlock (2007) ampliou essa perspectiva ao analisar o conteúdo da coluna “Abreast of the Market” do Wall Street Journal entre 1984 e 1999. Utilizando o dicionário Harvard General Inquirer para extrair o componente de pessimismo do texto jornalístico, o autor

demonstrou que altos níveis de pessimismo na mídia antecipavam quedas nos retornos do mercado, enquanto um pessimismo anormalmente alto ou baixo era seguido de reversão à média. O trabalho foi fundamental por conectar explicitamente o conteúdo qualitativo da mídia financeira à Hipótese do Mercado Eficiente, sugerindo que o sentimento expresso em texto pode conter informação que os preços demoram a incorporar plenamente (Tetlock, 2007; Fama, 1970).

O trabalho de Bollen; Mao; Zeng (2011) representou o marco mais influente para o campo ao deslocar o foco dos textos jornalísticos para as redes sociais. Analisando cerca de 9,7 milhões de *tweets* publicados entre abril e dezembro de 2008, os autores mensuraram o humor coletivo por meio de duas ferramentas — OpinionFinder e GPOMS — e demonstraram, por análise de causalidade de Granger, que a dimensão “Calma” do GPOMS apresentava causalidade preditiva sobre os valores de fechamento do DJIA com defasagem de dois a seis dias, alcançando acurácia de 87,6% na previsão de movimentos diários de alta e baixa. A sofisticação metodológica do trabalho — combinando análise de sentimento multidimensional, testes de causalidade e redes neurais *fuzzy* — e a robustez de seus resultados tornaram-no a referência central da área, com mais de dez mil citações na literatura (Bollen; Mao; Zeng, 2011).

Ranco *et al.* (2015) estenderam essa linha de pesquisa ao examinar a relação entre sentimento no Twitter e retornos das 30 ações componentes do DJIA, em vez do índice agregado. Os autores identificaram que o impacto do sentimento é especialmente pronunciado nos dias que antecedem e sucedem eventos corporativos relevantes — como divulgação de resultados trimestrais e anúncios de fusões —, e que a correlação entre sentimento e retornos é assimétrica: eventos de sentimento negativo tendem a ter impacto mais imediato e acentuado do que eventos positivos. Kearney; Liu (2014), por fim, forneceram a síntese mais abrangente do campo até então, revisando mais de cem estudos sobre análise de sentimento em finanças e organizando-os em torno das dimensões de fonte de dados, método de extração de sentimento e variável financeira de interesse. Os autores concluem que as fontes não convencionais de dados textuais — incluindo mídias sociais — constituem um complemento informacionalmente rico às fontes tradicionais de dados financeiros, e que a escolha do método de análise deve ser guiada pela especificidade do domínio e da língua em questão (Kearney; Liu, 2014).

2.5.2 Trabalhos Nacionais

No contexto brasileiro, a pesquisa em análise de sentimento aplicada ao mercado financeiro é mais recente e ainda escassa, especialmente no que diz respeito ao uso de publicações em redes sociais como fonte de dados. Os trabalhos existentes concentram-se predominantemente na análise de notícias em português, com resultados que evidenciam tanto o potencial da abordagem quanto a lacuna de recursos linguísticos especializados.

Galdi; Gonçalves (2018) investigaram a relação entre o pessimismo e a incerteza das notícias financeiras e o comportamento dos investidores no Brasil. Utilizando o índice de legibilidade de Gunning Fog e um dicionário léxico adaptado ao português, os autores analisaram notícias relacionadas a empresas listadas na B3 e encontraram evidências de que o conteúdo informacional da mídia influencia as decisões dos investidores, especialmente em períodos de maior turbulência econômica. O trabalho foi pioneiro ao aplicar técnicas de análise de conteúdo textual ao mercado acionário brasileiro e ao demonstrar que variáveis qualitativas extraídas de notícias possuem poder explicativo sobre o comportamento dos preços, complementando indicadores quantitativos tradicionais (Galdi; Gonçalves, 2018).

Falcão (2020) realizou uma análise abrangente do efeito do sentimento textual de notícias financeiras sobre os preços no mercado acionário brasileiro. O trabalho analisou textos do Valor Econômico e da Folha de São Paulo entre janeiro de 2013 e agosto de 2019 — totalizando 1.470 observações diárias — e correlacionou o sentimento extraído com os valores diários do Ibovespa e de cinco ações de setores distintos (Ambev, Itaú, Magazine Luiza, Petrobras e Vale). Os léxicos LIWC, SentiLex e OpLexicon foram empregados para extração de sentimento, e os resultados indicaram que os sentimentos tendem a ser neutros na maioria dos dias, seguindo tendências pessimistas em períodos de incerteza econômica elevada. O estudo concluiu que o conteúdo dos jornais brasileiros influencia a visão dos investidores especialmente em momentos de maior incerteza, fornecendo evidências de que o corpus de notícias é uma fonte de informação relevante para a tomada de decisão no mercado brasileiro (Falcão, 2020).

Santos; Bianchi; Costa (2023) introduziram o avanço mais significativo para o campo ao proporem o **FinBERT-PT-BR**, modelo BERT especializado para o domínio financeiro em português. O modelo foi desenvolvido em duas etapas: pré-treinamento sobre 1,4 milhão de sentenças de notícias financeiras coletadas do Valor Econômico, Exame e InfoMoney (2006–2022) a partir do BERTimbau (Souza; Nogueira; Lotufo, 2020); e ajuste fino para classificação de sentimento sobre 500 sentenças anotadas, gerando o modelo SentFinBERT-PT-BR. Os autores demonstraram que o modelo supera abordagens léxicas e modelos multilíngues em métricas de acurácia, precisão, recall e F1-Score, e que o índice de sentimento por ele gerado captura eventos macroeconômicos relevantes da história recente do Brasil — como a Operação Lava Jato (2014), o *impeachment* de Dilma Rousseff (2016), o “Joesley Day” (2017) e a pandemia de COVID-19 (2020) — com alta aderência ao sentimento prevalente em cada período (Santos; Bianchi; Costa, 2023).

Mais recentemente, três trabalhos buscaram avançar a agenda de pesquisa no mercado financeiro brasileiro por caminhos metodológicos complementares. Sousa *et al.* (2025) propuseram uma abordagem híbrida de expansão automática de léxicos especializados para o Mercado Financeiro Brasileiro (MFB), combinando um léxico semente em português com técnicas de Word2Vec, busca por sinônimos/antônimos e Informação

Mútua Pontual (PMI). O léxico resultante alcançou F1-Score de 71,5% na classificação de *tweets* e de 68,4% em notícias do MFB, valores que sobem para 80% quando combinados com um classificador SVM, demonstrando o potencial das abordagens híbridas para o domínio financeiro em português (Sousa *et al.*, 2025). Lucas; Peixoto (2025), por sua vez, avaliaram sistematicamente a abordagem léxica na análise de sentimento de notícias do mercado financeiro coletadas via Google News API, aplicando os léxicos VADER e HIV ao Ibovespa. Os resultados mostraram que esses léxicos, originalmente desenvolvidos para o inglês e aplicados após tradução automática dos títulos, explicam respectivamente 28,8% e 18,4% da variância do índice — resultado expressivo dado o caráter genérico dos dicionários empregados, mas que reforça a necessidade de recursos especializados para o português financeiro (Lucas; Peixoto, 2025). Silva *et al.* (2025) investigaram a extração de sentimento de notícias do Yahoo Finance entre 2020 e 2023, utilizando VADER e TextBlob para correlacionar o sentimento com variações do S&P 500. Os autores observaram que, em determinados períodos — como o início de 2021 —, o aumento de notícias positivas coincidiu com a recuperação do mercado, mas concluíram que a relação entre sentimento e desempenho do mercado não é linear, sugerindo a influência de fatores macroeconômicos e geopolíticos que não são capturados pela análise de sentimento isolada (Silva *et al.*, 2025).

2.5.3 Síntese Comparativa e Posicionamento do Presente Trabalho

O Quadro 1 sintetiza os principais trabalhos relacionados, organizados pelas dimensões de fonte de dados, método de análise de sentimento, mercado-alvo e principal resultado.

A análise comparativa evidencia que o presente trabalho ocupa uma posição específica e ainda pouco explorada na interseção de três dimensões. Em primeiro lugar, no que diz respeito à **fonte de dados**: embora Twitter/X tenha sido amplamente utilizado em estudos internacionais (Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015), os trabalhos nacionais concentram-se predominantemente em notícias de portais jornalísticos, com poucos estudos explorando sistematicamente publicações do X/Twitter em português financeiro (Sousa *et al.*, 2025). Em segundo lugar, no que concerne ao **método de análise**: enquanto os trabalhos brasileiros mais recentes utilizam majoritariamente abordagens léxicas (Lucas; Peixoto, 2025; Sousa *et al.*, 2025) ou redes neurais genéricas (Silva *et al.*, 2025), este trabalho adota o FinBERT-PT-BR — o modelo de estado da arte especificamente treinado para o domínio financeiro em português — o que representa um avanço metodológico em relação às abordagens anteriores. Em terceiro lugar, em relação ao **mercado-alvo**: a aplicação ao contexto específico da B3, com foco nos índices do mercado acionário brasileiro, responde à demanda por estudos que considerem as particularidades institucionais, linguísticas e econômicas do Brasil, distinguindo-se dos trabalhos que utilizam o S&P 500 ou o DJIA como referência (Silva *et al.*, 2025; Bollen; Mao; Zeng, 2011).

Tabela 1 – Síntese dos trabalhos relacionados

Trabalho	Fonte de Dados	Método	Mercado	Principal Resultado
Antweiler & Frank (2004)	Fóruns Yahoo Finance / Raging Bull	Léxico (Harvard GI)	EUA (DJIA)	Volume de msg. prevê volatilidade
Tetlock (2007)	Wall Street Journal	Léxico (Harvard GI)	EUA (S&P 500)	Pessimismo na mídia antecipa quedas
Bollen et al. (2011)	Twitter	OpinionFinder / GPOMS	EUA (DJIA)	Humor coletivo prevê DJIA (87,6%)
Ranco et al. (2015)	Twitter	SVM / léxico	EUA (DJIA 30)	Sentimento impacta mais em eventos corporativos
Galdi & Gonçalves (2018)	Notícias (B3)	Léxico adaptado ao PT	Brasil (B3)	Pessimismo em notícias afeta investidores em períodos de incerteza
Falcão (2020)	Valor Econômico / Folha SP	LIWC / SentiLex / OpLexicon	Brasil (Ibovespa + 5 ações)	Sentimento neutro na maioria dos dias; pessimismo em crises
Santos et al. (2023)	Notícias (Valor / Exame / InfoMoney)	FinBERT-PT-BR (BERT)	Brasil (mercado geral)	Estado da arte em AS financeiro em PT-BR
Sousa et al. (2025)	Tweets + Notícias (MFB)	Léxico híbrido (Word2Vec + PMI + SVM)	Brasil (MFB)	F1-Score 80% em tweets com léxico+SVM
Lucas & Peixoto (2025)	Notícias (Google News)	VADER / HIV (léxicos)	Brasil (Ibovespa)	Léxicos genéricos explicam 28,8% da variância do Ibovespa
Silva et al. (2025)	Yahoo Finance	VADER / TextBlob	EUA (S&P 500)	Relação sentimento-mercado não é linear
Presente trabalho	X/Twitter	FinBERT-PT-BR	Brasil (B3)	AS de tweets financeiros em PT-BR com modelo especializado

Fonte: Elaborado pelo autor.

A contribuição principal deste trabalho, portanto, consiste em integrar uma fonte de dados de alta temporalidade (X/Twitter em tempo real) com o método de análise de sentimento de maior desempenho disponível para o português financeiro (FinBERT-PT-BR), aplicando essa combinação ao mercado acionário brasileiro, lacuna ainda não explorada na literatura nacional revisada.

3 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos adotados para o desenvolvimento da pesquisa. A construção do *pipeline* de Processamento de Linguagem Natural (PLN) proposto demandou decisões sucessivas acerca do tipo de pesquisa, da fonte e do processo de coleta de dados, das etapas de tratamento e pré-processamento textual, das abordagens de classificação de sentimento e dos critérios de avaliação e interpretação dos resultados. Cada escolha é apresentada e justificada à luz dos objetivos estabelecidos no Capítulo 1 e do referencial teórico discutido no Capítulo 2.

3.1 Caracterização da Pesquisa

A presente pesquisa pode ser caracterizada segundo quatro dimensões complementares: sua natureza, seus objetivos, a abordagem ao problema e os procedimentos técnicos empregados.

Quanto à sua **natureza**, trata-se de uma pesquisa **aplicada**, uma vez que visa produzir conhecimento direcionado à resolução de um problema concreto — a ausência de protocolos metodológicos replicáveis para análise de sentimento no domínio financeiro em língua portuguesa — com potencial de aplicação prática por analistas, gestores e pesquisadores da área (Galdi; Gonçalves, 2018).

Quanto aos **objetivos**, a pesquisa é **descritiva e exploratória**. Descritiva porque busca caracterizar a distribuição de polaridade e os padrões semânticos presentes no corpus de publicações coletadas, identificando regularidades temporais e temáticas sem estabelecer relações de causalidade. Exploratória porque investiga um domínio ainda pouco estudado na literatura nacional — a análise de sentimento de publicações financeiras em português brasileiro via modelos de linguagem pré-treinados — e porque a avaliação comparativa das abordagens de classificação gera hipóteses para pesquisas futuras (Santos; Bianchi; Costa, 2023).

Quanto à **abordagem ao problema**, trata-se de uma pesquisa **quantitativa**. O corpus textual coletado é tratado computacionalmente para gerar representações numéricas de polaridade (positiva, negativa ou neutra) que, agregadas, produzem um índice de sentimento passível de análise estatística descritiva. Embora a interpretação dos resultados recorra ao contexto qualitativo de eventos macroeconômicos do período, a unidade central de análise é de natureza quantitativa (Kearney; Liu, 2014).

Quanto aos **procedimentos técnicos**, a pesquisa adota o modelo **experimental-computacional**, caracterizado pela construção, aplicação e avaliação de um *pipeline* de PLN sobre dados coletados programaticamente via interface de programação de aplicações

(API). Esse modelo é consistente com a tradição metodológica da área de PLN aplicado a finanças, na qual a replicabilidade e a documentação pormenorizada dos procedimentos são requisitos centrais para a validade científica do trabalho Santos, Bianchi e Costa (2023).

O Quadro 1 sintetiza as escolhas metodológicas adotadas e suas respectivas justificativas.

Quadro 1 – Síntese da caracterização metodológica da pesquisa

Dimensão	Classificação	Justificativa
Natureza	Aplicada	Geração de protocolo metodológico replicável para o domínio financeiro em PT-BR
Objetivos	Descritiva e exploratória	Caracterização de padrões de sentimento; investigação de domínio pouco estudado na literatura nacional
Abordagem ao problema	Quantitativa	Mensuração numérica de polaridade via PLN e construção de índice de sentimento
Procedimentos técnicos	Experimental-computacional	Construção, aplicação e avaliação de <i>pipeline</i> de PLN sobre dados coletados via API

Fonte: Elaborado pelo autor.

3.2 Fonte de Dados e Processo de Coleta

3.2.1 Justificativa da Escolha do X/Twitter como Fonte

O X/Twitter foi selecionado como fonte primária de dados por congregar características estruturais que o tornam especialmente adequado para a análise de sentimento aplicada ao mercado financeiro. Em primeiro lugar, a plataforma opera como canal de comunicação em tempo real, com publicações cronológicas e públicas que registram o humor e as expectativas dos agentes financeiros de forma praticamente instantânea (Bollen; Mao; Zeng, 2011). Em segundo lugar, a arquitetura da plataforma — baseada em publicações curtas (*tweets*) com limite de caracteres — produz textos concisos e com orientação semântica, mais adequados à tarefa de classificação de polaridade do que textos longos de natureza mais ambígua (Ranco *et al.*, 2015).

A literatura internacional consolidou o X/Twitter como objeto de pesquisa em finanças, desde os trabalhos pioneiros de Bollen, Mao e Zeng (2011) e Antweiler e Frank (2004), que demonstraram a relação entre o conteúdo das publicações e o comportamento de mercado. No contexto brasileiro, trabalhos como os de Sousa *et al.* (2025) e Falcão (2020) também recorreram à plataforma como fonte de dados para análise de sentimento financeiro.

Em comparação com alternativas como artigos completos de veículos de imprensa, as publicações do X/Twitter apresentam duas vantagens metodológicas relevantes: (i) maior facilidade de extração estruturada de dados via API, dispensando técnicas complexas de *web scraping*; e (ii) formato textual conciso e objetivo, mais adequado para análise de polaridade semântica no nível de documento.

3.2.2 Veículos Seleccionados

Como *proxy* para o sentimento do mercado financeiro brasileiro, foram selecionadas as publicações de dois veículos especializados em economia e finanças com presença ativa na plataforma X/Twitter: **InfoMoney** (@InfoMoney) e **Investing Brasil** (@InvestingBrasil).

A escolha desses veículos é fundamentada em três critérios:

1. **Relevância editorial:** ambos são referências reconhecidas de jornalismo econômico-financeiro no Brasil, com cobertura sistemática de eventos macroeconômicos, decisões de política monetária, resultados corporativos e movimentações do mercado de capitais nacional;
2. **Volume e regularidade de publicações:** as contas institucionais mantêm frequência elevada e contínua de publicações, garantindo densidade suficiente de dados para a construção de séries temporais de sentimento;
3. **Consistência do público-alvo:** ao contrário de contas de pessoas físicas, cujo conteúdo pode ser heterogêneo, os veículos especializados produzem publicações com foco temático predominantemente financeiro, reduzindo a necessidade de filtragem por relevância.

Reconhece-se que a opção por veículos institucionais em detrimento de contas de investidores individuais representa uma escolha metodológica deliberada, que delimita o escopo do sentimento capturado ao discurso editorial — e não ao sentimento difuso dos participantes de varejo do mercado. Essa limitação circunscreve o alcance das generalizações admissíveis e é reconhecida como restrição metodológica deste trabalho.

3.2.3 Período de Análise

O corpus compreende publicações realizadas entre **17 de outubro de 2025** e **12 de fevereiro de 2026**, totalizando aproximadamente quatro meses de dados — intervalo determinado pelo registro mais antigo e pelo mais recente efetivamente presentes na base coletada via API. Esse recorte temporal foi determinado por um conjunto de restrições metodológicas e operacionais.

Do ponto de vista **técnico**, o acesso à API do X/Twitter está condicionado a planos comerciais com janelas históricas limitadas. A recuperação retroativa de grandes volumes de dados requer subscrição ao plano *Pro* ou *Enterprise* da API, cujos custos são proibitivos para pesquisas acadêmicas sem financiamento dedicado. O período analisado corresponde à janela de dados coletados em tempo real durante a execução da pesquisa, garantindo acesso completo e sem truncamento ao histórico de publicações.

Do ponto de vista **analítico**, o período de aproximadamente quatro meses abrange um conjunto relevante de eventos macroeconômicos do cenário brasileiro — incluindo reuniões do Comitê de Política Monetária (COPOM), divulgação de indicadores de inflação (IPCA e INPC), dados de atividade econômica e movimentações relevantes nos preços dos ativos — o que possibilita a avaliação qualitativa da coerência entre os índices de sentimento extraídos e o contexto econômico-financeiro do período.

3.2.4 Processo de Coleta via API

3.2.4.1 *Endpoint* Utilizado e Autenticação

A coleta foi realizada por meio do *endpoint* **GET /2/users/{id}/tweets** da API v2 do X/Twitter¹, que retorna a linha do tempo de publicações de um usuário específico identificado pelo seu *id* numérico. A opção por esse *endpoint* — em vez do *endpoint* de busca (*Search*) — é metodologicamente justificada pelo escopo da coleta: como os veículos de interesse (InfoMoney e Investing Brasil) são previamente conhecidos e possuem identificadores únicos fixos, a recuperação direta pela linha do tempo do usuário é mais eficiente e determinística do que uma busca por palavras-chave, eliminando a necessidade de filtros adicionais de autoria.

A autenticação foi realizada via **Bearer Token** (*app-only authentication*), mecanismo que concede acesso de leitura ao conteúdo público da plataforma sem requerer autorização individual de cada conta coletada. O token foi armazenado como variável de ambiente (`TWITTER_ACCESS_TOKEN`) e transmitido no cabeçalho HTTP de cada requisição no formato `Authorization: Bearer <token>`.

3.2.4.2 Parâmetros da Requisição

Para cada veículo monitorado, as requisições foram parametrizadas conforme o Quadro 2. O intervalo temporal foi delimitado pelos campos `start_time` e `end_time`, ambos no formato ISO 8601 (YYYY-MM-DDTHH:mm:ssZ, UTC). O volume máximo de resultados por página foi fixado em 100 registros — limite superior permitido pelo *endpoint* —, e a paginação foi controlada pelo parâmetro `pagination_token`, utilizado de forma iterativa até o esgotamento dos resultados disponíveis.

¹ Documentação oficial: <https://developer.twitter.com/en/docs/twitter-api/tweets/timelines/api-reference/get-users-id-tweets>. Acesso em: 12 fev. 2026.

Quadro 2 – Parâmetros utilizados nas requisições ao *endpoint* GET `/2/users/{id}/tweets`

Parâmetro	Valor / Descrição
<code>id (path)</code>	Identificador numérico do veículo: <code>@InfoMoney</code> e <code>@InvestingBrasil</code> , passados dinamicamente a cada ciclo de coleta
<code>start_time</code>	Limite inferior do intervalo temporal (ISO 8601, UTC)
<code>end_time</code>	Limite superior do intervalo temporal (ISO 8601, UTC)
<code>max_results</code>	100 (máximo permitido pelo <i>endpoint</i>)
<code>tweet.fields</code>	<code>created_at</code> , <code>note_tweet</code> , <code>author_id</code> , <code>public_metrics</code> , <code>lang</code> , <code>source</code> , <code>entities</code> , <code>context_annotations</code> , <code>geo</code>
<code>user.fields</code>	<code>name</code> , <code>username</code> , <code>location</code> , <code>description</code> , <code>public_metrics</code>
<code>pagination_token</code>	Token retornado pela API para recuperação da próxima página de resultados; omitido na primeira requisição de cada ciclo

Fonte: Elaborado pelo autor com base na documentação da API v2 do X/Twitter e no código-fonte do *pipeline* de coleta.

Um aspecto técnico relevante diz respeito ao campo `note_tweet`: publicações de usuários com assinatura X Premium podem ultrapassar o limite convencional de 280 caracteres por meio desse campo, que armazena o texto estendido separadamente do campo `text` padrão. O *pipeline* implementado prioriza o conteúdo de `note_tweet` quando disponível, recorrendo ao `text` convencional apenas na sua ausência — decisão que garante a recuperação do conteúdo textual integral das publicações. Registros sem conteúdo textual em nenhum dos dois campos são descartados durante a coleta.

3.2.4.3 Pipeline de Coleta e Armazenamento

O *pipeline* de coleta é a primeira etapa (`pipeline/01_extraction/`) de uma estrutura modular de seis estágios numerados. Os módulos que compõem essa etapa, com suas responsabilidades bem delimitadas, são:

- `app/core/extraction/twitter_api.py`: implementa a classe `TwitterAPIExtractor`, que herda da classe abstrata `BaseExtractor` e é responsável pela construção e execução das requisições HTTP à API via biblioteca `requests`. Recebe como parâmetros o identificador do usuário (`x_user_id`), o intervalo temporal e, opcionalmente, o token de paginação;
- `app/core/extraction/base_extractor.py`: define a classe abstrata `BaseExtractor` (ABC), que estabelece o contrato de interface para qualquer extrator de dados do *pipeline*, garantindo extensibilidade para futuras fontes de dados além do X/Twitter;

- `app/shared/schemas.py`: módulo transversal a todas as etapas do *pipeline*, contendo as *dataclasses* de *parsing* da resposta JSON da API — `Tweet`, `Tweets`, `NoteTweet`, `PublicMetrics`, `Entities`, `Hashtag` e `Meta` —, que estruturam os campos retornados em objetos Python tipados;
- `app/core/extraction/collection_log.py`: define a classe `SearchTerm`, que representa um registro de coleta agendada com os campos `x_user_id`, `from_date_time` e `to_date_time`, e gerencia a inserção dos termos de busca na tabela `collection_log`;
- `app/shared/db/database.py`: módulo transversal que implementa a classe `DatabaseManager`, responsável pela interface de comunicação com o banco de dados PostgreSQL — incluindo as operações de consulta, inserção e atualização utilizadas por todos os estágios do *pipeline*;
- `app/core/extraction/__main__.py`: ponto de entrada do estágio de coleta (invocado via `python -m app.core.extraction`, que orquestra o ciclo completo: recupera registros com status `pending` em `collection_log`, executa a paginação iterativa para cada um deles e persiste os resultados no banco de dados.

Os dados coletados foram persistidos em um banco de dados **PostgreSQL 15**, provisionado em contêiner **Docker** para garantir portabilidade e isolamento do ambiente. A infraestrutura é inicializada via `docker-compose.yml`, que sobe automaticamente o PostgreSQL (porta 5432) e o pgAdmin 4 (porta 5050), executando os scripts `infra/01-init-database.sh` — criação de usuário e permissões — e `infra/02-create-tables.sql` — criação das tabelas e índices. O esquema do banco é composto por três tabelas, cujas estruturas são descritas no Quadro 3.

A tabela `collection_log` cumpre função de controle de idempotência: cada combinação de veículo e intervalo temporal é registrada com status `pending` antes da execução, sendo atualizada para `completed` ao final de um ciclo sem falhas de inserção, ou para `partially_completed` caso algum registro não tenha sido persistido. Esse mecanismo permite a retomada segura de coletas interrompidas e a auditoria do histórico de execuções sem risco de duplicação de dados, uma vez que a coluna `tweet_id` na tabela `tweets` é definida com restrição `UNIQUE`.

3.3 Rotulagem Manual do Corpus

A rotulagem manual constitui etapa fundamental para a construção do conjunto de referência (*gold standard*) utilizado na avaliação das abordagens de classificação de sentimento descritas na seção 3.6. O processo foi conduzido pelo próprio pesquisador por meio de uma ferramenta de anotação desenvolvida especificamente para este trabalho,

Quadro 3 – Estrutura das tabelas do banco de dados PostgreSQL

Tabela	Campo	Descrição
tweets	tweet_id username note_tweet created_at likes hashtags tweet	Identificador único da publicação na plataforma (UNIQUE) Identificador numérico do veículo autor Conteúdo textual utilizado na análise (<code>note_tweet.text</code> ou <code>text</code>) Data e hora de publicação (com fuso horário) Número de curtidas Lista de <i>hashtags</i> (JSONB) Objeto JSON completo retornado pela API (JSONB)
tweets_classification	tweet_id sentiment why_sentiment is_finance_news why_is_finance_news classifier	FK → <code>tweets.id</code> (ON DELETE CASCADE) Polaridade atribuída: <i>positivo</i> , <i>negativo</i> ou <i>neutro</i> Justificativa textual para a polaridade classificada Relevância financeira classificada: 1 = financeiro, 0 = não financeiro Justificativa textual para a classificação de relevância Identificador do classificador: "Humano", "FinBERT-PT-BR", "BERTimbau" ou outro modelo futuro
collection_log	search_term tweets_collected start_time end_time status error_message	Parâmetros da coleta agendada (JSONB) Total de registros inseridos no ciclo Início da execução do ciclo de coleta Término da execução do ciclo de coleta Estado do ciclo: <code>pending</code> , <code>completed</code> ou <code>partially_completed</code> Mensagem de erro, se houver

Fonte: Elaborado pelo autor com base no schema `infra/02-create-tables.sql` do repositório do *pipeline*.

implementada em Python com a biblioteca `streamlit` e integrada ao banco de dados PostgreSQL descrito na subseção 3.2.4.3.

3.3.1 Protocolo de Anotação em Duas Etapas

O protocolo de anotação foi estruturado em duas etapas sequenciais, aplicadas a cada publicação individualmente:

Etapla 1 — Relevância financeira. O anotador classifica a publicação em uma de duas categorias mutuamente exclusivas: *tweet financeiro* (valor 1), quando o conteúdo se relaciona diretamente ao mercado financeiro, à economia, a investimentos ou a eventos com impacto sobre ativos financeiros; ou *não financeiro* (valor 0), quando o conteúdo é de outra natureza — editorial, esportivo, de entretenimento ou sem relação com o contexto econômico-financeiro. Apenas as publicações classificadas como financeiras prosseguem para a segunda etapa.

Etapla 2 — Polaridade de sentimento. Para as publicações identificadas como financeiras, o anotador atribui uma das três classes de polaridade:

- **Positivo:** o conteúdo veicula uma perspectiva favorável ao mercado ou a agentes econômicos — crescimento, resultados acima do esperado, alívio de incertezas, aprovação de medidas de estímulo, entre outros;
- **Neutro:** o conteúdo tem caráter predominantemente informativo e factual, sem atribuir valoração explícita ao evento relatado;
- **Negativo:** o conteúdo veicula uma perspectiva desfavorável — queda de indicadores, resultados abaixo do esperado, aumento de incerteza, crises ou eventos de risco sistêmico.

A separação entre relevância financeira e polaridade de sentimento em etapas distintas é uma decisão metodológica deliberada: ela evita que publicações de conteúdo não financeiro — mesmo que textualmente negativas ou positivas — contaminem o índice de sentimento do mercado financeiro.

3.3.2 Ferramenta de Anotação

A ferramenta de anotação constitui o segundo estágio do *pipeline* (`app/dashboard/`) e é composta por dois arquivos:

- `app/dashboard/app.py`: *launcher* multi-página Streamlit, invocado via `streamlit run app/dashboard/app.py` (acessível em `http://localhost:8501`). Agrega em uma única interface três páginas: *Classification* (`classifier.py`), *Analytics* (`app/dashboard/pages/e`) e *Exploração dos Dados* (`app/dashboard/pages/exploration.py`), permitindo ao anotador alternar entre a tarefa de rotulagem e a inspeção dos dados sem trocar de aplicação;

- `app/dashboard/pages/annotation.py`: página principal de anotação, que implementa a interface de classificação tweet a tweet e obtém os dados diretamente do banco de dados via `app/shared/db/database.py`.

A interface de classificação é composta por três componentes principais:

1. **Exibição do conteúdo**: para cada publicação, a ferramenta exibe o texto integral do campo `note_tweet` e a data de publicação, permitindo ao anotador contextualizar temporalmente o conteúdo antes de classificá-lo;
2. **Botões de classificação**: dois botões para a decisão de relevância financeira (Etapa 1) e, condicionalmente, três botões para a atribuição de polaridade (Etapa 2). O estado da classificação corrente é destacado visualmente, permitindo revisão e correção a qualquer momento;
3. **Registro de justificativa**: um formulário opcional (*dialog* Streamlit) permite que o anotador registre, em texto livre, a justificativa para cada decisão — tanto para a relevância financeira quanto para a polaridade atribuída. Esse registro é armazenado nos campos `why_is_finance_news` e `why_sentiment` da tabela `tweets_classification`, enriquecendo o *gold standard* com raciocínio explícito passível de auditoria futura.

A navegação pelo corpus é sequencial, com barra de progresso indicando o percentual de publicações já classificadas. A ferramenta prioriza automaticamente as publicações ainda sem classificação humana, identificadas pelo campo `has_human_classification`. Ao final de cada publicação, um histórico tabular exibe todas as classificações anteriores registradas em `tweets_classification`, com os campos *classificador*, *sentimento*, *relevância financeira* e as respectivas justificativas.

3.3.3 Armazenamento das Anotações

Cada decisão de classificação é persistida em duas estruturas complementares do banco de dados:

- **Tabela `tweets`**: os campos `is_finance_news` e `sentiment` são atualizados diretamente, tornando a classificação imediatamente disponível para as etapas de análise subsequentes;
- **Tabela `tweets_classification`**: registra o histórico completo de cada decisão com o identificador do classificador (`classifier = "Humano"`), as justificativas textuais e os valores atribuídos, garantindo rastreabilidade e possibilitando análises de concordância em estudos futuros.

3.3.4 Particionamento do Corpus Rotulado para Treinamento e Avaliação

O corpus rotulado manualmente cumpre, neste trabalho, dois propósitos metodológicos distintos: (i) constitui o conjunto de referência (*gold standard*) utilizado na avaliação comparativa das abordagens de classificação descritas na seção 3.6; e (ii) é a fonte de exemplos supervisionados para o *fine-tuning* de modelos pré-treinados ajustados localmente, como o BERTimbau (subseção 3.6.4). Esse duplo uso impõe uma decisão de protocolo: para que a comparação entre abordagens que viram os rótulos durante o treinamento (e.g., BERTimbau ajustado) e abordagens que não os viram (e.g., FinBERT-PT-BR e métodos léxicos) seja metodologicamente honesta, todas as abordagens devem ser avaliadas sobre o **mesmo subconjunto de teste**, definido a priori, antes de qualquer treinamento (Jurafsky; Martin, 2026; Caseli; Nunes; Pagano, 2024).

O particionamento é gerenciado pela classe `DatasetSplitRepository` (`app/shared/db/dataset_split.py`), que implementa o método `assign_split()` e persiste o resultado na tabela `dataset_split`. A operação é idempotente: uma vez realizada, é reutilizada por todas as execuções subsequentes do *pipeline*; o parâmetro `force=True` permite regenerá-la caso o corpus rotulado seja ampliado. A Tabela 2 descreve o esquema da tabela.

Tabela 2 – Esquema da tabela `dataset_split`

Coluna	Tipo	Descrição
<code>tweet_id</code>	INTEGER	Chave estrangeira para <code>tweets.id</code> ; único na tabela
<code>split</code>	VARCHAR	'train' ou 'test'
<code>fold</code>	SMALLINT	Fold do K-Fold (1–4) quando <code>split='train'</code> ; NULL quando <code>split='test'</code>

Fonte: Elaborado pelo autor.


O procedimento compreende duas etapas sequenciais, ambas com estratificação pela classe de polaridade e semente aleatória fixa (`random_state=42`), que preserva a distribuição original das três classes em cada conjunto — condição particularmente relevante dado o desbalanceamento esperado em favor da classe neutra, característico de publicações jornalísticas de natureza factual (Loughran; McDonald, 2011):

1. **Hold-out de teste** ($\approx 15\%$): por meio de `train_test_split` com estratificação pelo sentimento, extrai-se um subconjunto fixo reservado exclusivamente para a avaliação comparativa final. Os registros recebem `split='test'` e `fold=NULL`. Nenhum classificador — incluindo o BERTimbau — tem acesso a esses registros durante o treinamento, garantindo que as estimativas de desempenho reportadas no Capítulo 4 sejam livres de viés de seleção;

2. **Conjunto de treinamento** ($\approx 85\%$): os registros restantes recebem `split='train'` e são subdivididos em $K = 4$ folds por validação cruzada estratificada (`StratifiedKFold`, `shuffle=True`, `random_state=42`), cada um marcado com `fold` $\in \{1, 2, 3, 4\}$. Esse conjunto é utilizado exclusivamente pelo protocolo de *fine-tuning* do BERTimbau, detalhado na subseção 3.6.4.2; os demais classificadores (OpLexicon, SentiLex-PT e FinBERT-PT-BR) não requerem dados de treinamento e, portanto, não dependem dessa subdivisão.

A Figura 1 ilustra a estrutura resultante do particionamento.

Figura 1 – Estrutura do particionamento estratificado do corpus rotulado



Fonte: Elaborado pelo autor.

A fixação da semente aleatória e a persistência dos identificadores na tabela `dataset_split` asseguram a reprodutibilidade integral do protocolo: qualquer execução subsequente do *pipeline* sobre o mesmo corpus rotulado recupera os mesmos conjuntos, condição necessária para que comparações entre abordagens introduzidas em momentos distintos da pesquisa permaneçam metodologicamente consistentes.

3.3.5 Limitações do Processo de Rotulagem

O processo de rotulagem foi conduzido por um único anotador — o próprio pesquisador —, o que inviabiliza o cálculo de métricas de concordância interanotadores (e.g., Kappa de Cohen). A subjetividade inerente à tarefa, em especial para publicações de polaridade ambígua ou contextualmente dependente, representa uma fonte de incerteza não quantificada nos resultados, reconhecida como restrição metodológica deste trabalho.

3.4 Análise Exploratória dos Dados

Após a coleta e persistência dos registros no banco de dados PostgreSQL, o corpus foi submetido a uma Análise Exploratória dos Dados (AED) com três objetivos: (i) caracterizar a dimensão e a composição do conjunto coletado; (ii) verificar a completude dos campos e identificar valores ausentes; e (iii) examinar a distribuição do comprimento dos textos e detectar publicações atípicas que pudessem comprometer a etapa de classificação de sentimento. A AED foi implementada em Python como o terceiro estágio do

pipeline (`app/dashboard/`), estruturado em dois módulos Streamlit com responsabilidades complementares, ambos acessados via `streamlit run app/dashboard/app.py`:

- `app/dashboard/pages/exploration.py`: responsável pela análise textual do corpus — dimensões do conjunto, completude dos campos, distribuição do comprimento dos textos (caracteres e tokens) e identificação de publicações atípicas;
- `app/dashboard/pages/eda.py`: responsável pela visualização da distribuição de sentimentos e de relevância financeira entre as publicações já rotuladas, por meio de gráficos de setores interativos.

Ambos os módulos obtêm os dados diretamente do banco de dados PostgreSQL via `app/shared/db/database.py`, com o auxílio das bibliotecas `pandas` (The pandas development team, 2020), `plotly` e `streamlit`. Os resultados das subseções a seguir são provenientes do módulo `eda.py`.

3.4.1 Dimensões do Corpus e Distribuição por Veículo

O corpus final, exportado após o encerramento da coleta, é composto por **3.563 publicações**, distribuídas entre dois veículos monitorados conforme o Quadro 4. O InfoMoney responde pela ampla maioria das publicações (88,5% do total), enquanto o InvestingBrasil contribui com os 11,5% restantes. Essa assimetria reflete diferenças estruturais no ritmo de publicação das contas institucionais e deve ser considerada na etapa de construção do índice de sentimento agregado.


Quadro 4 – Distribuição do corpus por veículo monitorado

Veículo	Publicações	Participação (%)
InfoMoney	3.154	88,5
InvestingBrasil	409	11,5
Total	3.563	100,0


Fonte: Elaborado pelo autor com base nos dados coletados.

A distribuição temporal das publicações ao longo do período analisado é apresentada no Quadro 5 e ilustrada na Figura 2. Observa-se que o InfoMoney não apresenta registros para outubro de 2025 — primeiro mês da janela de coleta —, ao passo que o InvestingBrasil possui 36 publicações nesse período. A ausência do InfoMoney em outubro deve ser investigada para determinar se decorreu de limitação da janela de coleta da API, de interrupção editorial do veículo ou de outra causa operacional. Os meses de dezembro de 2025 e janeiro de 2026 concentram o maior volume de publicações para ambos os veículos, e fevereiro de 2026 apresenta volume reduzido por corresponder a um período parcialmente coletado (até o dia 12).

Figura 2 – Distribuição do corpus por veículo (esquerda) e distribuição temporal mensal (direita)



Fonte: Elaborado pelo autor.



Fonte: Elaborado pelo autor.

Quadro 5 – Distribuição mensal das publicações por veículo

Mês	InfoMoney	InvestingBrasil	Total
Out/2025	0	36	36
Nov/2025	723	94	817
Dez/2025	997	119	1.116
Jan/2026	1044	88	1.132
Fev/2026	390	72	462
Total	3.154	409	3.563

Fonte: Elaborado pelo autor com base nos dados coletados.

3.4.2 Completude dos Campos

A verificação de valores ausentes foi realizada sobre os campos diretamente coletados via API do X/Twitter. O Quadro 6 sumariza a completude dos campos analisados, e a Figura 3 apresenta a distribuição percentual de valores ausentes de forma visual.


Quadro 6 – Completude dos campos coletados via API

Campo	Ausentes	% Ausente	Observação
tweet_id	0	0,0	Completo
username	0	0,0	Completo
note_tweet	0	0,0	Completo
created_at	0	0,0	Completo
likes	0	0,0	Completo
hashtags	163	4,6	Publicações sem <i>hashtag</i>

Fonte: Elaborado pelo autor com base nos dados coletados.

O corpus apresenta completude integral em cinco dos seis campos analisados. A única exceção é o campo **hashtags** (163 registros; 4,6%), o que não constitui problema

Figura 3 – Percentual de valores ausentes nos campos coletados via API



Fonte: Elaborado pelo autor.

metodológico: o uso de *hashtags* é facultativo nas publicações e sua ausência não implica a inexistência de conteúdo textual classificável — o campo `note_tweet`, unidade central de análise, está integralmente preenchido em todos os 3.563 registros do corpus.

3.4.3 Distribuição do Comprimento dos Textos

Uma característica estrutural relevante do corpus, evidenciada pela AED, é o comprimento inusualmente elevado dos textos em relação ao formato convencional de publicações do X/Twitter. A mediana de **778 caracteres** e de **121 tokens** por publicação — valores muito superiores ao limite padrão de 280 caracteres da plataforma — confirma que a quase totalidade das publicações foi veiculada por meio do campo `note_tweet` (texto estendido), disponível para usuários com assinatura X Premium. O Quadro 7 apresenta as estatísticas descritivas completas.


Quadro 7 – Estatísticas descritivas do comprimento das publicações do corpus

Estatística	Caracteres	Tokens
Contagem	3.563	3.563
Média	783	123
Desvio padrão	254	40
Mínimo	282	38
1º quartil	596	94
Mediana	778	121
3º quartil	950	148
Máximo	2.503	381

Fonte: Elaborado pelo autor com base nos dados coletados.

Notavelmente, **nenhuma publicação** apresenta comprimento inferior a 50 caracteres ou a 5 tokens — limiares usualmente adotados para identificar textos curtos demais para classificação de sentimento. Esse resultado é diretamente explicado pela natureza da fonte: as publicações dos veículos monitorados consistem em resumos e chamadas de notícias que, mesmo no formato de *tweet*, apresentam densidade textual elevada. As distribuições por número de caracteres e por número de tokens são apresentadas na Figura 4.

Figura 4 – Distribuição do comprimento das publicações por número de caracteres (esquerda) e por número de tokens (direita). As linhas tracejadas vermelha e laranja indicam, respectivamente, os limiares de textos curtos e longos.



Fonte: Elaborado pelo autor.

No extremo oposto, 678 publicações (19,0%) ultrapassam 1.000 caracteres e 835 (23,4%) excedem 150 tokens. Esses textos mais longos não foram descartados, mas devem ser observados com atenção na etapa de pré-processamento: o modelo FinBERT-PT-BR, baseado na arquitetura BERT, aceita sequências de até 512 *tokens* após tokenização com *WordPiece*. Como a tokenização *WordPiece* é mais granular do que a contagem ingênua de palavras por espaços utilizada na AED, o número efetivo de *tokens* BERT é tipicamente superior ao contado aqui. Publicações que excedam o limite do modelo após tokenização serão truncadas automaticamente, e esse impacto constitui uma restrição reconhecida do modelo para textos mais longos.

3.4.4 Detecção e Tratamento de Duplicatas

A verificação de duplicatas revelou que **nenhum registro** apresenta `tweet_id` repetido, o que confirma a eficácia da restrição `UNIQUE` definida no esquema do banco de dados para prevenir a inserção duplicada de publicações durante ciclos de coleta sobrepostos.

A inspeção por conteúdo textual, contudo, identificou **31 textos com conteúdo idêntico**, envolvendo 54 registros agrupados em 23 grupos — todos provenientes do Info-Money. Esse padrão é consistente com a prática editorial de republicar a mesma manchete

em momentos distintos para ampliar o alcance da publicação, fenômeno documentado na literatura sobre comportamento de contas institucionais em plataformas de mídia social (Santana; Freitas, 2024). Para fins da análise de sentimento, os registros duplicados por conteúdo foram mantidos no corpus, uma vez que correspondem a eventos de publicação reais e independentes; sua eventual influência sobre o índice de sentimento agregado é mitigada pela granularidade temporal da agregação diária.

3.5 Pré-processamento Textual

O pré-processamento textual constitui uma etapa crítica em qualquer *pipeline* de PLN, com impacto direto sobre a qualidade das representações vetoriais e, consequentemente, sobre o desempenho do classificador de sentimento (Caseli; Nunes; Pagano, 2024). Para textos provenientes de mídias sociais, essa etapa é particularmente relevante dado o caráter informal, ruidoso e semanticamente denso desses dados, que inclui elementos típicos da linguagem de plataformas digitais — *hashtags*, menções, URLs e emojis — que não fazem parte do vocabulário para o qual os modelos de linguagem convencionais foram projetados (Santana; Freitas, 2024).

As decisões de pré-processamento adotadas neste trabalho foram calibradas em função de duas considerações centrais: (i) as características específicas das publicações financeiras do X/Twitter identificadas na AED (seção 3.4); e (ii) os requisitos de entrada de cada abordagem de classificação. Em particular, o modelo FinBERT-PT-BR, cujo tokenizador interno — baseado em *WordPiece* — já realiza parte da segmentação subtextual de forma automática (Santos; Bianchi; Costa, 2023; Devlin *et al.*, 2019), dispensa etapas de normalização agressiva como *stemização* e remoção de *stopwords*, pois captura variações morfológicas por meio de seus mecanismos de atenção contextual (Jurafsky; Martin, 2026). Isso motivou a existência de dois fluxos de pré-processamento distintos no *pipeline*, descritos nas subseções a seguir.

As funções de limpeza residem em `app/shared/text_cleaner.py`, módulo transversal compartilhado entre os estágios de pré-processamento e classificação, garantindo consistência e evitando duplicação de código.

3.5.1 Fluxo Completo — Abordagem Léxica

3.5.1.1 Substituição de URLs

Toda sequência de caracteres iniciada por `http` ou `https` é substituída pelo *token* especial [URL], preservando a informação de que um *link* estava presente sem carregar o conteúdo do endereço.

3.5.1.2 Conversão de Emojis para *Name Codes*

Os emojis são convertidos para seus *name codes* por meio de `emoji.demojize()` — por exemplo, 📈 torna-se `:chart_increasing:`. Essa abordagem preserva o potencial semântico dos emojis — que frequentemente sinalizam polaridade de forma explícita no discurso financeiro (Sprenger *et al.*, 2014) — tornando-os processáveis pelo léxico.

3.5.1.3 Substituição de Menções

Referências a usuários (`@usuário`) são substituídas pelo *token* `[MENTION]`, por não contribuírem para a polaridade semântica do texto.

3.5.1.4 Remoção do Símbolo de *Hashtag*

O caractere `#` é removido, mas o termo associado é preservado — `#IBOV` torna-se `IBOV`. Essa decisão mantém o conteúdo semântico relevante para o domínio financeiro sem o marcador de plataforma (Ranco *et al.*, 2015).

3.5.1.5 Normalização de Espaçamento

Sequências de espaços múltiplos, tabulações e quebras de linha são colapsadas em um único espaço e espaços residuais nas extremidades são removidos.

3.5.1.6 Normalização de Caixa com Preservação de Entidades

O texto é convertido para letras minúsculas, com exceção de categorias de termos que devem permanecer em maiúsculas para preservar sua identidade semântica no domínio financeiro:

- ***Tickers de ações***: sequências do padrão `[A-Z]{4,5}[0-9]{1,2}` (e.g., `PETR4`, `VALE3`, `ITUB4`);
- ***Entidades financeiras*** do conjunto `FINANCIAL_ENTITIES`: instituições e órgãos reguladores (BCB, CVM, BNDDES, BTG, XP), índices e instrumentos (IBOV, IBOVESPA, IPCA, SELIC, CDI, FII, IFIX, IPO), e a bolsa de valores (B3, COPOM), entre outros;
- ***Tokens especiais***: `[URL]` e `[MENTION]`, inseridos nas etapas anteriores.

3.5.1.7 Remoção de *Stopwords*

Palavras funcionais de alta frequência sem valor semântico para a tarefa de classificação de polaridade são removidas, utilizando a lista de *stopwords* do português disponível na biblioteca NLTK (Jurafsky; Martin, 2026).

3.5.1.8 Lematização

As palavras são reduzidas à sua forma canônica (lema) por meio do modelo de língua portuguesa `pt_core_news_lg` da biblioteca `spaCy`², preservando distinções lexicais relevantes ao domínio (e.g., “alta” como substantivo versus “alto” como adjetivo).

O Quadro 8 ilustra o resultado da aplicação sequencial das oito etapas a uma publicação de exemplo.

Quadro 8 – Exemplo de aplicação da função `clean()` a uma publicação do corpus

Etapa	Texto
Original	 Alta do #IBOV! Saiba mais em @InfoMoney
Após <code>clean()</code>	:rotating_light: alta IBOV! saber [URL] [MENTION]

Fonte: Elaborado pelo autor com base no código-fonte de `app/shared/text_cleaner.py`.

3.5.2 Fluxo Reduzido — FinBERT-PT-BR

O FinBERT-PT-BR utiliza um fluxo de pré-processamento próprio, implementado no método `preprocess()` da classe `FinBertPTBRAnalyzer` (`app/core/processing/bert/finbert_ptbr.py`), que importa seletivamente as funções de `app/shared/text_cleaner.py` e aplica apenas seis das oito etapas descritas na subseção 3.5.1. As diferenças em relação ao fluxo completo são:

- **Emojis:** em vez de converter para *name codes*, os emojis são **removidos** via `emoji.replace_emoji()`. Essa decisão decorre do fato de que o vocabulário do FinBERT-PT-BR não foi treinado sobre *name codes* de emojis, tornando sua presença potencialmente ruidosa para o modelo;
- **Remoção de *stopwords* e lematização: não aplicadas.** Como o BERT opera sobre sequências completas de *tokens* e captura dependências contextuais de longa distância por meio do mecanismo de atenção, a remoção de palavras funcionais ou a redução morfológica podem degradar a representação contextual do texto (Devlin *et al.*, 2019; Santos; Bianchi; Costa, 2023).

O Quadro 9 sintetiza as diferenças entre os dois fluxos de pré-processamento.

3.5.3 Fluxo Reduzido — BERTimbau Ajustado

O BERTimbau ajustado (subseção 3.6.4) utiliza um fluxo de pré-processamento idêntico ao descrito na subseção 3.5.2 para o FinBERT-PT-BR, implementado no mé-

² Disponível em: <https://spacy.io/>. Acesso em: 12 fev. 2026.

Quadro 9 – Comparativo entre os fluxos de pré-processamento aplicados às três abordagens de classificação

Etapa	Léxico (<code>clean()</code>)	FinBERT-PT-BR	BERTimbau
Substituição de URLs	✓	✓	✓
Emojis → <i>name codes</i>	✓	—	—
Remoção de emojis	—	✓	✓
Substituição de menções	✓	✓	✓
Remoção de #	✓	✓	✓
Normalização de espaços	✓	✓	✓
Normalização de caixa	✓	✓	✓
Remoção de <i>stopwords</i>	✓	—	—
Lematização	✓	—	—

Fonte: Elaborado pelo autor com base no código-fonte de `app/shared/text_cleaner.py`, `app/core/processing/bert/finbert_ptbr.py` e `app/core/processing/bert/bert_timbau.py`.

todo `preprocess()` da classe `BERTimbauAnalyzer` (`app/core/processing/bert/bert_timbau.py`). As mesmas seis etapas são aplicadas na mesma ordem: substituição de URLs, remoção de emojis, substituição de menções, remoção do símbolo de *hashtag*, normalização de espaçamento e normalização de caixa com preservação de entidades financeiras. A justificativa é análoga: por operar sobre o tokenizador *WordPiece* interno ao BERT, o modelo processa as variações morfológicas por meio do mecanismo de atenção contextual, tornando desnecessárias as etapas de remoção de *stopwords* e lematização (Devlin *et al.*, 2019).

Uma distinção relevante em relação ao FinBERT-PT-BR diz respeito à escolha da variante do modelo base. O BERTimbau é utilizado na versão `bert-base-portuguese-cased` (`neuralmind/bert-base-portuguese-cased`), que preserva a distinção entre maiúsculas e minúsculas durante a tokenização. Essa escolha é coerente com a etapa de normalização de caixa com preservação de entidades: ao manter *tickers* (e.g., PETR4, VALE3) e siglas financeiras (e.g., COPOM, SELIC, B3) em maiúsculas, o pré-processamento disponibiliza ao modelo um sinal de identidade semântica que o tokenizador *cased* é capaz de explorar diretamente na construção das representações contextuais (Souza; Nogueira; Lotufo, 2020).

3.5.4 Testes Unitários

O módulo de pré-processamento é acompanhado de um arquivo de testes unitários co-localizado em `app/shared/text_cleaner_tests.py`, executado via `pytest` a partir da raiz do projeto. Os testes verificam o comportamento de cada função individualmente — cobrindo URLs, emojis, menções, *hashtags*, espaçamento, normalização de caixa, *stopwords*

e lematização —, assegurando que alterações futuras no módulo não introduzam regressões silenciosas no fluxo de pré-processamento.

3.6 Abordagens de Classificação de Sentimento

Em consonância com o Objetivo Específico 4 estabelecido na seção 1.3 — avaliar e comparar o desempenho de diferentes abordagens de classificação de sentimento no domínio financeiro em português —, este trabalho avalia três paradigmas metodológicos distintos: a abordagem **baseada em léxico**, a abordagem **baseada em modelo de linguagem pré-treinado especializado por domínio** (FinBERT-PT-BR) e a abordagem **baseada em modelo de linguagem pré-treinado genérico ajustado por *fine-tuning* em dados locais** (BERTimbau). A distinção entre os dois paradigmas neurais é deliberada: enquanto o FinBERT-PT-BR obtém sua especialização por meio de pré-treinamento sobre um corpus financeiro de larga escala em etapa anterior a este trabalho, o BERTimbau parte de um modelo genérico e adquire especialização *a posteriori*, por meio de ajuste fino sobre o próprio corpus de *tweets* financeiros coletados. Essa dicotomia — especialização prévia de domínio versus especialização *post hoc* de gênero textual e subdomínio — constitui o eixo central da comparação empírica apresentada no Capítulo 4. A inclusão de métodos léxicos permite situar ambas as abordagens neurais em relação às ferramentas de referência disponíveis para o português, orientando recomendações práticas para trabalhos futuros (Kearney; Liu, 2014; Sousa *et al.*, 2025).

3.6.1 Abordagem Baseada em Léxico: OpLexicon

Métodos baseados em léxico (*lexicon-based*) classificam o sentimento de um texto a partir da correspondência de seus termos a um dicionário de polaridade previamente construído, no qual cada palavra ou expressão recebe um escore de valência positiva, negativa ou neutra (Liu; Zheng; Song, 2020). A principal vantagem dessa abordagem reside na transparência e na ausência de necessidade de dados de treinamento rotulados. Sua limitação central está na incapacidade de capturar negação, ironia e vocabulário específico do domínio não contemplado pelo léxico (Loughran; McDonald, 2011; Kearney; Liu, 2014).

3.6.1.1 Escolha do Recurso Léxico

O **OpLexicon v3.0** foi selecionado como léxico principal por duas razões: (i) abrangência léxica consideravelmente maior (32.191 entradas de *tokens* não lematizados, cobrindo formas coloquiais recorrentes em *tweets*); e (ii) construção orientada ao português brasileiro, com termos do jargão financeiro local. O **SentiLex-PT** (Silva; Carvalho; Sarmento, 2012), por sua vez, é implementado em paralelo como segunda abordagem léxica (Seção 3.6.2), permitindo avaliar o impacto da anotação manual e da cobertura de formas flexionadas sobre o desempenho no domínio financeiro.

3.6.1.2 Estrutura do Léxico

O OpLexicon v3.0 é distribuído como arquivo de texto tabular (*tab-separated values*) sem cabeçalho, com quatro colunas: `term` (lema), `type` (classe gramatical), `polarity` (polaridade inteira: +1, -1 ou 0) e `polarity_revision` (origem da entrada: A para revisão manual ou C para atribuição automática). A indexação por lemas — e não por formas flexionadas — é a razão pela qual a lematização constitui etapa obrigatória do pré-processamento para esta abordagem, conforme detalhado na subseção 3.5.1.

3.6.1.3 Implementação e Protocolo de Pontuação

A implementação foi realizada no quinto estágio do *pipeline* por meio da classe `OpLexiconAnalyzer`, definida em `app/core/processing/lexicon/op_lexicon.py`. A classe herda de `BaseSentimentAnalyzer` — a mesma classe abstrata (ABC) que fundamenta o `FinBertPTBRAnalyzer` —, garantindo interface uniforme entre as duas abordagens e extensibilidade para classificadores futuros.

O protocolo de pontuação compreende as seguintes etapas:

1. **Seleção dos registros:** o método `run()` recupera exclusivamente as publicações que já possuem classificação humana em `tweets_classification` mas ainda não foram processadas pelo OpLexicon, garantindo que a comparação opere sobre o mesmo *gold standard* utilizado pelo FinBERT-PT-BR;
2. **Pré-processamento:** cada texto é submetido ao método `preprocess()`, que aplica o fluxo completo descrito na subseção 3.5.1, incluindo lematização via `spaCy` — etapa obrigatória para maximizar a taxa de correspondência com as entradas do léxico, que indexa lemas e não formas flexionadas;
3. **Carregamento do léxico:** o método `load_model()` lê o arquivo `lexico_v3.0.txt` e constrói um dicionário em memória no formato `{lema: polaridade}`, com tempo de carga desprezível e sem demanda de GPU;
4. **Pontuação agregada:** para cada *token* do texto pré-processado, consulta-se o dicionário léxico. *Tokens* ausentes recebem pontuação zero e são excluídos da agregação. A polaridade final é calculada pela média aritmética dos escores dos *tokens* com entrada no léxico, conforme a Equação 3.1:

$$\bar{p} = \frac{1}{|T^*|} \sum_{t \in T^*} \text{pol}(t) \quad (3.1)$$

onde $T^* = \{t \in T \mid \text{pol}(t) \neq 0\}$ é o subconjunto de *tokens* com polaridade não-nula e $\text{pol}(t)$ é a polaridade do *token* t no léxico. Caso $T^* = \emptyset$, o texto é classificado como Neutro com escore zero.

5. **Limiarização:** a classe final é determinada por um limiar $\theta = 0,05$ aplicado à média $\bar{p}$: se $\bar{p} > \theta$, a publicação é classificada como Positivo; se $\bar{p} < -\theta$, como Negativo; caso contrário, como Neutro. O valor reduzido do limiar reflete a alta proporção esperada de *tokens* financeiros sem correspondência no léxico (siglas de ativos, nomes de emissores, jargão de derivativos), que dilui a magnitude da média sem necessariamente indicar neutralidade semântica;
6. **Persistência:** os resultados são armazenados em `tweets_classification` com `classifier = "OpLexicon"` e o respectivo `score`, permitindo comparação direta com as anotações humanas e com o FinBERT-PT-BR na etapa de avaliação (subseção 3.6.5).

3.6.2 Abordagem Baseada em Léxico: SentiLex-PT

3.6.2.1 Fundamentação da Escolha

O **SentiLex-PT** (Silva; Carvalho; Sarmento, 2012) foi incorporado como segunda abordagem léxica com o objetivo de ampliar a validade comparativa da avaliação. Enquanto o OpLexicon v3.0 é construído sobre um processo semiautomático voltado ao português brasileiro, o SentiLex-PT decorre de um esforço de anotação manual, o que lhe confere características complementares relevantes para o domínio financeiro:

1. **Anotação manual:** os 7.014 lemas (expandidos para 82.347 formas flexionadas na versão SentiLex-PT02) foram anotados manualmente por especialistas segundo a taxonomia *Manually Annotated* (ANOT:MAN), resultando em um recurso de alta precisão intrínseca (Silva; Carvalho; Sarmento, 2012);
2. **Cobertura de formas flexionadas:** a versão SentiLex-PT02, adotada neste trabalho, contém formas nominais, adjetivais e verbais flexionadas, dispensando etapa de lematização e tornando-a mais adequada ao processamento de *tweets* — textos curtos com vocabulário coloquial e morfologia variada;
3. **Validade científica consolidada:** o SentiLex-PT é amplamente utilizado como referência em estudos de análise de sentimento em português (Liu; Zheng; Song, 2020), permitindo contextualizar os resultados obtidos neste trabalho em relação à literatura.

3.6.2.2 Estrutura do Léxico

O SentiLex-PT02 é distribuído como arquivo de texto simples, com uma entrada por linha no formato:

`forma.PoS,POL:N;ANOT:TAG`

onde **forma** é a palavra flexionada em letras minúsculas, **PoS** é a classe gramatical (Adj, N, V, entre outras), **POL** é a polaridade inteira (1 = positivo, -1 = negativo, 0 = neutro) e **ANOT** é o tipo de anotação. A Tabela 3 apresenta exemplos representativos do léxico no domínio financeiro.

Tabela 3 – Exemplos de entradas do SentiLex-PT02 no domínio financeiro

Forma	PoS	ANOT	POL
lucro	N	MAN	1
crescimento	N	MAN	1
valorização	N	MAN	1
queda	N	MAN	-1
prejuízo	N	MAN	-1
crise	N	MAN	-1
empresa	N	MAN	0
mercado	N	MAN	0

Fonte: Adaptado de Silva, Carvalho e Sarmiento (2012).

3.6.2.3 Implementação e Protocolo de Pontuação

A implementação foi realizada no quinto estágio do *pipeline* por meio da classe `SentiLexAnalyzer`, definida em `app/core/processing/lexicon/senti_lex.py`. A classe herda de `BaseSentimentAnalyzer` (`app/core/processing/base_analyzer.py`), garantindo interface uniforme com o `OpLexiconAnalyzer` e o `FinBertPTBRAnalyzer`.

O protocolo de pontuação compreende as seguintes etapas:

1. **Seleção dos registros:** o método `run()` recupera exclusivamente as publicações que já possuem classificação humana em `tweets_classification`, utilizadas como *gold standard*;
2. **Pré-processamento:** cada texto é submetido ao método `preprocess()`, que aplica o fluxo descrito na seção 3.5 — remoção de URLs, menções, caracteres especiais e conversão para letras minúsculas. Diferentemente do `OpLexiconAnalyzer`, não é realizada lematização via `spaCy`, pois o SentiLex-PT02 já contém formas flexionadas;
3. **Carregamento do léxico:** o método `load_model()` lê o arquivo `data/SentiLex-PT02.txt` e constrói um dicionário em memória no formato `{forma: polaridade}`, com tempo de carga desprezível e sem demanda de GPU;
4. **Pontuação com janela de negação:** para cada *token* do texto pré-processado, consulta-se o dicionário léxico. A fim de capturar negações simples — padrão frequente em textos financeiros, como “*não houve crescimento*” —, aplica-se uma janela de negação de três *tokens*: quando um *token* pertencente ao conjunto de marcadores

de negação³ precede uma palavra com polaridade não-nula dentro desse intervalo, o sinal da polaridade é invertido. A pontuação final é dada por:

$$\bar{p} = \sum_{t \in T^*} \text{pol_neg}(t) \quad (3.2)$$

onde $T^* = \{t \in T \mid \text{pol}(t) \neq 0\}$ é o subconjunto de *tokens* com polaridade não-nula e $\text{pol_neg}(t)$ é a polaridade do *token* t após aplicação da janela de negação. Caso $T^* = \emptyset$, o texto é classificado como Neutro com escore zero;

5. **Limiarização:** a classe final é determinada diretamente pelo sinal da pontuação acumulada $\bar{p}$: se $\bar{p} > 0$, a publicação é classificada como Positivo; se $\bar{p} < 0$, como Negativo; se $\bar{p} = 0$, como Neutro. O escore de confiança reportado é dado por $|\bar{p}|/|T|$, normalizado ao intervalo $[0, 1]$, análogo ao *score* de probabilidade retornado pelo FinBERT-PT-BR;
6. **Persistência:** os resultados são armazenados em `tweets_classification` com `classifier = "SentiLex-PT"` e o respectivo escore, permitindo comparação direta com as demais abordagens conforme descrito na subseção 3.6.5.

3.6.3 Abordagem Baseada em Modelo de Linguagem Pré-treinado: FinBERT-PT-BR

3.6.3.1 Fundamentação da Escolha

O **FinBERT-PT-BR** (Santos; Bianchi; Costa, 2023) foi selecionado como ferramenta central da abordagem neural por três razões fundamentais, já antecipadas no Capítulo 2:

1. **Especialização no domínio:** o modelo foi pré-treinado sobre um corpus de 1,4 milhão de textos financeiros em português, incluindo notícias, relatórios e publicações de veículos especializados, o que lhe confere representações contextuais calibradas para o vocabulário técnico do mercado financeiro brasileiro;
2. **Desempenho superior no estado da arte:** nos experimentos reportados por Santos, Bianchi e Costa (2023), o FinBERT-PT-BR superou modelos de linguagem genéricos e abordagens léxicas em tarefas de classificação de sentimento financeiro em português;
3. **Disponibilidade pública:** o modelo está disponível publicamente no repositório *Hugging Face* sob o identificador `lucas-leme/FinBERT-PT-BR`, garantindo a reprodutibilidade da metodologia proposta.

³ Conjunto de marcadores: *não, nunca, jamais, nem, nenhum, nenhuma, tampouco, sequer*.

3.6.3.2 Arquitetura do Modelo

O FinBERT-PT-BR é construído sobre a arquitetura **BERT** (*Bidirectional Encoder Representations from Transformers*) (Devlin *et al.*, 2019), que implementa o mecanismo de atenção multi-cabeça proposto por Vaswani *et al.* (2017). A característica central do BERT — a codificação bidirecional do contexto — permite que a representação de cada *token* incorpore informações tanto dos termos que o precedem quanto dos que o sucedem na sequência, o que é particularmente relevante para a interpretação de negações e modificadores de intensidade frequentes no discurso financeiro (e.g., “*não* sobe”, “*queda* acentuada”).

O modelo base utilizado para o *fine-tuning* é o **BERTimbau** (Souza; Nogueira; Lotufo, 2020), pré-treinado sobre um corpus de 2,68 bilhões de palavras em português brasileiro. Sobre esse modelo base, Santos, Bianchi e Costa (2023) realizaram o *fine-tuning* para a tarefa de classificação de sentimento financeiro em três classes: **Positivo**, **Negativo** e **Neutro**.

3.6.3.3 Implementação e Protocolo de Inferência

A inferência foi implementada no quinto estágio do *pipeline* (`app/core/processing/bert/`), por meio da classe `FinBertPTBRAnalyzer`, definida em `app/core/processing/bert/finbert_ptbr.py`. A classe herda de `BaseSentimentAnalyzer` (`app/core/processing/base_analyzer.py`), uma classe abstrata (ABC) que estabelece o contrato de interface para qualquer analisador de sentimento no *pipeline*, garantindo extensibilidade para futuros modelos.

O protocolo de inferência compreende as seguintes etapas:

1. **Seleção dos registros:** o método `run()` recupera via `app/shared/db/database.py` exclusivamente as publicações que já possuem classificação humana em `tweets_classification` mas ainda não foram processadas pelo FinBERT-PT-BR. Esse critério garante que a inferência do modelo opere sobre o mesmo subconjunto utilizado como *gold standard*, permitindo comparação direta entre as duas abordagens;
2. **Pré-processamento:** cada texto é submetido ao método `preprocess()` da própria classe, que aplica o fluxo reduzido descrito na subseção 3.5.2 — substituição de URLs e menções, remoção de emojis, remoção do símbolo de *hashtag*, normalização de espaços e normalização de caixa com preservação de entidades financeiras;
3. **Carregamento do modelo:** o tokenizador e o modelo são instanciados via `AutoTokenizer` e `BertForSequenceClassification`, encapsulados em um objeto `pipeline` da biblioteca `transformers` com `task="text-classification"`;

4. **Inferência:** cada publicação é classificada pelo método `predict_text()`, com `batch_size=32`. O modelo retorna o *label* predito e o escore de confiança (*score*) associado;
5. **Mapeamento de *labels*:** os rótulos em inglês retornados pelo modelo são normalizados para o português: POSITIVE → positivo, NEGATIVE → negativo, NEUTRAL → neutro;
6. **Persistência e visualização:** os resultados são armazenados em `tweets_classification` com `classifier = "FinBERT-PT-BR"` e o respectivo `score`. O painel Streamlit de processamento (`app/dashboard/pages/processing.py`), invocado via `make dashboard`, apresenta a comparação entre o sentimento predito pelo modelo e o sentimento anotado pelo humano tweet a tweet, além de métricas de concordância.

3.6.4 Abordagem Baseada em Modelo de Linguagem Pré-treinado com *Fine-tuning*: BERTimbau

3.6.4.1 Fundamentação da Escolha

O **BERTimbau** (Souza; Nogueira; Lotufo, 2020) foi selecionado como modelo base para a abordagem de *fine-tuning* local por três razões complementares:

1. **Estado da arte para o português brasileiro genérico:** o BERTimbau é o modelo BERT pré-treinado de referência para a língua portuguesa, treinado sobre um corpus de 2,68 bilhões de palavras extraídas de fontes diversificadas — Wikipedia em português, Common Crawl e BrWaC (Souza; Nogueira; Lotufo, 2020). Sua adoção como base de *fine-tuning* é amplamente consolidada na literatura de PLN em português, inclusive como ponto de partida do próprio FinBERT-PT-BR (Santos; Bianchi; Costa, 2023);
2. **Endereçamento direto do desalinhamento de domínio:** o FinBERT-PT-BR foi pré-ajustado sobre notícias e relatórios financeiros, gênero textual estruturalmente distinto das publicações do X/Twitter. O *fine-tuning* do BERTimbau diretamente sobre o corpus de *tweets* coletados — incluindo suas características estilísticas de informalidade, densidade de abreviações e uso de emojis e *hashtags* — aborda essa limitação de forma explícita, produzindo um modelo alinhado ao gênero e ao subdomínio específico avaliado;
3. **Adequação ao tamanho do corpus:** a versão **base** do BERTimbau (110 milhões de parâmetros) foi preferida à versão **large** (335 milhões de parâmetros) pela maior adequação ao tamanho do corpus rotulado disponível. Modelos de maior capacidade requerem volumes de dados proporcionalmente maiores para generalização estável, e o uso da versão **large** sobre um corpus de algumas centenas ou poucos milhares

de exemplos aumentaria o risco de *overfitting* sem ganho garantido de desempenho (Devlin *et al.*, 2019).

3.6.4.2 Arquitetura e Protocolo de *Fine-tuning*

O modelo base utilizado é o `neuralmind/bert-base-portuguese-cased`, disponível publicamente no repositório *Hugging Face*. Sobre esse modelo, realiza-se o *fine-tuning* para a tarefa de classificação de sequência em três classes — **Positivo**, **Neutro** e **Negativo** —, por meio da adição de uma camada de classificação linear sobre a representação do *token* especial [CLS], que codifica o sentido global da sequência de entrada (Devlin *et al.*, 2019).

O protocolo de *fine-tuning* é implementado no script `app/core/processing/bert/bert_timbau_fine_tuner.py` e compreende as seguintes decisões de configuração:

- **Particionamento:** o corpus rotulado é particionado em etapa dedicada, anterior ao *fine-tuning*, conforme o protocolo descrito na subseção 3.3.4. O particionamento é gerenciado pela classe `DatasetSplitRepository` (`app/shared/db/dataset_split.py`), que persiste o resultado na tabela `dataset_split` em dois conjuntos mutuamente exclusivos: (i) **hold-out de teste** ($\approx 15\%$ dos registros), extraído por amostragem estratificada com `random_state=42` e reservado exclusivamente para a avaliação comparativa final descrita na subseção 3.6.5, marcado com `split='test'` e `fold=NULL`; e (ii) **conjunto de treinamento** ($\approx 85\%$), subdividido em $K = 4$ folds por validação cruzada estratificada (`StratifiedKFold`, $K = 4$, `shuffle=True`, `random_state=42`), marcado com `split='train'` e `fold` $\in \{1, 2, 3, 4\}$;
- **Validação cruzada e seleção do modelo:** o *fine-tuning* é executado $K = 4$ vezes, uma por fold. Em cada iteração k , os registros com `fold` $\neq k$ ($\approx 64\%$ do total rotulado) formam o conjunto de treinamento efetivo, e os registros com `fold` $= k$ ($\approx 21\%$) formam o conjunto de validação. Ao término das K iterações, o modelo correspondente ao fold com maior F1-Score macro na validação é selecionado como modelo definitivo e persistido em `models/bert-timbau-sentiment/`, acompanhado do relatório de classificação e do resumo do K-Fold em `models/bert-timbau-sentiment/eval/`;
- **Ponderação de classes:** dado o desbalanceamento esperado em favor da classe neutra, os pesos por classe são calculados via `compute_class_weight(class_weight='balanced')` da biblioteca `scikit-learn` e injetados na função de perda (`CrossEntropyLoss`) por meio de uma subclasse `WeightedTrainer`, garantindo que o modelo não colapse para prever sistematicamente a classe majoritária;
- **Hiperparâmetros:** taxa de aprendizado 5×10^{-5} , tamanho de lote (*batch size*) 8, comprimento máximo de sequência 512 *tokens*, razão de *warmup* 0,1 e decaimento de pesos (*weight decay*) 10^{-2} . Esses valores foram determinados por busca empírica

sobre o conjunto de validação cruzada e são consistentes com as recomendações dos autores do BERT para *fine-tuning* em conjuntos de dados de tamanho moderado (Devlin *et al.*, 2019);

- **Early stopping:** o treinamento de cada fold é limitado a doze épocas, com critério de parada antecipada (*patience* = 2) monitorando o F1-Score macro no conjunto de validação do fold corrente. O *checkpoint* com melhor F1-Score macro é restaurado automaticamente ao término de cada iteração, prevenindo o *overfitting* à distribuição de treinamento;
- **Reprodutibilidade:** a semente aleatória `random_state=42` é fixada em todas as operações estocásticas do treinamento (`seed` do `TrainingArguments`), garantindo que execuções sucessivas sobre o mesmo corpus produzam resultados idênticos.

O modelo ajustado, o tokenizador e o mapeamento de rótulos (`id2label.json`) são persistidos em `models/bert-timbau-sentiment/`, e o relatório de classificação e a matriz de confusão no conjunto de validação são salvos em `models/bert-timbau-sentiment/eval/`, para referência na análise apresentada no Capítulo 4.

3.6.4.3 Implementação e Protocolo de Inferência

A inferência é implementada pela classe `BERTimbauAnalyzer`, definida em `app/core/processing/bert_timbau.py`. Assim como `FinBertPTBRAnalyzer`, a classe herda de `BaseSentimentAnalyzer` (`app/core/processing/base_analyzer.py`), garantindo que ambos os analisadores compartilhem o mesmo contrato de interface e possam ser alternados pelo painel de processamento sem modificações adicionais. O protocolo de inferência é análogo ao descrito na subseção 3.6.3.3, com as seguintes particularidades:

1. **Pré-requisito de treinamento:** a classe verifica na inicialização a existência do diretório `models/bert-timbau-sentiment/`; caso ausente, emite um erro orientando o usuário a executar `python -m pipeline.05_processing.bert_timbau_fine_tuner` (atalho: `make finetune`) antes da inferência;
2. **Carregamento do modelo:** tokenizador e modelo são carregados diretamente do diretório local via `AutoTokenizer` e `AutoModelForSequenceClassification`, encapsulados em objeto `pipeline` da biblioteca `transformers` com `task="text-classification"`;
3. **Mapeamento de rótulos:** o modelo fine-tuned emite rótulos em português (`positivo`, `negativo`, `neutro`) diretamente via `id2label`, dispensando a etapa de normalização de inglês para português aplicada ao FinBERT-PT-BR;

4. **Persistência:** os resultados são armazenados em `tweets_classification` com `classifier = "BERTimbau"` e o respectivo escore de confiança, seguindo o mesmo esquema de persistência descrito na subseção 3.6.3.3 para o FinBERT-PT-BR.

3.6.5 Métricas de Avaliação das Abordagens

A comparação entre as quatro abordagens — OpLexicon, SentiLex-PT, FinBERT-PT-BR e BERTimbau ajustado — será realizada exclusivamente sobre o conjunto de teste *hold-out* definido na subseção 3.3.4, que constitui o *gold standard* efetivo da avaliação. Essa restrição é necessária para garantir comparabilidade: como o BERTimbau ajustado viu parte do corpus rotulado durante o treinamento, avaliá-lo sobre o conjunto completo produziria estimativas otimistas de desempenho incomparáveis às das demais abordagens. A implementação das métricas está organizada no sexto estágio do *pipeline* (`app/core/evaluation/metrics.py`), invocado via `make evaluate`. As métricas calculadas são:

- **Acurácia:** proporção de classificações corretas sobre o total de instâncias do conjunto de teste;
- **Precisão, Revocação e F1-Score** por classe: métricas calculadas individualmente para as classes Positivo, Negativo e Neutro, permitindo identificar vieses de classificação em classes específicas;
- **F1-Score macro:** média aritmética não ponderada dos F1-Scores de cada classe, tratando as classes como igualmente importantes independentemente de seu tamanho — métrica de referência para comparação entre abordagens em corpora desbalanceados;
- **Matriz de confusão:** representação tabular da distribuição de acertos e erros por classe, útil para identificar padrões sistemáticos de classificação incorreta entre as três abordagens.

A limitação inerente à anotação por avaliador único — ausência de cálculo de concordância interanotadores (*inter-annotator agreement*) — é reconhecida como uma restrição metodológica do presente trabalho.

3.7 Pipeline Integrado de PLN


O conjunto das etapas descritas nas seções anteriores foi organizado em um *pipeline* integrado de PLN de ponta a ponta (*end-to-end*), implementado em Python. A modularidade da implementação garante que cada etapa possa ser executada, auditada e substituída de forma independente, o que é um requisito central para a reprodutibilidade da metodologia proposta (Santos; Bianchi; Costa, 2023).

3.7.1 Visão Geral do *Pipeline*

O *pipeline* é estruturado em seis etapas sequenciais, conforme ilustrado na Figura 5:

1. **Coleta via API:** interação com o *endpoint* `GET /2/users/{id}/tweets` da API v2 do X/Twitter, com autenticação por Bearer Token e paginação iterativa dos resultados, conforme detalhado na subseção 3.2.4;
2. **Persistência em banco de dados:** os registros retornados pela API são armazenados diretamente no banco de dados PostgreSQL — provisionado em contêiner Docker — nas tabelas `tweets` e `collection_log`, eliminando a necessidade de arquivos intermediários em disco;
3. **Rotulagem manual:** as publicações persistidas são exibidas sequencialmente na ferramenta de anotação (*Classifier App*), onde o anotador atribui relevância financeira e polaridade de sentimento a cada registro, conforme o protocolo descrito na seção 3.3;
4. **AED e pré-processamento textual:** o corpus rotulado é inspecionado estatisticamente e submetido às transformações linguísticas descritas nas Seções 3.4 e 3.5;
5. **Classificação de sentimento:** o corpus pré-processado é submetido às quatro abordagens de classificação de sentimento descritas na seção 3.6: (a) abordagem léxica via OpLexicon v3.0; (b) abordagem léxica via SentiLex-PT; (c) abordagem neural via FinBERT-PT-BR; e (d) abordagem neural via BERTimbau ajustado. Todas gravam os resultados em `tweets_classification` com o respectivo campo `classifier`, permitindo comparação direta com o *gold standard* humano na etapa de avaliação;
6. **Agregação e análise:** as classificações individuais são agregadas temporalmente e os resultados são comparados entre as abordagens e analisados à luz do contexto macroeconômico do período, conforme apresentado no Capítulo 4.

Figura 5 – Diagrama do *pipeline* integrado de PLN para análise de sentimento de publicações financeiras no X/Twitter



Fonte: Elaborado pelo autor.

3.7.2 Ambiente de Execução e Ferramentas

A implementação foi realizada na linguagem **Python 3.11**, escolhida por sua ampla adoção na comunidade de PLN e aprendizado de máquina e pela disponibilidade de ecossistema maduro de bibliotecas especializadas. O Quadro 10 lista as principais dependências utilizadas e suas respectivas funções no *pipeline*.

Quadro 10 – Principais bibliotecas Python utilizadas no *pipeline* e respectivas funções

Biblioteca	Versão	Função no <i>Pipeline</i>
<code>requests</code>	≥ 2.31	Requisições HTTP à API v2 do X/Twitter com Bearer Token
<code>psycopg2</code>	≥ 2.9	Interface de comunicação com o banco de dados PostgreSQL
<code>streamlit</code>	≥ 1.35	Ferramenta de anotação manual (<i>Classifier App</i>) e painel de AED (<code>eda.py</code>)
<code>pandas</code>	≥ 2.0	Manipulação tabular do corpus, AED e construção do índice temporal
<code>transformers</code>	≥ 4.40	Carregamento e inferência com o modelo FinBERT-PT-BR
<code>torch</code>	≥ 2.2	<i>Backend</i> de inferência neural (PyTorch)
<code>scikit-learn</code>	≥ 1.4	Particionamento estratificado do corpus, cálculo de métricas de avaliação e pesos por classe para <i>fine-tuning</i>
<code>accelerate</code>	≥ 0.28	<i>Backend</i> de paralelização do <i>Trainer</i> da biblioteca <code>transformers</code> , requerido pelo protocolo de <i>fine-tuning</i> do BERTimbau
<code>datasets</code>	≥ 2.18	Estruturação eficiente de conjuntos de dados para o ciclo de <i>fine-tuning</i> supervisionado
<code>nltk</code>	≥ 3.8	Remoção de <i>stopwords</i> para abordagem léxica
<code>spacy</code>	≥ 3.7	Lematização com modelo <code>pt_core_news_lg</code>
<code>emoji</code>	≥ 2.10	Transliteração de emojis para texto
<code>plotly</code>	≥ 5.20	Visualizações interativas da AED e do índice de sentimento

Fonte: Elaborado pelo autor.

O código-fonte do *pipeline* está organizado como um pacote Python versionado, com dependências declaradas em arquivo `requirements.txt`, de modo a facilitar a reprodução dos experimentos em ambientes distintos.

3.8 Limitações da Pesquisa

A identificação e discussão honesta das limitações metodológicas integra os requisitos de rigor científico do método (Caseli; Nunes; Pagano, 2024). As limitações do presente trabalho operam em quatro dimensões: fonte de dados, representatividade do corpus, restrições do modelo e escopo analítico.

3.8.1 Limitações Relativas à Fonte e ao Período de Dados

Janela temporal restrita. O corpus cobre aproximadamente quatro meses de dados (outubro de 2025 a fevereiro de 2026), período que, embora suficiente para os objetivos descritivos desta pesquisa, impede generalizações sobre o comportamento do sentimento ao longo de ciclos econômicos mais longos. A limitação decorre das restrições de custo de acesso à API histórica do X/Twitter, conforme detalhado na subseção 3.2.3.

Dependência da API do X/Twitter. A coleta de dados via API está sujeita a alterações de política e estrutura de preços da plataforma, o que representa um risco de reprodutibilidade para pesquisas futuras que tentem replicar o protocolo com o mesmo instrumento de coleta. Mudanças nas políticas de acesso do X/Twitter têm sido frequentes desde a aquisição da plataforma em 2022, configurando uma instabilidade estrutural que afeta toda a literatura baseada em dados dessa fonte.

3.8.2 Limitações Relativas à Representatividade do Corpus

Restrição a dois veículos editoriais. O corpus é composto exclusivamente por publicações institucionais dos veículos InfoMoney e InvestingBrasil, o que circunscreve o sentimento capturado ao discurso editorial — mediado por critérios jornalísticos de seleção e enquadramento (*framing*) — e não ao sentimento difuso e espontâneo dos participantes do mercado. O índice resultante deve ser interpretado como medida do **sentimento editorial financeiro**, e não do sentimento do investidor em sentido amplo, conforme concebido por Baker e Wurgler (2007) e Bollen, Mao e Zeng (2011).

Ausência de anotação por múltiplos avaliadores. O *gold standard* construído para avaliação comparativa das abordagens foi anotado por um único avaliador, inviabilizando o cálculo de métricas de concordância interanotadores (e.g., Kappa de Cohen). A variabilidade intrínseca à tarefa de anotação de sentimento financeiro — especialmente para publicações de polaridade ambígua ou contextualmente dependente — representa uma fonte de incerteza não quantificada nos resultados de avaliação.

3.8.3 Limitações Relativas aos Modelos Pré-treinados

Tamanho reduzido do corpus de *fine-tuning* do FinBERT-PT-BR. Conforme reportado por Santos, Bianchi e Costa (2023), o *fine-tuning* do FinBERT-PT-BR foi realizado sobre apenas 503 textos anotados manualmente, um volume consideravelmente menor do que o utilizado em modelos análogos para o inglês (e.g., o FinBERT original de Araci (2019)). Isso pode limitar a robustez do modelo em subdomínios ou estilos textuais subrepresentados no corpus de *fine-tuning*.

Possível desalinhamento de domínio do FinBERT-PT-BR. O corpus de pré-treinamento do FinBERT-PT-BR é composto majoritariamente por notícias e relatórios financeiros, enquanto as publicações do X/Twitter apresentam características estilísticas

distintas: linguagem mais informal, alta densidade de abreviações, emojis e *hashtags*. Esse desalinhamento de domínio (*domain shift*) pode degradar o desempenho do modelo em relação ao reportado nos experimentos originais. Essa limitação é parcialmente endereçada pela inclusão da abordagem BERTimbau ajustada (subseção 3.6.4), cujo *fine-tuning* é realizado diretamente sobre o corpus de *tweets* financeiros coletados, alinhando o modelo ao gênero textual e ao subdomínio de interesse.

Cobertura léxica limitada no vocabulário financeiro especializado. O OpLexicon v3.0 foi construído a partir de um corpus de propósito geral, com cobertura parcial do vocabulário técnico do mercado financeiro brasileiro — siglas de ativos, nomes de emissores, jargão de derivativos e expressões idiomáticas do setor não estão contemplados no léxico. Na prática, isso implica alta taxa de *tokens* sem correspondência durante a pontuação agregada, reduzindo a magnitude dos escores e aumentando a probabilidade de classificação como Neutro. Essa limitação estrutural da abordagem léxica é um dos fatores que justificam a expectativa de que o FinBERT-PT-BR apresente desempenho superior nos resultados da avaliação comparativa.

Limitações específicas da abordagem BERTimbau ajustada. A estratégia de *fine-tuning* local introduz um conjunto próprio de restrições metodológicas, distintas das limitações do FinBERT-PT-BR:

- **Tamanho modesto do conjunto de *fine-tuning* e variância das estimativas.** O corpus rotulado disponível para treinamento é composto por poucas centenas a poucos milhares de exemplos, volume que produz estimativas de desempenho com variância potencialmente elevada quando obtidas de uma única partição *hold-out*. Embora o protocolo adotado — particionamento estratificado 70/15/15 com semente fixa (subseção 3.3.4) — garanta reprodutibilidade, ele não quantifica a estabilidade das métricas em relação a diferentes realizações do particionamento. Uma análise complementar de robustez por validação cruzada estratificada de k dobras ($k = 5$) é sugerida como extensão metodológica no Capítulo 4;
- **Propagação do viés do anotador único.** A limitação documentada na subseção 3.8.2 — ausência de anotação por múltiplos avaliadores — adquire gravidade adicional no contexto do BERTimbau ajustado: enquanto para o FinBERT-PT-BR e as abordagens léxicas o viés do anotador afeta apenas a métrica de avaliação, para o BERTimbau ele contamina também os pesos aprendidos pelo modelo. Decisões de polaridade subjetivas ou inconsistentes do anotador são internalizadas como sinal de treinamento, potencialmente amplificando padrões de erro sistemáticos na inferência;
- **Risco residual de *overfitting*.** Apesar das três salvaguardas empilhadas — *early stopping* monitorando F1-Score macro na validação (*patience* = 2), decaimento de pesos (*weight decay* = 10^{-2}) e seleção automática do *checkpoint* de melhor

desempenho na validação —, o risco de ajuste excessivo à distribuição de treinamento não é eliminado, especialmente se o corpus rotulado apresentar baixa diversidade estilística ou concentração temporal de eventos.

3.8.4 Limitações de Escopo Analítico

Ausência de modelagem preditiva. Este trabalho não inclui análise de correlação ou modelagem preditiva entre o índice de sentimento construído e variáveis de mercado (retornos, volume de negociação ou volatilidade). A validação do índice é exclusivamente qualitativa e descritiva. A investigação de relações quantitativas entre sentimento e comportamento de mercado, conforme documentado na literatura internacional (Tetlock, 2007; Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015), constitui uma extensão natural deste trabalho, sugerida como direcionamento de pesquisa futura no ??.

Ausência de análise de sentimento em nível de aspecto. A abordagem adotada classifica cada publicação com uma única polaridade global (*document-level*), sem distinguir o sentimento associado a entidades ou atributos específicos mencionados no texto (e.g., sentimento sobre determinada empresa, taxa de juros ou setor da economia). Conforme discutido na subseção 3.6.1, a análise de sentimento baseada em aspectos (*aspect-based sentiment analysis*) representa um nível de granularidade mais refinado, cuja implementação demandaria recursos de anotação e infraestrutura computacional além do escopo deste trabalho.

O reconhecimento dessas limitações não invalida os resultados obtidos, mas circunscreve o alcance das generalizações admissíveis e orienta a agenda de pesquisa futura apresentada no Capítulo 5.

4 AVALIAÇÃO EXPERIMENTAL

Este capítulo apresenta os resultados da avaliação comparativa das quatro abordagens de classificação de sentimento descritas na seção 3.6: OpLexicon v3.0, SentiLex-PT, FinBERT-PT-BR e BERTimbau ajustado. A avaliação foi conduzida exclusivamente sobre o conjunto de teste *hold-out* definido na subseção 3.3.4, composto por 373 publicações rotuladas manualmente pelo pesquisador, em conformidade com o protocolo detalhado no Capítulo 3.

A seção 4.1 descreve as condições de configuração do experimento. A seção 4.2 apresenta os resultados individuais de cada abordagem. A seção 4.3 realiza a análise comparativa consolidada entre as abordagens e, por fim, a seção 4.4 interpreta os achados à luz da literatura e dos objetivos da pesquisa.

4.1 Configuração Experimental

4.1.1 Conjunto de Teste

A avaliação comparativa foi realizada sobre um conjunto de teste composto por 373 publicações, extraídas do subconjunto rotulado manualmente conforme o protocolo de anotação descrito na seção 3.3. O conjunto corresponde à partição de teste (15%) obtida por particionamento estratificado com `random_state=42`, conforme detalhado na subseção 3.3.4. A estratificação preservou a distribuição original das três classes de sentimento no corpus rotulado, resultando na composição apresentada na Tabela 4.

Tabela 4 – Distribuição de classes no conjunto de teste ($n = 373$)

Classe	Instâncias	Proporção
Positivo	59	15,8%
Neutro	266	71,3%
Negativo	48	12,9%
Total	373	100,0%

Fonte: Elaborada pelo autor.

A predominância da classe neutra (71,3%) é consistente com o caráter editorial e factual das publicações dos veículos analisados, conforme discutido na subseção 3.8.2, e constitui um fator relevante na interpretação das métricas de cada abordagem, em particular do F1-score macro, que é calculado sem ponderação pelo tamanho de cada classe.

4.1.2 Protocolo de Avaliação

Todas as quatro abordagens avaliadas — OpLexicon v3.0, SentiLex-PT, FinBERT-PT-BR e BERTimbau ajustado — foram aplicadas exatamente ao mesmo conjunto de 373 instâncias de teste, sem que qualquer abordagem tenha tido acesso a esses exemplos durante o desenvolvimento ou o treinamento. Para o BERTimbau ajustado, o particionamento estratificado garantiu que os exemplos de teste nunca fizeram parte das partições de treinamento (70%) ou de validação (15%) utilizadas no *fine-tuning*.

As abordagens léxicas (OpLexicon e SentiLex-PT) e o FinBERT-PT-BR operam de forma determinística e não consomem dados de treinamento do corpus local; portanto, sua avaliação no conjunto de teste é direta e não sujeita a viés de vazamento (*data leakage*). As métricas calculadas para cada abordagem são as definidas na subseção 3.6.5: acurácia, precisão, revocação e F1-score por classe, F1-score macro e matriz de confusão. A implementação do protocolo de avaliação está centralizada no módulo `app/core/evaluation/metrics.py`, invocado via a função `evaluate(classificador)`.

4.1.3 Configuração do Fine-Tuning do BERTimbau

O processo de *fine-tuning* do BERTimbau, descrito em detalhes na ??, foi executado com os hiperparâmetros consolidados no Quadro 11.

Quadro 11 – Hiperparâmetros utilizados no *fine-tuning* do BERTimbau

Hiperparâmetro	Valor
Modelo base	neuralmind/bert-base-portuguese-cased
Taxa de aprendizado	5×10^{-5}
Tamanho do batch	8
Número máximo de épocas	12
Comprimento máximo (<i>tokens</i>)	512
<i>Warmup ratio</i>	0,10
<i>Weight decay</i>	0,01
<i>Early stopping</i>	Paciência de 2 épocas (F1 macro na dobra de validação)
Validação cruzada	4 dobras estratificadas (<i>best fold</i> : 1, F1 macro val. = 90,00%)
Função de perda	CrossEntropyLoss com pesos de classe balanceados
Semente aleatória	42

Fonte: Elaborada pelo autor.

O desbalanceamento de classes foi mitigado por meio de uma subclasse personalizada do `Trainer` da biblioteca *HuggingFace Transformers* (Wolf *et al.*, 2020) (`WeightedTrainer`), que recalcula a função de perda com pesos inversamente proporcionais à frequência de cada classe, calculados via `compute_class_weight('balanced')` do *scikit-learn*. O treinamento foi executado sobre a partição de 70% do corpus rotulado, com monitoramento sobre a partição de validação (15%) para ativação do *early stopping*.

4.1.4 Ambiente Computacional

O *pipeline* de avaliação foi executado em ambiente Python 3.11, com as principais dependências listadas no Quadro 12.

Quadro 12 – Principais dependências do ambiente de execução

Biblioteca	Finalidade
<code>transformers</code> (HuggingFace)	Carregamento e inferência dos modelos BERT
<code>scikit-learn</code>	Métricas de avaliação e pesos de classe
<code>torch</code> (PyTorch)	Backend de treinamento e inferência neural
<code>pandas</code> / <code>numpy</code>	Manipulação de dados e matrizes
<code>psycopg2</code>	Acesso ao banco de dados PostgreSQL
<code>loguru</code>	Registro de eventos do <i>pipeline</i>

Fonte: Elaborada pelo autor.

O banco de dados PostgreSQL foi provisionado em contêiner Docker, e os artefatos do *fine-tuning* do BERTimbau — incluindo a matriz de confusão e o relatório de classificação do conjunto de teste — foram persistidos no diretório `models/bert-timbau-sentiment/eval/` do repositório do *pipeline*.

4.2 Resultados por Abordagem

Esta seção apresenta os resultados individuais de cada abordagem de classificação sobre o conjunto de teste ($n = 373$). Para cada abordagem são reportados: o relatório completo de classificação por classe (subseção 3.6.5) e a matriz de confusão, que evidencia os padrões sistemáticos de acerto e erro.

4.2.1 OpLexicon v3.0

O OpLexicon v3.0 (Souza; Vieira, 2011) classifica cada publicação pela polaridade líquida dos termos presentes no léxico, após a etapa de pré-processamento. O resultado apresentado na Tabela 5 revela o desempenho mais baixo entre as quatro abordagens avaliadas.

Tabela 5 – Métricas de desempenho do OpLexicon v3.0 ($n = 373$)

Classe	Precisão	Revocação	F1-Score	Suporte
Positivo	0,17	0,81	0,28	59
Neutro	0,78	0,12	0,21	266
Negativo	0,19	0,19	0,19	48
<i>Macro avg</i>	0,38	0,37	0,23	373
<i>Acurácia</i>	—	—	0,24	373

Fonte: Elaborada pelo autor.

Tabela 6 – Matriz de confusão do OpLexicon v3.0. Linhas: rótulo verdadeiro; colunas: rótulo predito.

	Pred. Positivo	Pred. Neutro	Pred. Negativo
Real Positivo	48	4	7
Real Neutro	202	32	32
Real Negativo	34	5	9

Fonte: Elaborada pelo autor.

O OpLexicon alcançou acurácia de 23,86% e F1-score macro de 22,53%, indicando desempenho sistematicamente inferior ao classificador aleatório estratificado. A matriz de confusão (Tabela 6) revela o principal padrão de falha: 202 das 266 publicações neutras (75,9%) foram classificadas como positivo, evidenciando uma tendência de atribuir polaridade positiva a publicações jornalísticas factuais cujo vocabulário financeiro não carrega sinal negativo explícito. A classe neutro, dominante no corpus, obteve revocação de apenas 12%, o que significa que a abordagem léxica é incapaz de identificar o padrão de ausência de sentimento predominante neste tipo de dado.

4.2.2 SentiLex-PT

O SentiLex-PT (Silva; Carvalho; Sarmento, 2012) é um léxico de sentimentos para o português construído a partir de entradas morfológicamente anotadas. Os resultados são apresentados na Tabela 7.

Tabela 7 – Métricas de desempenho do SentiLex-PT ($n = 373$)

Classe	Precisão	Revocação	F1-Score	Suporte
Positivo	0,19	0,61	0,29	59
Neutro	0,75	0,18	0,29	266
Negativo	0,20	0,50	0,28	48
<i>Macro avg</i>	0,38	0,43	0,29	373
<i>Acurácia</i>	—	—	0,29	373

Fonte: Elaborada pelo autor.

Tabela 8 – Matriz de confusão do SentiLex-PT. Linhas: rótulo verdadeiro; colunas: rótulo predito.

	Pred. Positivo	Pred. Neutro	Pred. Negativo
Real Positivo	36	6	17
Real Neutro	138	48	80
Real Negativo	14	10	24

Fonte: Elaborada pelo autor.

O SentiLex-PT obteve acurácia de 33,51% e F1-score macro de 30,79%, ligeiramente superior ao OpLexicon, mas ainda muito abaixo de um classificador por maioria de classe

(*majority class baseline*). A matriz de confusão (Tabela 8) evidencia que 127 das 266 publicações neutras (47,7%) foram classificadas como positivo, padrão análogo ao observado no OpLexicon. A revocação da classe neutra é igualmente baixa (28%), confirmando a dificuldade estrutural de abordagens léxicas em reconhecer ausência de polaridade em textos de caráter informativo. O SentiLex-PT distribui mais erros entre positivo e negativo do que o OpLexicon, refletindo diferenças na cobertura léxica de cada recurso.

O SentiLex-PT obteve acurácia de 28,95% e F1-score macro de 28,88%, ligeiramente superior ao OpLexicon, mas ainda muito abaixo de um classificador por maioria de classe (*majority class baseline*). A matriz de confusão (Tabela 8) evidencia que 138 das 266 publicações neutras (51,9%) foram classificadas como positivo, padrão análogo ao observado no OpLexicon. A revocação da classe neutra é igualmente baixa (18%), confirmando a dificuldade estrutural de abordagens léxicas em reconhecer ausência de polaridade em textos de caráter informativo. O SentiLex-PT distribui mais erros entre positivo e negativo do que o OpLexicon, refletindo diferenças na cobertura léxica de cada recurso.

4.2.3 FinBERT-PT-BR

O FinBERT-PT-BR (Santos; Bianchi; Costa, 2023) é um modelo BERT especializado para o domínio financeiro em língua portuguesa, pré-treinado sobre corpus de notícias financeiras. Neste trabalho, o modelo é utilizado em modo de inferência direta (*zero-shot* em relação ao corpus local), sem qualquer ajuste sobre as publicações coletadas, conforme descrito na ???. Os resultados são apresentados na Tabela 9.

Tabela 9 – Métricas de desempenho do FinBERT-PT-BR ($n = 373$)

Classe	Precisão	Revocação	F1-Score	Suporte
Positivo	0,41	0,47	0,44	59
Neutro	0,88	0,30	0,45	266
Negativo	0,20	0,88	0,32	48
<i>Macro avg</i>	0,49	0,55	0,40	373
<i>Acurácia</i>	—	—	0,40	373

Fonte: Elaborada pelo autor.

Tabela 10 – Matriz de confusão do FinBERT-PT-BR. Linhas: rótulo verdadeiro; colunas: rótulo predito.

	Pred. Positivo	Pred. Neutro	Pred. Negativo
Real Positivo	28	7	24
Real Neutro	39	81	146
Real Negativo	2	4	42

Fonte: Elaborada pelo autor.

O FinBERT-PT-BR alcançou acurácia de 45,58% e F1-score macro de 43,20%, um resultado superior às abordagens léxicas, mas distante do desempenho documentado pelos autores do modelo sobre o corpus de notícias financeiras de treinamento (Santos; Bianchi; Costa, 2023). O padrão mais relevante na Tabela 10 é o viés pronunciado em favor da classe negativo: o modelo classificou 145 das 266 publicações neutras (54,5%) e 27 das 59 positivas (45,8%) como negativo, atingindo revocação de 88% nessa classe à custa de precisão de apenas 20%. Esse comportamento indica que o modelo generaliza excessivamente o padrão negativo aprendido a partir do corpus de notícias formais — no qual termos como “queda”, “perda” e “risco” são indicadores frequentes de sentimento negativo — para publicações de formato editorial curto do X/Twitter, nas quais o mesmo vocabulário aparece recorrentemente em contextos factuais e neutros.

O FinBERT-PT-BR alcançou acurácia de 40,48% e F1-score macro de 40,44%, um resultado superior às abordagens léxicas, mas distante do desempenho documentado pelos autores do modelo sobre o corpus de notícias financeiras de treinamento (Santos; Bianchi; Costa, 2023). O padrão mais relevante na Tabela 10 é o viés pronunciado em favor da classe negativo: o modelo classificou 146 das 266 publicações neutras (54,9%) e 24 das 59 positivas (40,7%) como negativo, atingindo revocação de 88% nessa classe à custa de precisão de apenas 20%. Esse comportamento indica que o modelo generaliza excessivamente o padrão negativo aprendido a partir do corpus de notícias formais — no qual termos como “queda”, “perda” e “risco” são indicadores frequentes de sentimento negativo — para publicações de formato editorial curto do X/Twitter, nas quais o mesmo vocabulário aparece recorrentemente em contextos factuais e neutros.

4.2.4 BERTimbau Ajustado

O BERTimbau (`neuralmind/bert-base-portuguese-cased`) (Souza; Nogueira; Lotufo, 2020) foi submetido a *fine-tuning* sobre a partição de treinamento do corpus rotulado, conforme o protocolo descrito na ???. Os resultados, apresentados na Tabela 11, revelam desempenho amplamente superior às demais abordagens avaliadas.

Tabela 11 – Métricas de desempenho do BERTimbau ajustado ($n = 373$)

Classe	Precisão	Revocação	F1-Score	Suporte
Positivo	0,85	0,76	0,80	59
Neutro	0,90	0,97	0,93	266
Negativo	0,89	0,65	0,75	48
<i>Macro avg</i>	0,88	0,79	0,83	373
<i>Acurácia</i>	—	—	0,89	373

Fonte: Elaborada pelo autor.

O BERTimbau ajustado alcançou acurácia de 89,28% e F1-score macro de 82,78%, representando ganhos absolutos de 48,8 pontos percentuais em acurácia e 42,3 pontos

Tabela 12 – Matriz de confusão do BERTimbau ajustado. Linhas: rótulo verdadeiro; colunas: rótulo predito.

	Pred. Positivo	Pred. Neutro	Pred. Negativo
Real Positivo	45	12	2
Real Neutro	7	257	2
Real Negativo	1	16	31

Fonte: Elaborada pelo autor.

em F1-score macro em relação ao FinBERT-PT-BR. A matriz de confusão (Tabela 12) evidencia que o modelo distribuiu os erros de forma muito mais equilibrada entre as três classes: 257 das 266 instâncias neutras (96,6%) foram corretamente classificadas, 45 das 59 positivas (76,3%) e 31 das 48 negativas (64,6%). Diferentemente do FinBERT-PT-BR, o BERTimbau ajustado não apresenta viés sistemático em favor de nenhuma classe; os erros residuais concentram-se principalmente em confusão entre neutro e as classes minoritárias (12 positivos classificados como neutro e 16 negativos como neutro), um padrão esperado dado o desequilíbrio de classes no corpus.

4.3 Análise Comparativa

A Tabela 13 consolida os resultados das quatro abordagens avaliadas sobre o mesmo conjunto de teste ($n = 373$), permitindo a comparação direta de acurácia, F1-score por classe e F1-score macro.

Tabela 13 – Comparativo de desempenho entre as quatro abordagens ($n = 373$). F1-scores expressos por classe (Pos, Neu, Neg) e como média macro (Macro). Melhor resultado por coluna em negrito.

Abordagem	Acurácia	F1 Pos	F1 Neu	F1 Neg	F1 Macro
OpLexicon v3.0	0,24	0,28	0,21	0,19	0,23
SentiLex-PT	0,29	0,29	0,29	0,28	0,29
FinBERT-PT-BR	0,40	0,44	0,45	0,32	0,40
BERTimbau (FT)	0,89	0,80	0,93	0,75	0,83

Fonte: Elaborada pelo autor. (FT) = *fine-tuned* sobre o corpus local.

4.3.1 Hierarquia de Desempenho

Os resultados estabelecem uma hierarquia clara entre as abordagens, ordenada por complexidade metodológica crescente: OpLexicon < SentiLex-PT < FinBERT-PT-BR << BERTimbau ajustado. O salto de desempenho mais expressivo ocorre entre o FinBERT-PT-BR e o BERTimbau ajustado: a adaptação ao gênero e ao subdomínio via *fine-tuning* local produziu ganhos de 48,8 pontos percentuais em acurácia e 42,3 pontos

em F1-score macro, valores que colocam o BERTimbau ajustado como a única abordagem com desempenho praticamente utilizável para classificação de sentimento neste corpus.

Entre as abordagens léxicas, o SentiLex-PT supera marginalmente o OpLexicon em F1-score macro (28,88% versus 22,53%), diferença atribuível, em parte, à maior cobertura morfológica do SentiLex-PT, que inclui entradas anotadas com classes gramaticais e permite maior precisão na recuperação de termos flexionados. Nenhuma das duas abordagens, contudo, supera o limiar de desempenho de um classificador por maioria de classe — que obteria acurácia de 71,3% ao classificar todas as instâncias como neutro — evidenciando que a tarefa não pode ser resolvida por correspondência léxica simples neste tipo de corpus.

4.3.2 Desempenho nas Classes Minoritárias

O desempenho nas classes minoritárias (positivo e negativo) é o discriminador mais revelador entre as abordagens. A Tabela 14 detalha precisão e revocação das três classes para cada abordagem.

Tabela 14 – Precisão (P) e revocação (R) por classe para cada abordagem

Abordagem	Positivo		Neutro		Negativo	
	P	R	P	R	P	R
OpLexicon v3.0	0,17	0,81	0,78	0,12	0,19	0,19
SentiLex-PT	0,19	0,61	0,75	0,18	0,20	0,50
FinBERT-PT-BR	0,41	0,47	0,88	0,30	0,20	0,88
BERTimbau (FT)	0,85	0,76	0,90	0,97	0,89	0,65

Fonte: Elaborada pelo autor.

As abordagens léxicas apresentam revocação aparentemente elevada para a classe positivo (OpLexicon: 81%; SentiLex-PT: 61%), mas com precisão inferior a 20%, o que indica que a maioria das predições positivas é incorreta — a proporção de verdadeiros positivos no total de predições positivas é baixíssima. Esse padrão reflete a tendência das abordagens léxicas de superclassificar instâncias como positivo quando o vocabulário não apresenta polaridade negativa explícita, mesmo que o conteúdo seja factual e neutro.

O FinBERT-PT-BR apresenta o inverso para a classe negativo: revocação de 88% com precisão de apenas 20%, confirmando o viés pronunciado discutido na subseção 4.2.3. O modelo recupera quase todas as instâncias verdadeiramente negativas, mas ao custo de classificar incorretamente grande parte das neutras como negativas.

O BERTimbau ajustado é a única abordagem que simultaneamente mantém precisão e revocação acima de 65% para todas as três classes, incluindo as minoritárias. Esse resultado indica que o *fine-tuning* local capacitou o modelo a discriminar os padrões linguísticos específicos das três classes no contexto de publicações financeiras do X/Twitter em português, sem privilegiar sistematicamente nenhuma das classes ao custo das demais.

4.3.3 Viés de Classe Neutra

O tratamento da classe neutra é um indicador relevante da qualidade de cada abordagem para a tarefa específica deste trabalho. Publicações jornalísticas financeiras são predominantemente neutras — 71,3% do corpus de teste — e a correta identificação dessa classe é condição para a geração de um índice de sentimento com distribuição de polaridade fiel ao corpus. A Tabela 13 mostra que somente o BERTimbau ajustado alcança F1-score acima de 0,80 para a classe neutra ($F1 = 0,93$). As demais abordagens variam entre 0,21 (OpLexicon) e 0,45 (FinBERT-PT-BR) para essa classe, o que implica que seus índices de sentimento subestimariam sistematicamente a proporção de publicações neutras e exageram a fração de publicações com polaridade definida.

4.4 Discussão

4.4.1 Especialização Prévia versus Ajuste Local ao Gênero

O contraste mais relevante que emerge dos resultados é o que opõe o FinBERT-PT-BR ao BERTimbau ajustado, duas abordagens neurais que diferem fundamentalmente na estratégia de especialização ao domínio e ao gênero. O FinBERT-PT-BR incorpora **especialização prévia de domínio** (*prior domain specialization*): o modelo foi pré-treinado sobre um corpus de notícias financeiras formais em português (Santos; Bianchi; Costa, 2023), o que lhe confere vocabulário financeiro robusto, mas não o prepara para as particularidades do gênero textual de publicações do X/Twitter — sentenças curtas, uso de emojis convertidos, menções a tickers, estilo telegráfico e ausência de marcadores explícitos de polaridade. O BERTimbau ajustado incorpora **especialização pós-hoc de gênero e subdomínio** (*post hoc genre and subdomain specialization*): o modelo base generalista (Souza; Nogueira; Lotufo, 2020) foi adaptado diretamente sobre publicações do mesmo gênero e subdomínio que compõem o corpus de avaliação.

Os resultados confirmam a hipótese de que a adaptação local ao gênero produz ganhos substanciais mesmo quando comparada a um modelo com especialização de domínio prévia: o BERTimbau ajustado superou o FinBERT-PT-BR em 34,2 pontos percentuais de F1-score macro (77,45% versus 43,20%). Esse achado está alinhado com a tradição de *fine-tuning* de modelos de linguagem em domínios especializados (Devlin *et al.*, 2019; Santos; Bianchi; Costa, 2023), que demonstra que a proximidade entre os dados de ajuste e os dados de inferência é um fator determinante para o desempenho em tarefas de classificação de sentimento.

4.4.2 Diagnóstico do Viés do FinBERT-PT-BR

O viés do FinBERT-PT-BR em favor da classe negativo (revocação de 88%, precisão de 20%) merece análise específica. Uma hipótese explicativa plausível é a distribuição assimétrica de sentimento no corpus de treinamento do modelo: notícias financeiras formais

tendem a tratar de eventos de risco, quedas de indicadores, inadimplência e crises, gerando uma representação mais densa de vocabulário negativo no espaço de *embeddings* do modelo. Quando aplicado a publicações do X/Twitter, o modelo interpreta o vocabulário neutro de cobertura de mercado (e.g., “variação”, “fechamento”, “resultado”) como sinal negativo, produzindo o padrão de superclassificação observado. Esse diagnóstico é consistente com a observação de Loughran e McDonald (2011), que documentaram que léxicos de sentimento geral aplicados ao domínio financeiro frequentemente atribuem polaridade incorreta a termos com significado neutro ou positivo em contextos de negócios.

4.4.3 Limitações das Abordagens Léxicas em Corpus de Tweet

O desempenho das abordagens léxicas — OpLexicon (F1 macro 26,83%) e SentiLex-PT (F1 macro 30,79%) — é sistematicamente inferior ao que seria esperado de uma aplicação ao domínio para o qual foram construídos: textos em português com marcadores explícitos de polaridade. Dois fatores estruturais explicam esse resultado. Primeiro, publicações jornalísticas financeiras do X/Twitter são predominantemente informativas e factuais; a proporção de termos com polaridade lexical explícita é baixa, o que reduz a capacidade de discriminação dos léxicos. Segundo, a ausência de mecanismos de desambiguação contextual implica que termos polissêmicos ou dependentes de contexto (e.g., “alta” como variação de preço versus expressão de intensidade) são classificados com base apenas em sua ocorrência, independentemente do sentido contextual (Liu; Zheng; Song, 2020).

Ressalta-se que o OpLexicon e o SentiLex-PT foram construídos para o português de domínio geral, sem especialização para o vocabulário financeiro; o desempenho observado pode ser interpretado como um *baseline* léxico de referência, não como o limite superior das abordagens baseadas em léxico para o domínio.

4.4.4 Restrições à Generalização dos Resultados

Os resultados devem ser interpretados considerando as restrições metodológicas identificadas na seção 3.8. O conjunto de teste foi anotado por um único avaliador, inviabilizando o cálculo de concordância interanotadores; a margem de incerteza associada à qualidade do *gold standard* não é quantificada. Adicionalmente, o corpus é restrito a dois veículos de mídia financeira institucional (InfoMoney e InvestingBrasil), o que circunscreve a representatividade dos resultados ao gênero editorial financeiro em língua portuguesa — os achados podem não ser diretamente generalizáveis a outros gêneros textuais do domínio financeiro, como análises de analistas independentes, fóruns de investidores ou mensagens de corretoras.

Por fim, o tamanho do corpus de ajuste do BERTimbau (aproximadamente 2.600 instâncias de treinamento) é modesto em comparação com os corpora utilizados em estudos de *fine-tuning* de grande escala; a utilização de conjuntos de dados maiores e de maior

diversidade de gênero poderia produzir modelos com desempenho superior nas classes minoritárias, especialmente positivo ($F1 = 0,72$) e negativo ($F1 = 0,69$).

5 CONCLUSÕES

REFERÊNCIAS

- ANTWEILER, W.; FRANK, M. Z. Is all that talk just noise? The information content of internet stock message boards. **The Journal of Finance**, v. 59, n. 3, p. 1259–1294, 2004. Acesso aberto (PDF do autor): <https://wernerantweiler.ca/public/noise-a.pdf>. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=282320.
- ARACI, D. FinBERT: Financial sentiment analysis with pre-trained language models. **arXiv preprint**, 2019. Disponível em: <https://arxiv.org/abs/1908.10063>.
- BAKER, M.; WURGLER, J. Investor sentiment in the stock market. **Journal of Economic Perspectives**, v. 21, n. 2, p. 129–151, 2007. Acesso aberto (PDF NYU): https://pages.stern.nyu.edu/~jwurgler/papers/wurgler_baker_investor_sentiment.pdf. AEA: <https://www.aeaweb.org/articles?id=10.1257/jep.21.2.129>.
- BOLLEN, J.; MAO, H.; ZENG, X. Twitter mood predicts the stock market. **Journal of Computational Science**, v. 2, n. 1, p. 1–8, 2011. Acesso aberto (arXiv): <https://arxiv.org/abs/1010.3003>.
- CASELI, H. d. M.; NUNES, M. d. G. V.; PAGANO, A. O que é PLN? In: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 1. ISBN 978-65-01-20581-6. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao/parte-introducao/cap-introducao/cap-introducao.html>.
- CHEN, M.; MAO, S.; LIU, Y. Big data: A survey. **Mobile Networks and Applications**, v. 19, n. 2, p. 171–209, 2014. Acesso aberto (ResearchGate): https://www.researchgate.net/publication/259529914_Big_Data_A_Survey. Springer: <https://link.springer.com/article/10.1007/s11036-013-0489-0>.
- CLARO, D. B. *et al.* Extração de informação. In: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 22. ISBN 978-65-01-20581-6. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao/parte-aplicacoes/cap-ie/cap-ie.html>.
- DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. Association for Computational Linguistics, 2019. p. 4171–4186. Disponível em: <https://arxiv.org/abs/1810.04805>.
- FALCÃO, M. C. d. S. **Análise de Sentimento de Notícias do Mercado Financeiro**. 2020. Monografia (Projeto de Graduação) — Escola Politécnica, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2020. Orientador: Prof. Heraldo Luís Silveira de Almeida, D.Sc.
- FAMA, E. F. Efficient capital markets: A review of theory and empirical work. **The Journal of Finance**, v. 25, n. 2, p. 383–417, 1970. Acesso aberto (PDF): <https://people.hec.edu/rosu/wp-content/uploads/sites/43/2023/09/Fama-Efficient-capital-markets-1970.pdf>. JSTOR: <https://www.jstor.org/stable/2325486>.

FAMA, E. F. Efficient capital markets: II. **The Journal of Finance**, v. 46, n. 5, p. 1575–1617, 1991. Acesso aberto (PDF): <https://www.bu.edu/econ/files/2011/01/Fama2.pdf>. Wiley: <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1540-6261.1991.tb04636.x>.

FREITAS, C. Dataset e corpus. In: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 13. ISBN 978-65-01-20581-6. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao/parte-dados-avaliacao/cap-dataset-corpus/cap-dataset-corpus.html>.

GALDI, F. C.; GONÇALVES, A. M. Pessimismo e incerteza das notícias e o comportamento dos investidores no brasil. **Revista de Administração de Empresas**, Fundação Getulio Vargas, Escola de Administração de Empresas de S.Paulo, v. 58, n. 2, p. 130–148, mar. 2018. ISSN 0034-7590. Disponível em: <https://doi.org/10.1590/S0034-759020180203>.

GROSSMAN, S. J.; STIGLITZ, J. E. On the impossibility of informationally efficient markets. **The American Economic Review**, v. 70, n. 3, p. 393–408, 1980. JSTOR: <https://www.jstor.org/stable/1805228>.

JR., N. C. A. C. Overreaction in the Brazilian stock market. **Journal of Banking & Finance**, v. 18, n. 4, p. 633–642, 1994. ScienceDirect: <https://www.sciencedirect.com/science/article/abs/pii/0378426694000115>.

JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models**. 3rd. ed. [S.l.: s.n.], 2026. Online manuscript released January 6, 2026. Disponível em: <https://web.stanford.edu/~jurafsky/slp3/>.

KEARNEY, C.; LIU, S. Textual sentiment in finance: A survey of methods and models. **International Review of Financial Analysis**, v. 33, p. 171–185, 2014. Acesso aberto (Open Access UCD): <https://researchrepository.ucd.ie/handle/10197/8213>. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2213801. ScienceDirect: <https://www.sciencedirect.com/science/article/abs/pii/S1057521914000295>.

LANEY, D. **3D Data Management: Controlling Data Volume, Velocity, and Variety**. [S.l.], 2001. Documento fundacional do conceito dos “3 Vs” do Big Data. Acesso aberto (PDF Gartner): <http://blogs.gartner.com/doug-laney/files/2012/01/ad949-3D-Data-Management-Controlling-Data-Volume-Velocity-and-Variety.pdf>.

LIU, X.; ZHENG, X.; SONG, X. A survey of text classification: From shallow to deep learning. **arXiv preprint**, 2020. Acesso aberto (arXiv): <https://arxiv.org/abs/2008.00364>.

LO, A. W. The adaptive markets hypothesis: Market efficiency from an evolutionary perspective. **The Journal of Portfolio Management**, v. 30, n. 5, p. 15–29, 2004. Acesso aberto (PDF MIT): https://web.mit.edu/Alo/www/Papers/JPM2004_Pub.pdf. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=602222.

LO, A. W. Reconciling efficient markets with behavioral finance: The adaptive markets hypothesis. **Journal of Investment Consulting**, v. 7, n. 2, p. 21–44, 2005. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=728864.

- LOUGHRAN, T.; MCDONALD, B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. **The Journal of Finance**, v. 66, n. 1, p. 35–65, 2011. Acesso aberto (PDF do autor): https://www3.nd.edu/~mcdonald/Word_Lists_files/Publications/Loughran_McDonald_2011_JF.pdf. Wiley: <https://onlinelibrary.wiley.com/doi/10.1111/j.1540-6261.2010.01625.x>.
- LUCAS, I. d. C.; PEIXOTO, N. G. M. Análise de sentimento com abordagem léxica: Aplicação em notícias do mercado financeiro. **Trabalho de Conclusão de Curso — Bacharelado em Engenharia de Software, PUC Minas**, 2025. Orientador: Rodrigo Baroni de Carvalho. Belo Horizonte, 30 de junho de 2025.
- MAO, H.; COUNTS, S.; BOLLEN, J. Predicting financial markets: Comparing survey, news, Twitter and search engine data. **arXiv preprint**, 2011. Acesso aberto (arXiv): <https://arxiv.org/abs/1112.1051>.
- MAYER-SCHÖNBERGER, V.; CUKIER, K. **Big Data: A Revolution That Will Transform How We Live, Work, and Think**. Boston, MA: Houghton Mifflin Harcourt, 2013. ACM Digital Library: <https://dl.acm.org/doi/10.5555/2588165>. Google Books (prévia): <https://books.google.com/books?id=uy4lh-WEhhIC>. ISBN 9780544002692.
- RANCO, G. *et al.* The effects of Twitter sentiment on stock price returns. **PLOS ONE**, v. 10, n. 9, p. e0138441, 2015. Acesso aberto (PLOS ONE): <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0138441>. arXiv: <https://arxiv.org/abs/1506.02431>.
- SANTANA, B. S.; FREITAS, L. A. d. PLN em redes sociais. In: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 34. ISBN 978-65-01-20581-6. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao/parte-dominios/cap-redes-sociais/cap-redes-sociais.html>.
- SANTOS, L. L.; BIANCHI, R. A. C.; COSTA, A. H. R. FinBERT-PT-BR: Análise de sentimentos de textos em português do mercado financeiro. In: **Anais do Brazilian Workshop on Artificial Intelligence in Finance (BWAIF)**. Porto Alegre, RS, Brasil: SBC, 2023. Disponível em: <https://sol.sbc.org.br/index.php/bwaif/article/view/24960>.
- SILVA, F. S. d. *et al.* Processo de extração de sentimento no mercado financeiro. **Boletim de Conjuntura (BOCA)**, v. 21, n. 62, p. 318–338, 2025. ISSN: 2675-1488. Acesso aberto: <https://doi.org/10.5281/zenodo.15092801>.
- SILVA, M. J.; CARVALHO, P.; SARMENTO, L. Building a sentiment lexicon for social judgement mining. In: **Proceedings of the 10th International Conference on Computational Processing of the Portuguese Language (PROPOR)**. [S.l.: s.n.]: Springer, 2012. p. 218–228. Apresenta o SentiLex-PT, léxico de sentimento para o português com cobertura de 7.014 lemas e 82.347 formas flexionadas.
- SOUSA, T. M. d. *et al.* Expansão automática de léxico para análise de sentimentos de textos no domínio do mercado financeiro brasileiro. **Revista de Educação, Ciência e Tecnologia do IFG**, v. 10, n. Edição Especial 1, 2025. Submetido: 30/05/2024. Aprovado: 21/03/2025.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for brazilian portuguese. *In: 9th Brazilian Conference on Intelligent Systems (BRACIS)*. Springer, 2020. p. 403–417. Disponível em: <https://arxiv.org/abs/2006.02960>.

SOUZA, M.; VIEIRA, R. Sentiment analysis on twitter with portuguese language corpora. *In: 8th Brazilian Symposium in Information and Human Language Technology (STIL)*. Cuiabá, MT, Brasil: [S.l.: s.n.], 2011. Descreve a construção e validação do OpLexicon, léxico de polaridade para o português brasileiro.

SPRENGER, T. O. *et al.* Tweets and trades: The information content of stock microblogs. **European Financial Management**, v. 20, n. 5, p. 926–957, 2014. Wiley: <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1468-036X.2013.12007.x>. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=1702854.

TETLOCK, P. C. Giving content to investor sentiment: The role of media in the stock market. **The Journal of Finance**, v. 62, n. 3, p. 1139–1168, 2007. Acesso aberto (PDF Columbia): https://business.columbia.edu/sites/default/files-efs/pubfiles/3097/Tetlock_Media_Sentiment_JF.pdf. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=685145.

The pandas development team. pandas-dev/pandas: Pandas. *In: . Zenodo*, 2020. Biblioteca Python para manipulação e análise de dados tabulares. Versão 2.x. Disponível em: <https://doi.org/10.5281/zenodo.3509134>.

VASWANI, A. *et al.* Attention is all you need. *In: Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30. Disponível em: <https://arxiv.org/abs/1706.03762>.

WOLF, T. *et al.* Transformers: State-of-the-art natural language processing. *In: Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2020. p. 38–45. Biblioteca **transformers** da Hugging Face para carregamento e inferência de modelos BERT e derivados. Disponível em: <https://arxiv.org/abs/1910.03771>.

YOSHINAGA, C. E.; CASTRO, F. H. F. d. The relationship between market sentiment index and stock rates of return: A panel data analysis. **Brazilian Administration Review**, v. 9, n. 2, p. 189–210, 2012. Acesso aberto (SciELO): <https://www.scielo.br/j/bar/a/MFZPpHF8fH9PfjQ3h4QLWFs/>.